

DOCUMENTACIÓN TÉCNICA

NexusMQ

Broker de mensajería distribuido en C++23
shared-nothing thread-per-core · Raft por partición

Andrés Ojeda Rodríguez · 2026

Tabla de contenidos

Documentación técnica

Prefacio

1. Resumen ejecutivo

2. Contexto y motivación

3. Estado del arte

4. Glosario

5. Vista de conjunto

6. Principios de diseño

7. Concurrencia

8. Modelo de I/O

9. Almacenamiento

10. Replicación y consenso

11. Ingress

12. Observabilidad

13. Protocolo binario nativo

14. Subconjunto Kafka

15. API REST de administración

16. Modelo de errores y códigos de wire

17. Mapa de módulos

18. Catálogo por subsistema

19. Arranque y composition root

20. Herramientas y bindings

21. Estrategia de pruebas

22. Puerta de calidad y CI/CD

23. Rendimiento y benchmarks

24. Portabilidad

25. Despliegue

26. Configuración y operación

27. Seguridad

28. Registro de decisiones (ADR)

29. Historia de desarrollo

30. Limitaciones y trabajo futuro

Apéndice A. Bibliografía

Apéndice — Catálogo de diagramas

Diagrama 1: Contexto del sistema (C4 nivel 1)

Diagrama 2: Contenedores de un nodo (C4 nivel 2)

Diagrama 3: Grafo de dependencias de targets

Diagrama 4: Mapa fase → targets

Diagrama 5: Topología thread-per-core (shared-nothing)

Diagrama 6: Sharding del plano de datos por núcleo

Diagrama 7: Secuencia de una operación de E/S sobre el proactor

Diagrama 8: Layout del log de una partición

Diagrama 9: Retención y compactación del log

Diagrama 10: Estados y transiciones de una réplica Raft

Diagrama 11: Replicación y confirmación a quórum (``acks=quorum``)

Diagrama 12: Failover y elección de líder

Diagrama 13: Espacios de coordenadas (índice de entrada Raft vs offset por record)

Diagrama 14: Compactación por snapshot e ``InstallSnapshot``

Diagrama 15: Planos de red (cliente vs inter-nodo Raft)

Diagrama 16: Layout de la cabecera del frame nativo

Diagrama 17: Petición/respuesta del subconjunto Kafka

Diagrama 18: Flujo REST admin con JWT

Diagrama 19: Ingress en dos modos — nativo directo vs proxy

Diagrama 20: Puente TLS — OpenSSL síncrono sobre el proactor asíncrono

Diagrama 21: Despliegue local con Docker Compose

Diagrama 22: Despliegue en Kubernetes — StatefulSet + Service headless

Diagrama 23: Pipeline de observabilidad — métricas y logs

Diagrama 24: Almacenamiento por niveles (tiered storage)

Diagrama 25: Transacciones y 2PC logueado (exactly-once nativo)

Apéndice — Registro de decisiones (ADR)

Registro de decisiones de arquitectura (ADR)

ADR-0001: Plataforma de desarrollo y `*target*` (Linux primero, Windows después)

ADR-0002: Modelo de I/O asíncrona (proactor; io_uring primero, IOCP después)

ADR-0003: Modelo de replicación (Raft por partición)

ADR-0004: Protocolo del plano de datos (binario propio + gateway REST)

ADR-0005: Arquitectura de concurrencia (*shared-nothing thread-per-core* con reactor propio)

ADR-0006: Rol del *ingress* (dos modos: nativo directo + proxy/REST)

ADR-0007: Postura de consistencia (CP / PACELC PC-EC)

ADR-0008: Viabilidad de coste cero (desarrollo y test gratuitos; cloud como *target* opcional)

ADR-0009: Política de manejo de errores por capa (excepciones / `std::expected` / códigos de wire)

ADR-0010: Entorno de desarrollo (VS Code sobre WSL; reemplaza el IDE de ADR-0001)

ADR-0011: Estándar C++23 + libc++ en Clang (para `std::expected`)

ADR-0012: Backend io_uring directo sobre el uapi del kernel (sin liburing)

ADR-0013: Capa `nexus-wire` para el framing sobre conexión (`FrameReader`/`FrameWriter`)

ADR-0014: Modelo del log de Raft (índice = ordinal de entrada; término en sidecar)

ADR-0015: RaftNode como máquina de estados síncrona sin E/S (entradas→salidas)

ADR-0016: `ReplicatedPartition` como tipo paralelo a `Partition` (composición de la pila Raft)

ADR-0017: Target `nexus-telemetry` para observabilidad (métricas/logs) bajo el broker

ADR-0018: REST admin por puerto/adaptador (`AdminService` en ingress, `AdminApi` en server)

ADR-0019: TLS opcional vía OpenSSL con puente de BIOS de memoria sobre el `Proactor`

ADR-0020: *Binding* de Python vía **ABI C estable** (`nexus-ffi` + `ctypes`) en lugar de pybind11

ADR-0021: Backend **IOCP** (Windows) — diseño fijado, **implementación diferida**

ADR-0022: Backend **IOCP** (Windows) — **implementado** y compile-verificado con MinGW (reemplaza ADR-0021)

ADR-0023: Backend **IOCP** (Windows) — **verificado en runtime** sobre Windows con MSVC (reemplaza ADR-0022)

ADR-0024: Compactación del log de Raft por **snapshot** (base de snapshot en `RaftLog`)

ADR-0025: Activación en producción del stack Raft + multi-reactor con transporte inter-nodo real

ADR-0026: Sharding por núcleo del plano de datos — partición→núcleo y coordinación de grupos por hash

ADR-0027: Cableado del modo proxy en el plano de datos — *pool* de conexiones aguas arriba por reactor

ADR-0028: Port **completo** de `nexusrd` a Windows — backend, afinidad y señales por plataforma

ADR-0029: Adaptador Kafka **asíncrono cross-core** sobre el broker vivo + codec por versión (interop `kcat`)

ADR-0030: Partición mono-protocolo — guarda cross-protocol nativo/Kafka

ADR-0031: Cifrado en reposo del log con AES-256-GCM y framing AEAD por bloque

ADR-0032: Almacenamiento por niveles (tiered storage) — puerto `StorageTier` y tier local

ADR-0033: Exactly-once multi-partición nativo (transacciones, coordinador y `read\_committed`)

ADR-0034: 2PC logueado y recuperable (reconciliación con la prohibición del 2PC bloqueante)

Prefacio

Este documento es la **documentación técnica final** de NexusMQ: la referencia autoritativa del *qué*, el *porqué* y el *cómo* del sistema, organizada para leerse de principio a fin o consultarse por partes.

Qué es este documento

NexusMQ es un *message broker* de mensajería distribuido de alto rendimiento, escrito en **C++23**, con arquitectura **shared-nothing thread-per-core** (un reactor por núcleo físico, *pinned*) y **Raft por partición** como mecanismo único de replicación y consenso. Es un **proyecto de aprendizaje y portfolio**: su objetivo nº1 es demostrar profundidad técnica en un sistema coherente y criterio de ingeniería, no acumular funcionalidades.

Esta documentación recoge ese sistema **tal como está construido** (*as-built*): la visión y el contexto, la arquitectura y sus principios, los contratos de red, la implementación por subsistemas, la estrategia de calidad, la operación y, por último, el registro de decisiones de arquitectura (ADR) y la historia de su evolución por fases.

A quién va dirigido

- **Al autor**, como mapa de construcción y memoria del diseño.
- **A revisores técnicos** (entrevistadores, colaboradores) que evalúen el proyecto como muestra de competencia en sistemas e infraestructura, C++ de bajo nivel y *backend* distribuido. Lo que se pretende evidenciar es **profundidad dentro de una sola tesis arquitectónica** —correctitud distribuida, latencia y funcionamiento *end-to-end*— y **decisiones justificadas y medidas**, no una lista de características.

Se asume familiaridad con conceptos de sistemas (E/S, concurrencia, memoria) y de datos distribuidos (replicación, consenso). Los términos de dominio se definen en el [Glosario](#).

Cómo está organizado

La documentación se divide en **siete partes** más **apéndices**:

Parte	Contenido
I — Introducción y visión	Resumen ejecutivo, contexto y motivación, estado del arte y glosario.
II — Arquitectura	Vista de conjunto, principios de diseño, concurrencia, modelo de I/O, almacenamiento, replicación y consenso, <i>ingress</i> y observabilidad.
III — Contratos	Protocolo binario nativo, subconjunto Kafka, API REST de administración y modelo de errores.
IV — Implementación	Mapa de módulos, catálogo por subsistema, arranque y <i>composition root</i> , herramientas y <i>bindings</i> .
V — Calidad	Estrategia de pruebas, puerta de calidad y CI/CD, rendimiento y <i>benchmarks</i> , portabilidad.
VI — Operación y despliegue	Despliegue, configuración y operación, seguridad.
VII — Decisiones y evolución	Registro de decisiones (ADR), historia de desarrollo y trabajo futuro.

Los **apéndices** recogen la bibliografía, el índice de diagramas y una guía rápida de construcción y ejecución.

Cada capítulo vive en su propio fichero Markdown numerado bajo `docs/tecnica/`. Los **diagramas** (Mermaid, tablas y *layouts* ASCII) viven en `docs/diagramas/` y se referencian desde la prosa.

Relación con los contratos as-built y con los ADR

Esta documentación distingue, siguiendo **Diátaxis**, dos tipos de texto:

- **Referencia** — los **contratos as-built** en `docs/`: el protocolo binario nativo (`protocol.md`), el subconjunto Kafka (`kafka.md`), la API REST de administración (`openapi.yaml`) y la metodología y cifras de rendimiento (`benchmarks.md`). Son la **única fuente de verdad** de los detalles precisos (byte-layouts, ApiKeys y versiones, *endpoints*, números). Se consultan.
- **Explicación** — los capítulos narrativos de `docs/tecnica/`. Se leen en orden. Los capítulos de contratos (Parte III) **explican y enlazan** —dan *rationale*, flujos, ejemplos y diagramas— pero **no duplican** el contrato: remiten a él para evitar divergencia (*drift*).

Las **decisiones de arquitectura** se registran como ADR, uno por archivo, en `docs/adr/` (ADR-0001 a ADR-0029). Un ADR aceptado **no se edita**: si una decisión cambia, se **reemplaza** por un ADR nuevo que marca al anterior como reemplazado. El registro narrado vive en el capítulo 28; los capítulos los referencian por su número (p. ej. `ADR-0005`).

Alcance y fuentes

Esta documentación técnica es la **fuentes de verdad** del proyecto: reparte y desarrolla la visión, la arquitectura y las decisiones por las siete partes, **extrae** los ADR a `docs/adr/` y se apoya en los **contratos as-built** de `docs/` (`protocol.md` , `kafka.md` , `openapi.yaml` , `benchmarks.md`). El código fuente en `src/` y la suite de pruebas son la referencia última cuando el detalle de implementación importa.

1. Resumen ejecutivo

Qué es NexusMQ, qué demuestra, cómo es su arquitectura en un vistazo y en qué estado se encuentra. Una página para situarse antes de entrar en el detalle.

Qué es

NexusMQ es un **broker de mensajería distribuido de alto rendimiento** escrito en **C++23**. Adopta el modelo de **log particionado** estilo Kafka: los productores **añaden** registros al final de un log *append-only* y los consumidores **leen** desde el *offset* que elijan y avanzan a su ritmo —el broker no borra al entregar, retiene por tiempo o tamaño—. Un *topic* es un flujo lógico dividido en **particiones**; cada partición es una secuencia ordenada e inmutable de registros, cada uno identificado por un *offset* monótono.

No pretende competir con Kafka en producción. Su propósito es **demostrar**, en una base de código propia y comprensible, las técnicas que hacen viable un sistema así. La arquitectura es la **frontera actual** del diseño de brokers (la que usa Redpanda), no la de hace una década.

Qué demuestra

El proyecto persigue **profundidad dentro de una sola tesis arquitectónica**, no amplitud. Lo que busca evidenciar es:

- **Profundidad técnica en un sistema coherente** — correctitud distribuida (consenso y replicación), latencia (camino caliente sin contención) y funcionamiento *end-to-end* (de la conexión del cliente al *fsync* en disco).
- **Criterio de ingeniería** — cada técnica avanzada se introduce **donde un profiling lo justifica** ("medido, no *checklist*"), y cada decisión de arquitectura queda registrada y argumentada como un [ADR](#).

Arquitectura en un vistazo

- **Shared-nothing thread-per-core**. Un **reactor por núcleo físico**, *pinned* a su CPU, dueño exclusivo de su anillo *io_uring*, su *allocator* y su subconjunto de particiones. **No hay estado mutable compartido** entre reactores: se comunican por **paso de mensajes** (colas SPSC *cross-core*). Elimina la clase de bug más cara —las carreras sobre estado compartido—. Ver [ADR-0005](#) y el diagrama [05 — topología thread-per-core](#).
- **Raft por partición**. Cada partición es su propio **grupo Raft**: su log replicado es el log de la partición (el WAL). El *high-watermark* es el `commitIndex` de Raft, y el modelo de `acks ( 0 / 1 / quorum )` se asienta sobre su *commit*. Postura **CP** (consistencia sobre disponibilidad; PACELC PC/EC). Ver [ADR-0003](#) y [ADR-0007](#).
- **I/O por completions (proactor)**. Abstracción común a *io_uring* en Linux —usado **directamente sobre el uapi del kernel**, sin `liburing` ([ADR-0012](#))— e **IOCP** en Windows. Sobre el proactor se asientan las **corutinas de C++23**. Ver [ADR-0002](#) y el diagrama [07 — secuencia proactor](#).
- **Protocolo binario propio** (framing + *multiplexing* por *correlation ID* + versionado) con **gateway REST** para administración y un **subconjunto Kafka-compatible** ya implementado (interop con `kcat`). Ver [ADR-0004](#) y [ADR-0029](#).

- **Capa de *ingress* en dos modos:** cliente nativo directo al líder (primario) + proxy/REST (*opt-in*). Ver [ADR-0006](#).

La solución son **15 librerías** `nexus-*` (`common`, `io`, `wire`, `protocol`, `storage`, `reactor`, `consensus`, `cluster`, `broker`, `kafka`, `ingress`, `telemetry`, `server`, `client`, `ffi`) más los ejecutables (`nexusd` , `nexus-cli` , `nexus-bench` , `nexus-loadgen`) y herramientas de soporte. La vista de conjunto está en el diagrama [02 — contenedores C4](#) y el grafo de dependencias en [03 — grafo de dependencias](#).

Estado

NexusMQ está construido **por fases**, cada una autocontenida y demoable. Las **fases 1 a 4 están implementadas**:

Fase	Nombre	Entregable
1	Storage engine	Motor de log monopartición con cifras de rendimiento. I/O bloqueante, sin reactor.
1b	Reactor + broker monolítico	Broker de un nodo <i>thread-per-core</i> : publicar y consumir con cliente nativo.
2	Distribución	Cluster tolerante a fallos (Raft por partición, <i>failover</i>).
3	Ingress + operación	Plataforma operable y observable (TLS, REST admin, CLI, métricas Prometheus).
4	<i>Stretch</i>	Productor idempotente, DLQ, compactación, LZ4/Zstd, <i>direct I/O</i> , subconjunto Kafka, IOCP (Windows).

El objetivo primario es **Linux x86-64**; el árbol completo compila y pasa la suite con GCC/libstdc++ y Clang/libc++, y el port a **Windows** está **verificado en runtime con MSVC** (ADR-0023/0028). El mapa fase→targets está en el diagrama [04 — mapa fase-targets](#).

Dónde están las cifras

Este documento **no fabrica números de rendimiento**. La metodología de medición —percentiles p50/p99/p999, generación de carga *open-loop* para evitar *coordinated omission*— y todos los resultados reproducibles viven en el contrato as-built `benchmarks.md` , explicado en el capítulo [Rendimiento y benchmarks](#).

2. Contexto y motivación

El problema que NexusMQ aborda, por qué se construye, qué objetivos persigue y —tan importante como lo anterior— qué queda explícitamente fuera de alcance.

2.1 El problema: la mensajería como columna vertebral

Los sistemas distribuidos modernos se construyen, cada vez más, alrededor de una **columna vertebral de mensajería asíncrona**. En lugar de que los servicios se llamen entre sí de forma síncrona y acoplada, **publican** y **consumen** eventos a través de un *broker* que los desacopla en el tiempo y en el espacio. Apache Kafka popularizó el modelo del **log distribuido append-only particionado** como sustrato común para *event streaming*, *event sourcing*, integración de datos y comunicación entre microservicios.

El modelo de log particionado resuelve varios problemas a la vez:

- **Desacoplo temporal** — productor y consumidor no necesitan estar vivos a la vez.
- **Re-lectura (*replay*)** — varios consumidores independientes pueden leer el mismo flujo, y rebobinar a un *offset* histórico.
- **Escalado horizontal** — por particiones, cada una unidad de paralelismo y de replicación.

Construir un broker de esta clase **desde cero** obliga a enfrentarse, sin atajos, a los problemas centrales de la ingeniería de sistemas: **durabilidad** ante fallos, **consenso y replicación**, **control de concurrencia** de alto rendimiento, **gestión explícita de memoria**, **I/O asíncrona** eficiente y **diseño de protocolos** de red. Es, por tanto, un vehículo idóneo para demostrar dominio de C++ moderno y de los fundamentos de los sistemas distribuidos.

2.2 Objetivos de aprendizaje y portfolio

NexusMQ es, ante todo, un **proyecto de aprendizaje y de portfolio**. No busca competir con Kafka en producción, sino **demostrar**, en una base de código propia y comprensible, las técnicas que hacen viable un sistema así.

La propuesta de valor del proyecto se sostiene en cuatro diferenciadores:

- **Arquitectura *shared-nothing thread-per-core* con reactor propio**. No hay *thread-pool* con estado compartido bajo *locks*: cada núcleo es un reactor independiente (su *event loop* *io_uring*, su *allocator*, su subconjunto de particiones) y se comunican por **paso de mensajes** explícito. Es la frontera actual del diseño de brokers, no la de hace más de una década (ver [estado del arte](#)).
- **Capa de *ingress* integrada** —no como pieza externa (HAProxy/Nginx) sino como parte del producto— y con **dos modos** explícitos (cliente nativo directo al líder + proxy/REST), demostrando criterio en vez de "un *ingress* que lo hace todo".
- **C++ de alto rendimiento con criterio**. Cada técnica avanzada (*lock-free*, SIMD, *allocators* por núcleo, *io_uring*) se introduce **donde un *profiling* lo justifica** y se acompaña de su *benchmark* antes/después, con metodología *anti-coordinated-omission*.
- **Portabilidad por diseño**. Linux primero, con una abstracción de I/O (*proactor*) preparada para un backend Windows (IOCP) que más tarde se completó y verificó en runtime.

El proyecto busca evidenciar **profundidad técnica en un sistema coherente** (correctitud distribuida + latencia + funcionamiento *end-to-end*) y **criterio** (decisiones justificadas y medidas), por encima de la mera acumulación de funcionalidades. La ambición se persigue como **profundidad dentro de una sola tesis arquitectónica**, nunca como amplitud: dos arquitecturas en paralelo sería *scope sprawl*, no ambición.

Casos de uso objetivo

El diseño se valida contra cuatro patrones de uso representativos:

- **Streaming de eventos** entre microservicios (publicación/suscripción durable).
- **Cola de trabajo** con grupos de consumidores y reparto de carga.
- **Event sourcing / auditoría** — log inmutable re-leíble desde cualquier *offset*.
- **Buffer de absorción de picos** (*backpressure*) entre sistemas de ritmos distintos.

2.3 Objetivos específicos (OE-1..OE-7)

El objetivo general es diseñar e implementar, por fases, un broker de mensajería distribuido de alto rendimiento en C++23, con arquitectura *shared-nothing thread-per-core*, persistencia durable, replicación con consenso (Raft por partición) y una capa de *ingress* inteligente, acompañado de herramientas de operación y observabilidad. Se desglosa en siete objetivos específicos:

- **OE-1.** Construir un *storage engine* de log *append-only* con segmentación, índice disperso, *checksums* (CRC32C) y política de durabilidad configurable.
- **OE-2.** Definir e implementar un **protocolo binario propio** con *framing*, *multiplexing* y versionado, una librería cliente nativa en C++ y un **gateway REST** para interoperabilidad.
- **OE-3.** Implementar el núcleo del broker sobre un **reactor thread-per-core propio**: *topics*, particiones (cada una anclada a un núcleo), grupos de consumidores y semánticas de entrega.
- **OE-4.** Dotar al sistema de **replicación con consenso mediante Raft por partición** (elección de líder y *failover* automático) para tolerancia a fallos.
- **OE-5.** Construir la **capa de ingress** en dos modos (cliente nativo directo al líder + proxy/ REST), con terminación TLS, *rate limiting*, *circuit breaker*, *health checks* y *load balancing*.
- **OE-6.** Proporcionar **observabilidad** de grado producción (métricas Prometheus, logs estructurados, *tracing*) y herramientas de administración (API REST + CLI).
- **OE-7.** Demostrar, con **benchmarks reproducibles y metodológicamente rigurosos**, el impacto de las técnicas de alto rendimiento aplicadas (throughput y latencia con percentiles, sin *coordinated omission*).

2.4 Alcance funcional

El sistema se organiza en seis bloques funcionales:

1. **Ingress Layer** — proxy/gateway en dos modos: TLS 1.3, *rate limiting* (*token bucket*), *circuit breaker*, *health checks*, *load balancing*, *retry* con *backoff* + *jitter*, y gateway REST.
2. **Core Broker** — *topics*, particiones (ancladas a núcleo), grupos de consumidores, gestión de *offsets*, semánticas de entrega, DLQ, TTL, *batching*/compresión, *backpressure* por créditos.
3. **Consenso y replicación** — Raft por partición: elección de líder, replicación de log, *failover* automático, *high-watermark* derivado del `commitIndex` de Raft.
4. **Protocolo de red** — *framing*, *multiplexing*, versionado; librería cliente C++ nativa + gateway REST.
5. **Storage engine** — WAL, segmentos, índice disperso, *mmap*/io_uring, retención y compactación.

Requisitos funcionales (selección)

- **RF-01.** Un productor publica mensajes en un *topic*/partición y recibe confirmación con el *offset* asignado y la política de *ack* solicitada.
- **RF-02.** Un consumidor lee desde un *offset* arbitrario y avanza (*commit* manual y automático).
- **RF-03.** Los mensajes persisten de forma durable y sobreviven a un reinicio del broker.
- **RF-04.** Los grupos de consumidores reparten particiones entre miembros con rebalanceo.
- **RF-05.** El sistema replica cada partición (grupo Raft) y elige un nuevo líder automáticamente ante la caída del actual, **sin pérdida de datos committed**.
- **RF-06.** La capa de *ingress* aplica *rate limiting* y *circuit breaking* por cliente/*topic*, y ofrece un gateway REST.
- **RF-07.** Operación vía API REST y CLI; métricas expuestas en formato Prometheus.

Requisitos no funcionales (cualitativos)

Las cifras objetivo (throughput, latencias por percentil, retención) son orientativas y se fijan con la metodología del capítulo [Rendimiento y benchmarks](#); las cifras reales viven en [benchmarks.md](#). Los requisitos cualitativos son:

- **Durabilidad / ACK.** Modelo de *ack* configurable por petición: `acks=0` (sin esperar, *at-most-once*), `acks=1` (escrito en el líder) y `acks=quorum` (replicado y *committed* por la mayoría del grupo Raft; **por defecto**). Ningún mensaje confirmado con `acks=quorum` se pierde mientras sobreviva la mayoría del grupo. La política de `fsync` (cada N mensajes / N ms / por *commit*) es ortogonal y combinable.
- **Consistencia / Disponibilidad.** Postura **CP** ([ADR-0007](#)): ante partición de red, una partición sin quórum **deja de aceptar escrituras** antes que arriesgar divergencia. *Failover* automático sin pérdida de datos *committed* por el quórum.
- **Seguridad.** TLS 1.3 en el borde (terminación en *ingress*) y opción de mTLS intra-cluster; autenticación de cliente y autorización básica por *topic*.
- **Observabilidad.** Métricas, logs estructurados y *tracing* con *correlation IDs*.
- **Portabilidad.** Núcleo independiente de plataforma tras la abstracción de I/O (*proactor*); Linux primero, Windows después.
- **Mantenibilidad.** Separación estricta plano de datos / plano de control; cobertura de pruebas en la lógica de dominio.

2.5 Fuera de alcance (explícito)

Para acotar el proyecto y evitar la dispersión —el riesgo número uno de un proyecto "infinito"—, **quedan fuera** de forma deliberada:

- **Compatibilidad total con el protocolo de Kafka.** Se aborda solo un **subconjunto** (`ApiVersions` / `Metadata` / `Produce` / `Fetch`) como *stretch* de Fase 4, suficiente para que `kcat` hable con el broker; sin grupos de consumidores Kafka (`JoinGroup` / `Heartbeat`) ni transacciones. Ver [ADR-0004](#) y [ADR-0029](#).
- **Exactly-once transaccional entre particiones.** Sí se contempla **productor idempotente** (*effectively-once* por partición).
- **Tiered storage** a almacenamiento de objetos (idea futura, inspirada en Pulsar).

- **Multi-tenancy y ACLs avanzadas.** (El **cifrado en reposo** del log **sí** está implementado — AES-256-GCM opcional, [ADR-0031](#); lo que queda fuera es la rotación de la clave maestra.)
- **Dashboard gráfico propio.** La observabilidad se expone vía Prometheus/CLI; un panel Grafana es opcional y *self-hosted*.
- **Despliegue de pago en cloud.** El proyecto se **orienta** a Azure/AWS por diseño (imagen Docker, configuración 12-factor), pero su desarrollo, prueba y *benchmark* **no requieren** gasto en cloud: el cluster de 3 nodos se levanta en local con Docker Compose. Ver [ADR-0008](#).

El detalle de las limitaciones aceptadas y la evolución posible se trata en el capítulo [Limitaciones y trabajo futuro](#).

3. Estado del arte

Dónde se sitúa NexusMQ en el mapa de los *brokers* de mensajería: qué hereda del modelo clásico de log particionado y por qué adopta la **frontera actual** (*thread-per-core* + Raft por partición) en lugar del diseño de hace más de una década.

3.1 El modelo de log particionado

Apache Kafka popularizó el **log distribuido append-only particionado** como sustrato común de *event streaming*, *event sourcing*, integración de datos y comunicación entre microservicios. Ese modelo —*topics* divididos en **particiones**, cada una un log inmutable de registros identificados por **offset** monótono, con consumidores que leen desde el offset que eligen— es la base que NexusMQ **hereda** (ver el [capítulo 9, Almacenamiento](#)). De Kafka se toman también el **high-watermark**, los **grupos de consumidores**, la **retención** y el **formato de record batch v2**.

3.2 Dos generaciones de arquitectura

La diferencia entre NexusMQ y un Kafka clásico no está en *qué* es (un log particionado), sino en *cómo* se ejecuta por dentro:

Dimensión	Kafka clásico (≈2011)	Frontera actual (Redpanda)	NexusMQ
Concurrencia	<i>thread-pool</i> + estado compartido bajo <i>locks</i>	<i>shared-nothing thread-per-core</i>	<i>thread-per-core</i> (reactor propio)
Replicación	ISR + <i>controller</i> (consenso solo para metadatos)	Raft por partición	Raft por partición
I/O	JVM + <i>page cache</i> del SO	<i>io_uring</i> (Seastar)	proactor <i>io_uring</i> /IOCP + corutinas C++23
Lenguaje	Scala/Java (JVM, GC)	C++ (Seastar)	C++23 (reactor mínimo propio)

El salto de generación es deliberado: NexusMQ no se posiciona en la frontera de 2011 (*thread-pool* + ISR clásico), sino en la **frontera actual**, la que usa **Redpanda** para batir a Kafka en latencia. Es el diseño más ambicioso, el más coherente con el objetivo de *correctitud demostrable* y el que mejor compone consigo mismo: un grupo Raft anclado a un núcleo, un anillo *io_uring* por núcleo, sin estado mutable compartido.

3.3 Análisis de referentes

Sistema	Lenguaje	Modelo	Qué se toma como referencia
Apache Kafka	Scala/Java	Log particionado + ISR; KRaft para metadatos	Modelo de log, particiones, grupos de consumidores, <i>high-watermark</i> , retención, <i>record batch</i> .
Redpanda	C++ (Seastar)	Kafka-compatible; Raft por partición ; <i>thread-per-core</i> / <i>shared-nothing</i>	Validación directa del diseño adoptado: un broker <i>thread-per-core</i> + Raft por partición es viable y <i>state-of-the-art</i> en C++.
RabbitMQ	Erlang	Colas AMQP, <i>routing</i> por <i>exchange</i>	Semánticas de entrega, <i>dead letter queues</i> , ACK/NACK.
NATS / JetStream	Go	Mensajería ligera + <i>streams</i> durables	Simplicidad del protocolo, baja latencia, <i>at-least-once</i> .
Apache Pulsar	Java	<i>Compute/storage</i> separados (BookKeeper)	Separación de capas, <i>tiered storage</i> (idea para <i>stretch</i>).

3.4 Posicionamiento de NexusMQ

- **Redpanda como validación de diseño, no como dependencia.** Redpanda demuestra que la arquitectura *thread-per-core* + Raft por partición es construible en C++ con rendimiento de primera línea. NexusMQ construye su **propio reactor mínimo** sobre *io_uring* + corutinas; **no usa Seastar** (dependencia pesada, *Linux-only*): "construir" demuestra más que "usar" y encaja con la política de hacer el núcleo a mano (ver [ADR-0005](#)).
- **No compite con Kafka en producción.** El objetivo es **demostrar**, en una base de código propia y comprensible, las técnicas que hacen viable un sistema así —profundidad técnica y criterio—, no acumular funcionalidades ni superar a Kafka en *features*.
- **Compatibilidad Kafka como subconjunto recuperable.** En vez de atarse a la especificación completa de Kafka, se implementa un **subconjunto** Kafka-compatible como *stretch* de Fase 4 (interop con `kcat`), preservando el control del protocolo binario propio (ver [ADR-0004](#) y el [capítulo 14](#)).

4. Glosario

Define los términos de dominio que el resto de la documentación usa sin más aclaración. Identificadores y términos técnicos asentados van en inglés (es la convención del ecosistema); la definición, en español.

Modelo de log y mensajería

- **Topic.** Flujo lógico de mensajes, dividido en una o más **particiones**.
- **Partición.** Unidad de paralelismo y de replicación: un **log append-only** ordenado e inmutable. En NexusMQ, además, **un grupo Raft** y el dueño de un núcleo concreto.
- **Offset.** Identificador monótono de un registro dentro de una partición; da el orden (no el *timestamp*).
- **Record / RecordBatch.** Un registro es la unidad de mensaje (clave, valor, cabeceras, *timestamp*); el **RecordBatch** (formato v2, estilo Kafka) agrupa varios registros con un *checksum* y metadatos comunes. Ver [contrato](#).
- **Segmento.** Tramo físico del log en disco: un fichero `.log` (registros) + un `.index` (índice disperso offset→posición). El log de una partición es una secuencia de segmentos.
- **Índice disperso.** Índice que mapea algunos offsets a posiciones de fichero (no todos), para acotar su tamaño; la búsqueda fina se completa con un escaneo corto.
- **WAL (Write-Ahead Log).** Log de escritura previa que garantiza durabilidad. En NexusMQ el **log de Raft es el WAL** de la partición.
- **High-watermark (HWM).** Offset hasta el cual los datos están *committed* (replicados por el quórum) y, por tanto, visibles a los consumidores. Se deriva del `commitIndex` de Raft.
- **acks.** Política de confirmación de una escritura: `acks=0` (sin esperar, *at-most-once*), `acks=1` (escrito en el líder), `acks=quorum` (replicado y *committed* por la mayoría del grupo Raft; valor por defecto).
- **Grupo de consumidores.** Conjunto de consumidores que se reparten las particiones de un *topic* con **rebalanceo**, para escalar el consumo.
- **DLQ (Dead Letter Queue).** Destino de los mensajes no procesables tras N intentos.
- **Productor idempotente.** Productor con *producer-id* + *sequence* que evita duplicados por reintento (*effectively-once* por partición).
- **Retención / compactación.** Borrado de datos antiguos por tiempo/tamaño (retención) o conservación del último valor por clave (compactación).

Consenso y distribución

- **Raft.** Algoritmo de consenso (Ongaro & Ousterhout) para replicar un log de forma tolerante a fallos con un líder elegido por mayoría.
- **commitIndex.** Índice del log de Raft hasta el cual las entradas están *committed*.
- **Quórum.** Mayoría de un grupo Raft ($\lfloor n/2 \rfloor + 1$), necesaria para *commit* y para elegir líder.
- **Leader epoch.** Número que identifica el mandato de un líder; detecta y descarta líderes obsoletos.
- **Snapshot (Raft).** Imagen/base compactada del estado que permite truncar el prefijo del log replicado y acotar su tamaño (ver [ADR-0024](#)).

- **PACELC.** Marco que extiende CAP: ante **P**artición se elige **A** o **C**; en operación normal (**E**lse), **L**atencia o **C**onsistencia. NexusMQ es **PC/EC**.
- **Failover.** Sustitución automática de un líder caído por un nuevo líder elegido.

Concurrencia, memoria y sistemas

- **Shared-nothing.** Diseño sin estado mutable compartido entre unidades de ejecución; se comunican por **paso de mensajes**.
- **Thread-per-core.** Un hilo (reactor) por núcleo físico, *pinned* a su CPU.
- **Reactor / Proactor.** Modelos de I/O asíncrona: *reactor* basado en *readiness* (epoll); *proactor* basado en *completions* (io_uring/IOCP). NexusMQ usa **proactor**.
- **io_uring / IOCP.** Interfaces de I/O por *completions* de Linux y Windows. NexusMQ usa io_uring **directo sobre el uapi del kernel**, sin liburing ([ADR-0012](#)).
- **Cross-core message passing.** Comunicación entre reactores por colas **SPSC** con despertar del destino (estilo `submit_to`).
- **SPSC.** *Single-producer single-consumer*: cola con un único productor y un único consumidor (caso simple y rápido).
- **Backpressure (por créditos).** Control de flujo en el que el receptor concede *créditos*; sin créditos, el emisor se frena (colas acotadas).
- **Afinidad (pinning).** Fijar un hilo a un núcleo concreto para localidad de caché y NUMA.
- **NUMA.** *Non-Uniform Memory Access*: la memoria local al nodo del núcleo es más rápida.
- **False sharing.** Degradación por compartir una línea de caché entre hilos que escriben; se mitiga con `alignas(std::hardware_destructive_interference_size)`.
- **CRC32C.** Variante de CRC de 32 bits con instrucción hardware (SSE4.2), usada como *checksum*.
- **Direct I/O.** I/O que evita el *page cache* del SO (`O_DIRECT`), gestionando caché/alineación propias.
- **Reloj monotónico.** Reloj que nunca retrocede; se usa para *timeouts*/heartbeats/elección Raft (nunca el *wall-clock*).

Modelo de errores y observabilidad

- `expected<T>`. `std::expected<T, Error>` (C++23): resultado-o-error como valor, usado en el núcleo/hot-path ([ADR-0009](#)).
- **errorCode (wire).** Código de error numérico (`int16`) del protocolo; es **contrato**, se traduce al modelo interno en el borde.
- **RFC 7807 (ProblemDetail).** Formato estándar de error para la API REST de administración.
- **Liveness / Readiness.** Estar vivo (el proceso responde) vs estar listo para tráfico (*checks* de disco/Raft/*lag*).
- **Coordinated omission.** Sesgo de medición de latencia de los clientes *closed-loop*; se evita con un generador *open-loop* (ver [capítulo 23](#)).

Otros patrones

- **Circuit breaker.** Patrón que "abre" el circuito ante fallos para no insistir contra un destino caído.
- **Token bucket.** Algoritmo de *rate limiting* basado en una cubeta de *tokens* que se rellena a tasa fija.
- **Decompression bomb.** *Batch* comprimido que se expande desmesuradamente al descomprimir; se mitiga con límites de ratio/tamaño.

5. Vista de conjunto

El sistema a vista de pájaro: cómo se descompone NexusMQ en librerías, cómo fluyen sus dependencias y cómo se mapea al modelo C4. Es el mapa que sitúa los capítulos siguientes.

5.1 Un nodo, N reactores

Cada **nodo** del broker es un proceso (imagen Docker) que ejecuta **N reactores** (uno por núcleo físico, *pinned*) y mantiene un subconjunto de **réplicas de partición** —líder de unas, seguidor de otras—, donde **cada partición es su propio grupo Raft**. El cluster de referencia son **3 nodos** (tolera la caída de uno con quórum de 2). En desarrollo, los 3 nodos se levantan con Docker Compose en una sola máquina (ver [capítulo 25](#)). El contexto y los contenedores se ilustran en los diagramas [1](#) y [2](#).

5.2 Las 15 librerías `nexus-*`

La solución es un único árbol CMake con **15 librerías** `nexus-*`, más ejecutables y herramientas. Por capas (de la base hacia arriba):

Capa	Librerías	Responsabilidad
Base	<code>nexus-common</code>	Tipos, <code>bytes</code> , <code>varint</code> , <code>crc32c</code> , <code>record</code> , <code>error</code> , <code>task</code> (corutinas), compresión.
Plataforma	<code>nexus-io</code> , <code>nexus-wire</code>	Proactor (<code>io_uring</code> /IOCP), <code>File</code> / <code>Socket</code> ; framing sobre conexión.
Dominio E/S	<code>nexus-protocol</code> , <code>nexus-storage</code>	Protocolo binario (codec, frames, versionado); motor de log (segmentos, índice).
Ejecución	<code>nexus-reactor</code>	Reactor por núcleo, colas SPSC cross-core, <code>PartitionRouter</code> .
Consenso	<code>nexus-consensus</code> , <code>nexus-cluster</code>	Raft (FSM, log, RPC); transporte inter-nodo.
Broker	<code>nexus-broker</code> , <code>nexus-kafka</code>	Topics, particiones, grupos, offsets; subset Kafka.
Bordes	<code>nexus-ingress</code> , <code>nexus-telemetry</code>	Dos modos de ingress, TLS, REST admin; métricas/logs.
Cima	<code>nexus-server</code> , <code>nexus-client</code> , <code>nexus-ffi</code>	Composición de <code>nexusrd</code> ; cliente nativo; ABI C para bindings.

Ejecutables y *tools*: `nexusrd` (el servidor, `src/server/main.cpp`), `nexus-cli`, `nexus-bench`, `nexus-loadgen` y `wincheck` (arnés Windows-only). El detalle por subsistema está en el [capítulo 18](#).

5.3 Regla de dependencia

Las dependencias **apuntan hacia el núcleo**: una librería nunca depende de otra de su misma capa o superior. `nexus-common` no depende de nada interno; `nexus-server` está arriba y compone casi todo. Esta disciplina (clean architecture aplicada a sistemas) mantiene el núcleo —storage, broker, consenso—

independiente del detalle de I/O y de protocolo, que entran por *puertos* y *adaptadores* (DIP). El grafo completo está en el [diagrama 3](#) y se detalla en el [capítulo 17](#).

5.4 Modelo C4 (resumen)

- **Contexto:** productores y consumidores ↔ NexusMQ ↔ operadores (CLI/REST) y Prometheus; otros nodos del cluster por el plano Raft.
- **Contenedores:** ingress (dos modos), nodos de broker (N reactores *per-core* c/u), almacén en disco, plano de administración.
- **Componentes (por reactor):** *event loop* del proactor → *handlers* de protocolo (corutinas) → broker (particiones del núcleo) → storage engine → módulo Raft de esas particiones; colas SPSC *cross-core* hacia otros reactores.

5.5 Planos del sistema

NexusMQ separa explícitamente tres planos, lo que se refleja en su despliegue y en sus puertos (ver [diagrama 15](#)):

- **Plano de datos / cliente:** *produce/fetch* por el protocolo binario (o subset Kafka) contra el líder de cada partición. Es el camino caliente.
- **Plano de consenso / inter-nodo:** los RPC de Raft (*AppendEntries* / *RequestVote*) entre réplicas, por un puerto separado.
- **Plano de control / administración:** API REST (`/api/v1`), salud y métricas.

La separación plano de datos/plano de control es un principio rector: el camino caliente se mantiene libre de lógica de administración (ver [capítulo 6](#)).

6. Principios de diseño

Los principios que vertebran NexusMQ y que explican por qué el código está como está. Especializan al dominio de sistemas los principios generales (SOLID, clean architecture) sin duplicarlos.

6.1 Principios rectores

- **Separación plano de datos / plano de control.** El camino caliente (*produce/fetch*) se mantiene libre de lógica de administración; la gestión (crear *topics*, rebalanceos) vive en un plano aparte (REST admin).
- **Shared-nothing.** El estado mutable es **propiedad de un único reactor**; nada se comparte entre núcleos salvo por paso de mensajes. Es el principio que hace el sistema razonable y testeable (ver [capítulo 7](#)).
- **Hexagonal aplicada a sistemas.** El núcleo (storage, broker, consenso) no depende del detalle de I/O ni de protocolo: estos entran por **puertos** (interfaces) y **adaptadores** (p. ej. `io_uring` vs IOCP es un adaptador del puerto de I/O). Materializa **DIP** y permite romper ciclos de capas ([ADR-0017](#), [ADR-0018](#)).
- **Mecanismo vs política.** El storage ofrece *mecanismo* (append, read, fsync); la *política* (retención, durabilidad, `acks`) es configurable y externa.

6.2 Las decisiones de arquitectura, en una frase cada una

Los principios anteriores se concretan en decisiones registradas como ADR (ver [capítulo 28](#)). Las que más condicionan el diseño:

- **Concurrencia *shared-nothing thread-per-core*** con reactor propio ([ADR-0005](#)): elimina la clase de bug más cara (carreras sobre estado compartido) y los *locks* del camino caliente.
- **Raft por partición** ([ADR-0003](#)): un único mecanismo de ordenación, replicación y elección por partición; el log de Raft es el WAL; el *high-watermark* es el `commitIndex`.
- **Proactor / completions** ([ADR-0002](#), [ADR-0012](#)): I/O modelada como *completions* (`io_uring`/IOCP), base portable sobre la que se asientan las corutinas C++23.
- **Postura CP / PACELC PC-EC** ([ADR-0007](#)): ante partición se elige consistencia; en operación normal también consistencia sobre latencia.
- **Modelo de errores por capa** ([ADR-0009](#)): `expected<T>` en el núcleo, excepciones en el plano de control, códigos de wire en el protocolo (ver [capítulo 16](#)).

6.3 Patrones arquitectónicos y de almacenamiento

- **Reactor/Proactor** (I/O por *completions*, un reactor por núcleo).
- **Leader-Follower vía Raft**: cada partición tiene un líder que ordena las escrituras y *followers* que replican.
- **Pipeline**: recepción → decodificación → *append* → replicación → *ack*, como etapas conectadas por colas.
- **WAL + log-structured storage**: escritura secuencial append-only; **el log de Raft es el WAL**.
Segmentación + índice disperso para *seek* y retención por segmentos enteros; **compactación por clave** como política alternativa.

6.4 Patrones distribuidos y de resiliencia

- **Consenso (Raft) por partición**, con extensiones contempladas: *pre-vote*, *leadership transfer* y réplicas *learner*.
- **Productor idempotente** (*producer-id + sequence*) para *effectively-once* por partición; **DLQ** para mensajes no procesables.
- **Resiliencia del ingreso**: *Circuit Breaker* (closed/open/half-open), *Bulkhead*, *retry* con *backoff + jitter*, *rate limiting* (token bucket), **backpressure por créditos** (colas acotadas *end-to-end*; sin créditos, el productor se frena, no se descarta).

6.5 Disciplina de C++ y calidad

Transversal a todo el código: **RAII estricto** (sin `new` / `delete` crudos; recursos del SO envueltos en tipos), semántica de valor, `const` -correcto, `enum class`; corutinas que **nunca bloquean** el reactor; y una **puerta de calidad** (dos compiladores, sanitizers, `clang-tidy`, `clang-format`) obligatoria antes de cada *commit* (ver [capítulo 22](#)). El detalle de convenciones lo fija la `BibliotecaDocumentacion`, autoridad de estilo del proyecto.

7. Concurrency

El modelo de ejecución de NexusMQ: por qué no hay *locks* en el camino caliente y cómo se reparte el trabajo entre núcleos sin estado compartido. Decisiones de fondo: [ADR-0005](#) y [ADR-0026](#).

7.1 Un reactor por núcleo

NexusMQ ejecuta **un reactor por núcleo físico**, cada uno *pinned* a su CPU. Un reactor es dueño **exclusivo** de: su **anillo io_uring** (o IOCP en Windows), su **allocator** (arena/pool local, NUMA-aware) y un **subconjunto de réplicas de partición**. **No hay estado mutable compartido entre reactores**. Esto elimina la clase de bug más cara —las carreras sobre estado compartido— y, con ella, los *locks* del camino caliente: cada partición es una **unidad de serialización** (estilo *actor*) anclada a un núcleo. La topología se ilustra en el [diagrama 5](#).

7.2 Sharding: qué núcleo es dueño de qué

El reparto de carga no se hace por *work-stealing* sobre una cola compartida, sino por **asignación de particiones a núcleos** ([ADR-0026](#)):

- **Partición → núcleo:** `partition % N` (N = número de reactores). El reactor resultante es el **único dueño** de esa réplica.
- **Grupo de consumidores → núcleo:** `hash(group_id) % N` (FNV-1a), para que la coordinación de cada grupo viva siempre en el mismo reactor.

Como cada *shard* tiene **un único dueño**, las operaciones sobre él son **linealizables sin locks**: las sirve el reactor propietario, en orden, sin sincronización. Ver el [diagrama 6](#).

7.3 Paso de mensajes cross-core

Cuando una petición llega al núcleo A pero su partición vive en B, **no** se accede a estado de B: la petición se **reenvía** a B por una cola **SPSC** (*single-producer single-consumer*), con despertar del destino (estilo `submit_to` de Seastar). El resultado vuelve por el mismo mecanismo. SPSC es el caso simple y rápido (un *ring buffer* basta); el diseño minimiza productores/consumidores por cola precisamente para evitar la complejidad (CAS, ABA) de las colas MPMC.

- **Lock-free solo con motivo y medición.** Donde hay colas, se usa CAS con el `memory_order` mínimo correcto (`acquire / release` en productor-consumidor); en las MPMC se resuelve el problema **ABA** (contadores de versión / *hazard pointers* / *epoch-based reclamation*) y se valida con **ThreadSanitizer + estrés aleatorio** en CI.
- **False sharing.** Los campos escritos por hilos distintos (p. ej. *head/tail* de cada cola) se separan a líneas de caché distintas con `alignas(std::hardware_destructive_interference_size)`.

7.4 Backpressure por créditos

Las colas son **acotadas end-to-end**. El receptor concede **créditos** al emisor; cuando se agotan, el emisor se **frena** en lugar de descartar mensajes o dejar crecer los *buffers* sin límite. Esto evita el colapso bajo sobrecarga y mantiene las latencias de cola acotadas (`ConnectionState.credits` , ver [capítulo 8](#)).

7.5 Nada bloqueante en el reactor

La contrapartida del modelo es **disciplina asíncrona total**: un `fsync` síncrono, un `malloc` que entre al kernel o un *lock* contendido **congelan el núcleo entero** y con él todas las tareas que multiplexa. Por eso **todo** I/O (incluido `fsync`) pasa por el proactor y se usan *allocators* por núcleo para no entrar al kernel en el camino caliente. Las corutinas del reactor nunca hacen `co_await` sobre operaciones bloqueantes (ver [capítulo 8](#)).

7.6 Reloj para la concurrencia distribuida

Todo lo que mide **intervalos** y no puede retroceder —*timeouts*, *heartbeats* y el *election timeout* de Raft, *backoff*— usa el **reloj monotónico** (`steady_clock`), nunca el *wall-clock*: un salto de NTP hacia atrás dispararía elecciones espurias. El *wall-clock* se reserva para *timestamps* de `Record` y retención por tiempo. El orden dentro de una partición lo da el **offset**, no la marca de tiempo.

8. Modelo de I/O

Cómo NexusMQ habla con disco y red sin bloquear nunca un núcleo. El plano de datos es, en esencia, **I/O de red y disco a gran escala**; el modelo elegido es un **proactor** (*completions*) sobre el que se asientan las corutinas C++23.

8.1 Proactor, no reactor

Se adopta una abstracción de **proactor** (modelo de *completions*: se envía una operación asíncrona y se recibe su finalización con el resultado), no un *reactor* *epoll* (*readiness*). El motivo es la **portabilidad**: *completions* es la forma común a los dos backends objetivo, **io_uring** (Linux) e **IOCP** (Windows) ([ADR-0002](#)). El puerto `Proactor` y los tipos portables `NativeHandle` / `IoResult` viven en `nexus-io`; los backends concretos son adaptadores (`io_uring_backend`, `iocp_backend`). La secuencia *submit* → *completion* → *reanudar corutina* está en el [diagrama 7](#).

8.2 io_uring directo, sin liburing

En Linux, el backend usa **io_uring directamente sobre el uapi del kernel, sin liburing** ([ADR-0012](#)): el proyecto gestiona sus propios anillos de *submission/completion*. Bajo *thread-per-core* hay **un anillo por núcleo**, sin compartición entre reactores, lo que encaja con el modelo *shared-nothing* y amortiza *syscalls* por *batching* (coherente con "no una *syscall* por byte"). En Windows, el backend IOCP se construye sobre `GetQueuedCompletionStatusEx` / `AcceptEx` y está verificado en runtime con MSVC (ver [capítulo 24](#)).

8.3 Corutinas sobre el proactor

Las **corutinas de C++23** se asientan de forma natural sobre el proactor: un `co_await` de una operación de I/O suspende la corutina y la reanuda en su *completion*, con el resultado. El código del camino caliente queda **secuencial y legible** sobre I/O por *completions*. Las operaciones del núcleo devuelven `task<expected<T>>`: combinan la asincronía (`task`) con el modelo de errores como valor (`expected`, ver [capítulo 16](#)). Hay que cuidar el *lifetime* de los argumentos a través de la suspensión: una corutina puede reanudarse en otro momento, así que no se hace `co_await` sobre temporales colgantes.

8.4 Nada bloqueante en el reactor

La regla de oro: **un solo `fsync`, `malloc` que entre al kernel o *lock* contendido congela el núcleo entero**. Por eso:

- **Todo** I/O de disco —incluido `fsync` / `fdatasync` — pasa por `io_uring` asíncrono (`IORING_OP_FSYNC`), no por llamadas bloqueantes.
- Se usan **allocators por núcleo** (*arena/pool*) para no entrar al kernel a pedir memoria en el camino caliente.
- El control de flujo es por **créditos** (colas acotadas), no por *buffers* ilimitados (ver [capítulo 7](#)).

8.5 Durabilidad y checksums

- **write no persiste.** La durabilidad se fuerza con `fsync / fdatasync` ; como su coste es alto, se **agrupa** (por N mensajes / N ms / por *commit*), nunca por escritura. La política de `fsync` es configurable y ortogonal al modelo de `acks` .
- **Checksums.** Cada `RecordBatch` lleva un **CRC32C** que cubre el batch completo; al leer y al recuperar tras *crash* se verifica, detectando corrupción silenciosa (*bit rot, torn writes*) que el WAL por sí solo no ve. CRC32C usa la instrucción hardware de SSE4.2 con *fallback* software (ver [capítulo 9](#)).
- **Recuperación.** Al arrancar se valida el CRC de la cola del log y se **trunca la cola torn** (escritura a medias por un *crash*), dejando el log en un estado consistente.

8.6 Evolución escalonada de la I/O de storage

La I/O de disco se introdujo por fases (decisión deliberada de [ADR-0002](#)): la **Fase 1** arrancó con I/O de fichero **bloqueante** (`pread / pwrite + fsync`) detrás de la abstracción `File` , para validar correctitud y durabilidad antes que rendimiento; a partir de la **Fase 1b**, bajo el reactor, el disco pasó a `io_uring` asíncrono. **Direct I/O** (`O_DIRECT`) con caché y *readahead* propios quedó como **profundidad opcional** de Fase 4, solo si el *profiling* lo justifica (ver [capítulo 23](#)).

9. Almacenamiento

El *storage engine*: un log particionado append-only sobre segmentos, con índice disperso, *checksums* y retención. Es la Fase 1 del proyecto y la base sobre la que se monta Raft. El layout se ilustra en el [diagrama 8](#).

9.1 Log particionado

Cada partición es un **log append-only**: una secuencia ordenada e inmutable de registros, cada uno con un **offset** monótono. Los productores añaden al final; los consumidores leen desde el offset que elijan y avanzan a su ritmo (el broker no borra al entregar: retiene por tiempo/tamaño). Una partición es físicamente una **secuencia de segmentos**:

```
Partición 0 → [Seg 0 (closed)][Seg 1 (closed)][Seg 2 (active)]    cada Seg: .log + .index
```

`PartitionLog` reúne los segmentos, el segmento activo, `logStartOffset / logEndOffset` y el `recoveryPoint` (último `fsync`). Es **REACTOR-LOCAL**: pertenece al reactor dueño de la partición y no es *thread-safe* (su invariante es que `logEndOffset` es monótono).

9.2 Segmentos e índice disperso

Cada **segmento** (`Segment`) es un par de ficheros: `.log` (los `RecordBatch`) y `.index` (el índice disperso). El **índice disperso** mapea, cada N bytes, `relativeOffset` → posición en fichero (`IndexEntry { relativeOffset:u32, filePosition:u32 }`), lo que permite un *seek* eficiente sin recorrer todo el segmento: se localiza la entrada de índice más cercana por debajo del offset buscado y se escanea hacia delante un tramo corto.

Ciclo de vida de un segmento: `active` (recibe *appends*) → `closed` (alcanza `segment.bytes / segment.ms`; se sella y se finaliza su `.index`) → `eligible` (supera la retención) → `deleted`. La retención **nunca** borra el segmento activo.

9.3 RecordBatch v2

La unidad de escritura y replicación **no** es el registro suelto, sino el **RecordBatch** (estilo Kafka v2), que amortiza cabeceras, CRC y compresión sobre muchos registros. Sus campos (en disco, *little-endian*; *deltas* en `varint / zigzag`):

Campo	Tipo	Descripción
<code>baseOffset</code>	i64	Offset del primer registro del batch.
<code>length</code>	i32	Longitud del batch.
<code>crc32c</code>	u32	Checksum que cubre el batch completo.
<code>attrs</code>	u16	Codec de compresión (none/LZ4/Zstd), bits de txn/idempotencia.
<code>producerId</code> / <code>producerEpoch</code> / <code>baseSequence</code>	i64/i16/i32	Productor idempotente.
<code>recordCount</code>	i32	Número de registros.
<code>records[]</code>	—	Cada uno con <code>offsetDelta</code> / <code>timestampDelta</code> (varint/zigzag), <code>key</code> , <code>value</code> , <code>headers</code> .

El **offset** lógico de cada registro es `baseOffset + offsetDelta`. El formato exacto es contrato: ver [docs/protocol.md](#). La **compresión** LZ4/Zstd es opcional (se compila solo si `find_package` la encuentra) y se aplica por batch.

9.4 Durabilidad y recuperación

- **fsync agrupado** (por N mensajes / N ms / por *commit*): durabilidad real sin pagar un `fsync` por escritura (ver [capítulo 8](#)).
- **CRC32C por batch**, verificado al leer y al recuperar: detecta corrupción silenciosa.
- **Recuperación al arrancar**: se valida el CRC de la cola del log y se **trunca la cola torn** (escritura a medias por un *crash*), dejando el log consistente y listo en pocos segundos. Es la durabilidad que sostiene la garantía `acks=quorum`.

9.5 Retención y compactación

- **Retención por tiempo/tamaño** (`retention.ms` / `retention.bytes`): se borran **segmentos sellados enteros** cuando se supera el umbral (nunca registros sueltos ni el segmento activo). Ver el [diagrama 9](#).
- **Compactación por clave** (`LogCompactor`): política alternativa que conserva el último valor por clave, útil para *topics* de estado tipo *changelog*.

El storage ofrece **mecanismo** (append, read, fsync); la **política** (retención, durabilidad, compresión) es configurable y externa (`LogConfig`). Bajo Raft, este mismo log es el **WAL** de la partición y lo envuelve `RaftLog` (ver [capítulo 10](#)).

9.6 Cifrado en reposo (opcional)

El log puede persistirse **cifrado** con **AEAD AES-256-GCM**, de forma opcional y con **degradación limpia** ([ADR-0031](#), vía OpenSSL como en TLS). Si `LogConfig` no lleva clave, el `.log` se escribe **en claro**, byte a byte como hasta ahora; si la lleva, cada `RecordBatch` (unidad de escritura, §9.3) se cifra como **un bloque** independiente —nunca por registro—. El cifrado vive confinado en `segment_crypto` y en el framing de `Segment`; el resto del motor (índice, retención, recuperación, Raft) no cambia.

- **Jerarquía de claves.** La **KEK** (clave maestra de 256 bits) llega por entorno/config y jamás se persiste; deriva por **HKDF-SHA256(KEK, salt aleatoria por segmento)** una **DEK** distinta por segmento. Acotar cada clave a un segmento aísla el radio de daño y mantiene el número de cifrados por clave muy por debajo del límite de colisión de nonces.
- **Formato on-disk.** El `.log` cifrado empieza por una **cabecera de segmento** (32 bytes: `magic NXSEG1` + identificadores de KDF/cipher + `flags` + `salt`), que permite **autodetectar** cifrado vs. claro al abrir (logs mixtos admitidos). Cada bloque es `version | flags | base_offset | record_count | ct_len | nonce(12) | tag(16) | ciphertext`. Los metadatos de traversal (`base_offset / record_count / ct_len`) viajan **en claro pero autenticados** (AAD del GCM): el log se **recorre y localiza por offset sin descifrar** (el índice disperso y la lectura por offset siguen funcionando); solo las claves/valores de los registros van en el ciphertext.
- **Nonce e integridad.** Cada bloque toma un **nonce aleatorio de 96 bits** —robusto ante el ciclo truncar→re-append del WAL de Raft (§9.4, [capítulo 10](#)); la reutilización de nonce con la misma clave es la **invariante nº 1**—. El **tag GCM** autentica cada bloque: cualquier byte alterado (ciphertext o metadatos) produce un fallo **autenticado** (`Corrupt`), nunca datos corruptos silenciosos. El CRC32C del batch se conserva **dentro** del plaintext como defensa en profundidad. Configuración y operación de la KEK: ver [capítulo 26](#) y [capítulo 27](#).

9.7 Almacenamiento por niveles (opcional)

Para retención larga a bajo coste, el log puede **descargar** sus segmentos sellados fríos a un almacén de objetos barato y **rehidratarlos de forma transparente** al leerlos —el patrón *tiered storage* de Kafka/Pulsar—, de forma opcional y con **degradación limpia** ([ADR-0032](#)). Sin `--tier-dir`, el prefijo frío está siempre vacío y el comportamiento es byte-idéntico al de hoy. El diseño se ilustra en el [diagrama 24](#).

- **Puerto orientado a fichero.** El motor depende de un puerto `StorageTier` (DIP), no de una nube concreta: `put_file / fetch_file / contains / object_size / remove / list_segment_bases` sobre una **clave de objeto** determinista `TierObjectKey` (`<topic>/<partition>/<base:020>.<ext>`). Un segmento **es** un fichero, así que descargar y rehidratar son copias, sin cargar segmentos en RAM. El adaptador por defecto `LocalStorageTier` copia a un **directorio objeto** local (coste cero); un adaptador S3 futuro implementaría el mismo contrato tras `find_package`.
- **Descargar sellados, reclamar solo tras confirmar.** `offload_sealed_to_tier` sube los segmentos **sellados** (nunca el activo), del más antiguo al más nuevo, y **solo tras confirmar** la subida (atómica e idempotente) borra los ficheros locales y marca el segmento como frío. Un fallo del tier deja el segmento local y se reintenta; nunca se pierde un dato por reclamación prematura. Con un tier configurado, cada **rotación** de segmento dispara la descarga (best-effort).
- **El tier es la autoridad; sin manifiesto.** Al reabrir, el `PartitionLog` reconstruye su **prefijo frío** listando el tier (`list_segment_bases`), sin un fichero manifiesto que pudiera desincronizarse. Las bases que también existen localmente (offload confirmado pero sin reclamar por un *crash*) se descartan: el segmento local es autoritativo. La **contigüidad** del log (sin huecos) permite reconstruir el rango de cada segmento frío solo con las bases ordenadas.
- **Lectura transparente e interoperación.** `read` sirve el *suffix* caliente localmente y, para un offset del prefijo frío, **rehidrata** el segmento (baja `.log` + `.index` a un temporal, lo abre —descifrándolo si procede, §9.6— y sirve el fragmento) con limpieza **RAII**. El rango del log (`logStart / logEnd`) **no cambia** al descargar. El tier guarda el **ciphertext tal cual** (bytes opacos): la clave nunca sale del broker. Las operaciones de Raft son *tier-conscientes* —el truncado de compactación/snapshot borra del tier los segmentos que descarta, el truncado normal rechaza reescribir dentro del prefijo frío (historia

comprometida) y la retención no toca el *hot set* mientras haya prefijo frío—. Configuración: ver [capítulo 26](#).

9.8 Visibilidad transaccional (opcional)

El log soporta **transacciones multi-partición** con visibilidad atómica, de forma **opt-in** y con degradación limpia ([ADR-0033](#)). Sin usar la API transaccional, nada cambia. La coordinación (2PC recuperable) vive en el broker (ver [capítulo 10](#)); lo que toca al **almacenamiento** es cómo se marcan las transacciones en el log y cómo se acota la lectura. Se ilustra en el [diagrama 25](#).

- **Marcadores de control en el log.** El `RecordBatch` gana dos *flags* en `attrs` —**transaccional** y **control**— disjuntos de los bits de códec (§9.3). Un batch **transaccional** lleva datos de una transacción abierta; un batch de **control** no lleva datos de usuario sino un único **marcador** `EndTxnMarker` (COMMIT o ABORT, con la época del coordinador), que **cierra** la transacción en esa partición. El codec del marcador (clave/valor versionados, decodificador defensivo) vive en `common/control_record`; el marcador es un record normal del log (interopera con cifrado y tiering).
- **LSO y `read_committed`.** `PartitionTxnIndex` mantiene el **Last Stable Offset** = `min(high_watermark, primer_offset_de_la_transacción_abierta_más_antigua)`: la frontera hasta la que **todo** está decidido. Un consumidor `read_committed` no lee más allá del LSO y **filtra** los records de transacciones **abortadas** y los marcadores de control (`filter_committed`); `read_uncommitted` lee hasta el *high-watermark* como hasta ahora. Los offsets nunca se reescriben ni se borran por abortar: la visibilidad la decide el lector según su nivel de aislamiento.

10. Replicación y consenso

Cómo NexusMQ tolera fallos sin perder datos *committed*: **Raft por partición**, con el log de Raft como WAL. Es la Fase 2 del proyecto y el corazón de su *correctitud demostrable*. Decisiones: [ADR-0003](#), [0014](#), [0015](#), [0016](#), [0024](#), [0025](#).

10.1 Un grupo Raft por partición

Cada partición es **su propio grupo Raft**: un único mecanismo de ordenación, replicación y elección. Frente al ISR clásico de Kafka (consenso solo para metadatos + primario-backup para datos), Raft por partición es **conceptualmente uniforme, formalmente especificado y testeable de forma determinista**, y compone con shared-nothing (un grupo anclado a un núcleo). El precio es el **quórum en cada escritura** (latencia de mayoría) en el camino caliente, asumido por la postura CP. Los estados de un nodo (`follower` → `candidate` → `leader`) están en el [diagrama 10](#).

10.2 El log de Raft es el WAL

No hay un WAL separado del log replicado: **el log de Raft es el log de la partición**. De ahí dos consecuencias clave:

- **High-watermark** = `commitIndex`. El offset visible a los consumidores es el `commitIndex` del grupo Raft; no existe un mecanismo de ISR aparte. El modelo de `acks` se asienta sobre el *commit*: `acks=0` responde sin esperar (*at-most-once*); `acks=1`, tras el *append* local del líder; `acks=quorum` (por defecto), tras el *commit* de Raft. Ver el flujo de replicación en el [diagrama 11](#).
- **Dos espacios de coordenadas** ([ADR-0014](#)): el **índice de entrada Raft** (ordinal de entrada; **una entrada** = **un** `RecordBatch`) es distinto del **offset por record** (dentro del batch). `RaftLog` envuelve el `PartitionLog` y persiste `term` /offsets por entrada en un **sidecar** de tamaño fijo, dejando el `RecordBatch` y `nexus-storage` **sin cambios**. La correspondencia se ilustra en el [diagrama 13](#).

10.3 RaftNode: una máquina de estados sin E/S

El núcleo de Raft, `RaftNode`, es una **máquina de estados síncrona sin E/S** ([ADR-0015](#)): recibe **entradas** (`tick(now)`, `on_append_entries`, `on_request_vote`, `on_propose` ...) con el reloj **inyectado** y produce una **cola de mensajes de salida** drenable; no hace ni red ni disco por sí mismo. Esta separación núcleo/E-S es lo que habilita la **simulación determinista** (reloj y red virtuales): se reproducen *timing*, elecciones de líder y particiones de forma **repetible**, cumpliendo FIRST sin *flakiness* (ver [capítulo 21](#)). El estado persistente (`currentTerm`, `votedFor`, `log[]`) se guarda **antes** de enviar nada por la red.

10.4 ReplicatedPartition y el transporte inter-nodo

`ReplicatedPartition` es un **tipo paralelo** a `Partition` ([ADR-0016](#)) que compone la pila Raft sobre el log de la partición. En producción, los RPC de Raft viajan por un **plano inter-nodo separado** del plano de cliente ([ADR-0025](#)):

- Un **sobre de wire** (`topic | partition | from | to | type | payload` , longitud-prefijo) rutea cada `RaftMessage` a la réplica (`topic, partition`) destino, reutilizando el `encode / decode` por RPC.
- Un **portador por partición** (`RaftCarrier`), afinado al reactor dueño vía `PartitionRouter` , conduce la FSM (`tick / take_messages / on_*`), **persiste el estado antes de enviar** y dispara la compactación por política.
- El `Server` se monta sobre `ReactorPool` y el `RequestRouter` enruta async al reactor dueño.

Los dos planos (cliente vs Raft, en puertos separados) se ven en el [diagrama 15](#).

10.5 Failover sin pérdida de datos committed

Al expirar el *election timeout* sin *heartbeat* del líder, un *follower* pasa a *candidate*, incrementa el `term` y solicita votos (`RequestVote` , con *pre-vote* opcional); si obtiene mayoría, se promueve a líder. **Solo puede ganar quien tenga el log al menos tan actualizado como la mayoría**, así que **no se pierden datos committed**. Los clientes redescubren el líder vía *metadata* (un líder obsoleto responde `NOT_LEADER_FOR_PARTITION` , detectado por el `leaderEpoch`). El proceso está en el [diagrama 12](#).

10.6 Compactación por snapshot

Para que el log replicado no crezca sin límite, [ADR-0024](#) añade una **base de snapshot** (`last_included_index, last_included_term, last_included_offset`) persistida en un sidecar dedicado (`raft-snapshot` , registro fijo con CRC32C). `compact_to(index)` descarta el prefijo ya aplicado (exacto en el índice) y recorta el prefijo **físico** del `PartitionLog` por **segmentos sellados enteros** (*best-effort*). Un seguidor muy rezagado se pone al día con `InstallSnapshot` , adoptando la base del líder ([diagrama 14](#)).

10.7 Postura de consistencia

NexusMQ es **CP / PACELC PC-EC** ([ADR-0007](#)): ante una partición de red, una partición de datos sin quórum **deja de aceptar escrituras** (no diverge); en operación normal, las escrituras esperan al quórum (`acks=quorum`), priorizando consistencia sobre latencia. La lectura por defecto es desde el **líder** hasta el *high-watermark*; las lecturas *stale* desde *followers* son *opt-in* y documentadas.

10.8 Coordinador de transacciones (Raft propio)

El **exactly-once multi-partición** ([ADR-0033](#)) añade un `TransactionCoordinator` : una **máquina de estados sin E/S** (mismo patrón que `RaftNode` , §10.3, y `GroupCoordinator`) que conduce el *two-phase commit* de una transacción. Consume `init_producer_id / begin / add_partitions / commit / abort / on_marker_written / tick` con el `now` inyectado y produce **órdenes de marcador** que el portador escribe en cada partición participante. Su estado (por transacción: estado FSM, participantes, época) se replica por su **propio grupo Raft** —«otro grupo Raft» sobre la misma infraestructura—, lo que hace el 2PC **recuperable**.

El 2PC es **logueado y recuperable, no bloqueante** ([ADR-0034](#)): la decisión (`PrepareCommit / PrepareAbort`) se **registra en Raft antes** de escribir ningún marcador; un failover del coordinador **re-conduce** la decisión ya registrada (`resume_pending`) en vez de dejar a los participantes bloqueados. Cada marcador se sella con la **época del coordinador** para descartar los de un líder obsoleto, y un *timeout* (`tick`) aborta las transacciones colgadas, liberando el LSO (§9.8). Coherente con la postura **CP** (§10.7): cerrar transacciones nuevas exige quórum en el grupo del coordinador. El flujo se ilustra en el [diagrama 25](#).

11. Ingress

La capa de entrada: cómo llegan los clientes al broker. NexusMQ ofrece **dos modos** con jerarquía explícita —nativo directo (primario) y proxy/REST (secundario)— en lugar de "un ingress que lo hace todo". Decisiones: [ADR-0006](#), [0027](#), [0019](#), [0018](#).

11.1 Dos modos, un *trade-off* explícito

En un plano de datos de alto rendimiento, interponer un proxy añade un salto y rompe el *zero-copy*; pero exigir siempre un *smart-client* excluye a clientes simples y a HTTP. La respuesta son **dos modos** (ver [diagrama 19](#)):

- **Nativo directo (primario).** Un *smart-client* consulta *metadata* y va **directo al líder** de la partición, sin proxy. Es el camino óptimo en latencia; el cliente gestiona el descubrimiento de líder y reacciona a `NOT_LEADER_FOR_PARTITION`.
- **Proxy/REST (secundario, *opt-in*).** El *ingress* enruta clientes "tontos" (*consistent hashing*) y expone un **gateway REST**, asumiendo el salto extra a sabiendas.

11.2 Modo proxy: *upstream pool* por reactor

El cableado del modo proxy ([ADR-0027](#)) mantiene un **pool de conexiones aguas arriba por reactor** (`UpstreamPool`), coherente con shared-nothing: cada reactor reutiliza sus propias conexiones al broker destino (resuelto vía `PeerDirectory`), sin compartir *sockets* entre núcleos. Esto evita reabrir conexión por petición (el *handshake* TCP+TLS cuesta RTTs) y mantiene la localidad del modelo *thread-per-core*.

11.3 TLS opcional sobre el proactor

La terminación TLS 1.3 se hace con **OpenSSL** mediante un **punto de BIOS de memoria** sobre el `Proactor` ([ADR-0019](#)): OpenSSL procesa el *handshake* y el cifrado **en memoria** (memory BIOs), mientras el socket asíncrono mueve los bytes cifrados; así una librería de TLS síncrona convive con la I/O por *completions* sin acoplarse a ella (ver [diagrama 20](#)). La dependencia es **opcional**: se compila si `find_package(OpenSSL)` la encuentra (`NEXUS_HAVE_OPENSSL`); si falta, el nodo **degrada a texto en claro** en lugar de no compilar. Se contempla **mTLS** intra-cluster (ver [capítulo 27](#)).

11.4 Gateway REST de administración

El plano de control HTTP (`/api/v1`, salud, métricas) se sirve por un **adaptador** (`AdminService` en `nexus-ingress`, `AdminApi` en `nexus-server`) en su propio puerto ([ADR-0018](#)), sin acoplar el núcleo al framework web. El detalle del contrato está en el [capítulo 15](#).

11.5 Resiliencia

El ingress aplica los patrones de estabilidad clásicos (Nygard):

- **Circuit Breaker** (estados *closed/open/half-open*, ventana deslizante de errores) para no insistir contra un destino caído.
- **Bulkhead**: *pools* de conexiones aislados por destino, para que un fallo no agote todo.
- **Retry con *backoff* exponencial + *jitter*** (con tope) sobre operaciones idempotentes.
- **Rate limiting** con *token bucket* por cliente/*topic*.
- **Health checks** activos (ping periódico) y pasivos (errores en tráfico real).
- **Backpressure por créditos** propagado hasta el cliente, en lugar de descartar en silencio (ver [capítulo 7](#)).

12. Observabilidad

Cómo se ve por dentro un broker en marcha: métricas, logs y salud. La observabilidad es de grado producción y se concentra en el target `nexus-telemetry` (ADR-0017). El flujo se ilustra en el [diagrama 23](#).

12.1 Un target dedicado bajo el broker

La telemetría vive en su propia librería, `nexus-telemetry`, por debajo del broker en el grafo de dependencias (ADR-0017): así el núcleo emite métricas y logs sin depender del detalle de exposición, y se evita un ciclo de dependencias. Agrupa tres piezas: `metrics`, `logging` y `tracing`.

12.2 Métricas (Prometheus)

El nodo expone `GET /metrics` en formato de exposición de Prometheus, sin autenticación (para no entorpecer al *scraper*). Las métricas cubren las **cuatro señales de oro** —latencia, tráfico, errores, saturación— y los recursos por el método **USE** (utilización, saturación, errores). Magnitudes típicas de un broker: throughput de *produce/fetch*, latencias por percentil, *lag* de consumidores, tamaño y *commit* del log, estado de Raft (líder/seguidor, `commitIndex`), créditos de *backpressure*. La latencia se reporta por **percentiles** (p50/p99/p999), no por medias (ver [capítulo 23](#)).

Las familias del plano de datos (`nexus_broker_requests_total`, `..._request_errors_total`, `..._request_bytes_total`, `..._request_duration_seconds`) llevan dos etiquetas: `api` (`produce / fetch`) y `protocol` (`native` para el protocolo binario propio, `kafka` para el subconjunto Kafka). Así un operador distingue —o agrega con `sum by (protocol)`— el tráfico de cada protocolo aunque compartan el mismo broker y las mismas particiones.

12.3 Logs estructurados

Los logs son **estructurados (JSON)**, con **correlation IDs** que permiten seguir una petición a través de los planos y los reactores. Se evita el *logging* síncrono caro en el camino caliente. El idioma de los mensajes de cara al operador es español; los identificadores, en inglés.

12.4 Tracing

`tracing` propaga *correlation IDs* a través del *pipeline* (recepción → decodificación → *append* → replicación → *ack*) y entre reactores, de modo que una operación distribuida pueda reconstruirse. Como toda observabilidad, tiene coste: se mide su *overhead* (*observer effect*) y no se deja activado a ciegas bajo carga.

12.5 Salud: liveness y readiness

El plano de salud distingue dos preguntas distintas:

- `GET /healthz` (**liveness**): ¿el proceso está vivo? Si falla, el orquestador reinicia.

- `GET /readyz` (**readiness**): ¿puede recibir tráfico? Comprueba disco, estado de Raft y *lag*; si falla, el orquestador lo saca de balanceo **sin** reiniciarlo.

Ambos endpoints solo aceptan `GET` (y `HEAD`); cualquier otro método responde **405 Method Not Allowed**, para que un `POST` / `PUT` accidental de una *probe* mal configurada falle de forma explícita en vez de ser tratado como una consulta de salud.

Esta distinción evita reiniciar procesos "vivos pero no listos" (p. ej. poniéndose al día tras un *failover*). El `HEALTHCHECK` de la imagen y las *probes* de Kubernetes se cablean a `/readyz` (ver [capítulo 25](#)). El despliegue de observabilidad (Prometheus + Grafana *self-hosted*) se describe en el [capítulo 26](#).

13. Protocolo binario nativo

Este capítulo **explica y enlaza** el protocolo binario propio del plano de datos de NexusMQ —el rationale, las capas que lo implementan y los flujos de petición/respuesta—. El contrato *as-built* (byte-layout exacto, tipos campo a campo) es [../protocol.md](#); este capítulo no lo duplica.

13.1. Por qué un protocolo propio

El plano de datos necesita un protocolo, y había dos caminos en tensión: un **binario propio** o la **compatibilidad con Apache Kafka** desde el inicio. La decisión está registrada en [ADR-0004](#): se implementa un **protocolo binario propio** para las fases nucleares, con un **gateway REST** para interoperabilidad temprana, y se **difiere** un subconjunto Kafka-compatible a la Fase 4 (ver [capítulo 14](#)).

Las razones, en una frase: un protocolo propio **maximiza el aprendizaje y el control** —*framing*, varint, *multiplexing* por *correlation id*, versionado negociado, control de flujo por créditos— y compone **sin impedance mismatch** con la arquitectura *shared-nothing thread-per-core*. La compatibilidad Kafka habría dado ecosistema, pero obliga a implementar una especificación ajena y enorme (más de 70 *API keys* versionadas, *consumer group protocol*...), atando el diseño antes de existir. El titular «Kafka-compatible» queda **recuperable más tarde** sin pagar su coste por adelantado.

13.2. La capa `nexus-wire` (framing sobre conexión)

El protocolo está partido en dos capas con responsabilidades distintas, una decisión de capas limpias registrada en [ADR-0013](#):

- `nexus-protocol` es **protocolo puro**: *codec* (`Encoder / Decoder`), `FrameHeader` , mensajes y códigos de error. Depende **solo** de `nexus-common` —sin E/S, sin *async*—, de modo que la (de)serialización se prueba y se *fuzzea* sin tocar sockets ni *io_uring*.
- `nexus-wire` aloja el **framing sobre conexión**: `Frame` , `FrameReader` y `FrameWriter` . Lee y escribe tramas longitud-prefijo sobre un `Socket` mediante el `Proactor` , así que depende de `nexus-io` (sockets, *proactor*) y de las corutinas (`task<expected<T>>`). Los consumidores del transporte de tramas —*broker*, *client*, *ingress*, *server*— dependen de `nexus-wire` .

`FrameReader::read_frame` expone el payload como **vista dentro del búfer del lector** (válida hasta la siguiente lectura): es *zero-copy* a cambio de una invariante de vida documentada. Esto encaja con la lectura del framing descrita abajo.

13.3. Estructura de la cabecera de trama

Toda trama es **longitud-prefijo**: una cabecera de **14 bytes** (`FrameHeader::kEncodedSize`) seguida del payload, en **little-endian**. La cabecera lleva, en orden, `length:u32` , `apiKey:u16` , `apiVersion:u16` , `correlationId:u32` y `flags:u16` ; el payload ocupa `length - 10` bytes. El byte-layout exacto está en el [diagrama 16](#) y en [../protocol.md](#) ; aquí basta con el modelo de lectura y la semántica de cada campo.

- **Lectura en dos fases**: se leen 4 bytes (`length`), y luego **exactamente** `length` bytes más. Como `length` cuenta los bytes *tras* su propio campo (resto de cabecera + payload), un lector nunca necesita conocer de antemano el tamaño total.

- **Cotas de seguridad:** el lector valida una **cota inferior** (debe caber el resto de la cabecera) y una **cota superior anti-DoS** (`max_frame`, por defecto **16 MiB**) antes de reservar el búfer.
- **flags** : un mapa de bits de control. Hoy se usa `0x0001` (*credit update*): la trama acarrea una actualización de créditos del control de flujo/*backpressure*. `FrameHeader::has_credit_update()` lo consulta.

ApiKeys

El campo `apiKey` selecciona la operación. El enum `ApiKey` (`src/protocol/frame.hpp`) define las operaciones del plano de datos: `ApiVersions`, `Metadata`, `Produce`, `Fetch`, la familia de offsets de grupo (`OffsetCommit` / `OffsetFetch`), el protocolo de grupos de consumidores (`JoinGroup` / `SyncGroup` / `Heartbeat` / `LeaveGroup`) y administración de topics (`CreateTopic` / `DeleteTopic`). La tabla de valores numéricos y su descripción está en [../protocol.md](#).

13.4. Versionado negociado

Cada operación tiene un **esquema versionado** por su `apiVersion`, y la versión efectiva se **negocia** al abrir la conexión:

1. El cliente envía `ApiVersions` anunciando el **máximo** que soporta por `ApiKey`.
2. El servidor publica un rango `[min, max]` por `ApiKey`.
3. La versión efectiva es la **mayor que ambos soportan**: `min(client_max, server.max)` si alcanza `server.min`; 0 si la `ApiKey` no es negociable o no hay solape.

A partir de ahí, cada trama lleva su `apiVersion` y el *codec* (de)serializa según el esquema de esa versión. La lógica de negociación vive en `src/protocol/versioning.hpp`. Este versionado permite **evolucionar el esquema sin romper** clientes antiguos (campos opcionales en versiones nuevas), coherente con la evolución de contratos del proyecto.

13.5. Correlation id y multiplexing

El transporte es **TCP**, y una **única conexión multiplexa muchas peticiones** simultáneas. El mecanismo es el `correlationId`:

- Lo **elige el cliente** en cada petición (típicamente un contador monótono por conexión).
- La respuesta del broker **espeja** (`echo`) ese mismo `correlationId`.
- El cliente casa respuesta con petición por ese id, sin necesidad de que las respuestas lleguen en orden de envío.

Esto evita el coste de abrir una conexión TCP (+TLS) por petición y minimiza RTTs: las peticiones se pueden *pipeline*-ar sobre una conexión persistente.

13.6. Flujos produce/fetch

Sobre este framing se construyen los dos flujos calientes del plano de datos. El **detalle de los mensajes** (campos de `ProduceRequest` / `FetchResponse`, etc.) está en `src/protocol/messages.hpp` y resumido en [../protocol.md](#); aquí, el flujo de extremo a extremo:

- **Produce** publica un `RecordBatch` en una partición. El batch viaja **íntacto** por el log y por la replicación: es la **unidad de escritura y de entrada de Raft** (ADR-0014). La respuesta acarrea el offset asignado y un `errorCode:i16`. La política de `acks` (0/1/quorum) se resuelve sobre el `commitIndex` de Raft de la partición (ver [capítulo 10](#)).
- **Fetch** lee registros desde un offset hasta el *high-watermark* de la partición. El blob de records puede ir **comprimido** (LZ4/Zstd, indicado en los 2 bits bajos de `attrs`): el broker lo trata como **opaco** —lo guarda y replica comprimido— y solo el cliente lo descomprime al consumir. El bloque comprimido lleva su tamaño original como prefijo (defensa anti *decompression bomb*).

Las respuestas siempre incluyen el `errorCode:i16` del contrato externo de errores; su taxonomía y la traducción en el borde se tratan en el [capítulo 16](#). Las operaciones de administración (`CreateTopic` / `DeleteTopic`) devuelven igualmente su `errorCode:i16`; en particular, `CreateTopic` con un **nombre inválido** (vacío, con espacios o separadores de ruta, `./..`, o de más de 249 caracteres) se rechaza con `InvalidRequest` **sin crear ficheros**, aplicando la misma validación centralizada (`TopicManager::validate_topic_name`) que la API REST.

13.6b. API transaccional (exactly-once nativo)

La superficie **nativa** —no el subset Kafka ([ADR-0030](#))— expone las transacciones multi-partición ([ADR-0033](#)) como un pequeño grupo de operaciones sobre el mismo framing:

- **InitProducerId** (`initTransactions`): registra un `transactional.id` y devuelve su identidad (`producer_id` + época). Reiniciar sube la época, expulsando (*fencing*) a la encarnación anterior.
- **AddPartitionsToTxn**: declara qué particiones participan en la transacción abierta.
- **EndTxn** (COMMIT/ABORT): decide el fin de la transacción; el coordinador escribe los marcadores de control en cada participante (ver [capítulo 10 §10.8](#)).

En el lado de lectura, **Fetch** acepta un **nivel de aislamiento**: `read_uncommitted` (0) entrega hasta el *high-watermark* como siempre; `read_committed` (1) entrega solo hasta el **LSO** y filtra los records abortados y los marcadores (§9.8). El **Produce** de un batch transaccional arrastra `producer_id /época/flag` transaccional en la cabecera del `RecordBatch`, reutilizando la idempotencia de `ProducerSession`. El camino no transaccional es idéntico al de hoy. Formatos en [../protocol.md](#).

13.7. Seguridad del transporte

El plano de datos puede terminar **TLS 1.3** (y **mTLS** intra-clúster) por delante del framing (ADR-0019): el protocolo binario es idéntico, cifrado o en claro. El puente TLS sobre el proactor asíncrono se trata en el [capítulo 11 \(Ingress\)](#) y el [capítulo 27 \(Seguridad\)](#).

13.8. Referencias

- Contrato *as-built*: [../protocol.md](#).
- Diagrama del frame: [diagrama 16](#).
- ADRs: [ADR-0004](#) (protocolo propio), [ADR-0013](#) (`nexus-wire`), [ADR-0009](#) (errores por capa).
- Capítulos relacionados: [14 \(Kafka\)](#), [16 \(modelo de errores\)](#).

14. Subconjunto Kafka

Este capítulo **explica y enlaza** el *listener* compatible con el protocolo de Apache Kafka: por qué existe, qué subconjunto cubre y cómo encaja en la arquitectura *shared-nothing*. El contrato *as-built* (APIs, versiones, framing, RecordBatch) es `../kafka.md`; este capítulo no lo duplica.

14.1. Por qué un subconjunto, y por qué diferido

La compatibilidad Kafka no es el plano de datos principal de NexusMQ —ese es el [protocolo binario nativo](#)—. Según [ADR-0004](#), implementar la especificación completa de Kafka desde el inicio habría atado el diseño a un contrato ajeno y enorme antes de que el broker existiera. Por eso se **difirió un subconjunto** a la **Fase 4** como *stretch*: lo justo para la demo «`kcat` habla con mi broker», con **interop verificada en vivo** (`kcat /librdkafka`), sin apostar el proyecto a la especificación entera.

El cableado real al servidor —el adaptador que conecta el protocolo Kafka al broker vivo— está registrado en [ADR-0029](#), cuya pieza central se explica abajo.

- **Activación:** `nexusd --kafka-port <N>` (apagado si no se indica). Convive en el mismo proceso con el plano de datos nativo (`--port`) y el de administración (`--admin-port`).

14.2. Adaptador asíncrono cross-core (ADR-0029)

El plano de datos es *shared-nothing thread-per-core* con **sharding partición→núcleo** (ADR-0026): una partición la **posee un único núcleo**. Pero una conexión Kafka aceptada en un reactor cualquiera puede pedir particiones que pertenecen a **otro** núcleo. La solución de [ADR-0029](#):

- El **puerto** `KafkaBroker` es **asíncrono**: sus métodos (`metadata / produce / fetch / list_offsets`) devuelven `task<...>`, y el `KafkaGateway` hace `co_await broker_.X(req)`. Así el adaptador puede **saltar al reactor dueño** de la partición y volver, en vez de serializar todo el tráfico Kafka en el núcleo 0.
- El **adaptador** concreto `KafkaServerBroker` (en `nexus-server`) implementa ese puerto **enrutando cada partición a su núcleo dueño** vía `PartitionRouter::route`. El puerto `KafkaBroker` no conoce `nexus-broker` (DIP): se testea con un `FakeBroker`.
- El `Server` abre el *listener* en `--kafka-port`; cada conexión la sirve `serve_kafka_connection`, que alimenta `KafkaGateway::handle_request`. El código vive en `src/kafka/` (codec y mensajes) y `src/server/kafka_*` (listener y adaptador).

14.3. Transporte y framing

El framing de Kafka difiere del nativo en dos puntos clave:

- Cada mensaje va **longitud-prefijo** con un `Size:INT32` **big-endian**: 4 bytes con el tamaño del resto del mensaje, seguido de ese número de bytes.
- **Endianness big-endian** en todo el protocolo (contrato de Kafka), a diferencia del protocolo nativo, que es **little-endian**.

Como en el nativo, el transporte es **TCP** y la petición/respuesta se multiplexa por `correlationId`. El detalle está en `../kafka.md` y en el [diagrama 17](#).

14.4. APIs y versiones soportadas

El subconjunto cubre **cinco APIs**: `ApiVersions`, `Metadata`, `Produce`, `Fetch` y `ListOffsets` —lo imprescindible para *metadata*, *produce* y *consume*—. El cliente abre con `ApiVersions`, el broker publica los rangos `[min, max]` soportados, y a partir de ahí cada petición lleva su versión; **lo no listado no se soporta** (el cliente recibe el rango y se ajusta). La tabla exacta de `ApiKeys` y rangos está en [../kafka.md](#).

`ApiVersions` anuncia deliberadamente rangos que **cubren lo que negocia librdkafka 2.x** (notablemente `Produce v7` y `Fetch v11`), no las versiones máximas teóricas.

14.5. Clásico vs flexible (tagged fields)

A partir de ciertas versiones, Kafka cambió a un formato **flexible**: cabeceras con *tagged fields* y arrays/strings *compact* con longitud en `UNSIGNED_VARINT`. El codec elige el formato **por API y versión**, según un umbral `flexible_since`: una versión `>=` su umbral es **flexible**; por debajo, **clásica**. Los umbrales por API están en [../kafka.md](#).

La consecuencia práctica, y un detalle que [ADR-0029](#) corrige explícitamente: las versiones que negocia librdkafka (**`Produce v7` y `Fetch v11`**) son **clásicas** (longitudes `INT16` / `INT32`, sin *tagged fields*), mientras que **`Metadata v9`, `ListOffsets v7` y `ApiVersions v3`** son **flexibles**. Por eso el codec **debe** ramificar por versión, con *gates* de campo por versión (p. ej. `last_fetched_epoch` solo `v12+` — el bug que rompía `Fetch v11`). Asumir versiones flexibles e ignorar las clásicas rompe con `kcat`: era el fallo de las iteraciones previas, descartado en [ADR-0029](#).

Una excepción heredada del propio Kafka: `ApiVersions` responde **siempre** con cabecera de respuesta `v0` (clásica) aunque su cuerpo sea flexible.

14.6. RecordBatch tratado como opaco

`Produce` / `Fetch` transportan **RecordBatch v2 de Kafka** (cabecera de 61 bytes con su `CRC32C`). El broker lo guarda y replica como **blob opaco** dentro de su envoltorio interno: **no reinterpreta el contenido**, solo su `record_count` gobierna la asignación de offsets. Esta decisión evita el coste y la fragilidad de traducir el `RecordBatch` a/desde el formato interno (reencode + recálculo de CRC en el *hot path*).

En `Fetch`, el blob se reconstruye y se le **reescribe el `baseOffset`** autoritativo. Es barato: el CRC de Kafka `v2` cubre desde `attributes` en adelante, así que parchear `baseOffset` **no** invalida el CRC.

Un detalle de interop importante: un `Fetch` sin datos nuevos (consumidor al día con el *high-watermark*) devuelve un `MessageSet` **presente pero de longitud 0**, nunca `null` (`-1`) — librdkafka rechaza un `MessageSetSize` de `-1` como trama corrupta.

Como el blob de Kafka y los records nativos comparten el mismo log pero **no** el mismo formato, mezclar ambos protocolos en una misma partición daría lecturas ilegibles. Por eso una partición es **mono-protocolo** ([ADR-0030](#)): la **primera** escritura reclama su protocolo (nativo o Kafka) y un `Produce` / `Fetch` del **otro** protocolo sobre esa partición se rechaza con `InvalidRequest`, en lugar de servir bytes que el cliente no sabe decodificar (antes se devolvían cero records en silencio). La marca es por partición y en memoria (se re-establece con la primera escritura tras un reinicio).

14.7. Mapeo al broker e interop

El adaptador traduce cada petición Kafka a operaciones del broker vivo: `Metadata` → topics/particiones del nodo; `Produce` → `produce` sobre la partición destino (`RecordBatch` opaco); `Fetch` → lectura desde el offset pedido hasta el *high-watermark*; `ListOffsets` → *earliest* (`log_start_offset`) / *latest* (*high-watermark*); `ApiVersions` → los rangos publicados. El mapeo completo está en [../kafka.md](#).

Con esto, `kcat` interopera en vivo: `-L` (metadata), `-P` (produce) y `-C` (consume), incluido **multi-partición cross-core** (mensajes servidos desde el núcleo dueño de cada partición).

14.8. Límites conocidos

El subconjunto es deliberadamente parcial (las limitaciones se detallan también en el [capítulo 30](#)):

- **Un-nodo:** la `Metadata` anuncia este nodo como único broker y líder de sus particiones; no hay descubrimiento de clúster por el plano Kafka.
- **Sin grupos de consumidores** por el plano Kafka (`OffsetCommit` / `JoinGroup` /... no están en el subconjunto): el seguimiento de offsets del lado servidor vive en el plano nativo.
- **Sin transacciones ni *idempotent producer*** de Kafka: la idempotencia del broker es la del plano nativo.
- **Sin mezcla de protocolos en una partición:** una partición la posee el primer protocolo que escribe en ella; el otro se rechaza con `InvalidRequest` ([ADR-0030](#)). Para convivir nativo y Kafka, usa particiones o topics separados.

14.9. Referencias

- Contrato *as-built*: [../kafka.md](#).
- Diagrama: [diagrama 17](#).
- ADRs: [ADR-0029](#) (adaptador async cross-core), [ADR-0030](#) (partición mono-protocolo), [ADR-0004](#) (subconjunto diferido a Fase 4).
- Capítulos relacionados: [13](#) (protocolo nativo), [7](#) (conurrencia / sharding), [30](#) (limitaciones).

15. API REST de administración

Plano de control HTTP para operar el broker: gestión de *topics* y grupos, salud y métricas. Este capítulo **explica y enlaza** el contrato; la fuente de verdad —rutas, esquemas y respuestas exactas— es [docs/openapi.yaml](#).

15.1 Rationale y ubicación

La administración no viaja por el plano de datos binario, sino por una **API REST** separada, expuesta en su propio puerto (`--admin-port`). La separación es deliberada ([ADR-0018](#)): el contrato HTTP/JSON se sirve por un **adaptador** (`AdminService` en `nexus-ingress`, `AdminApi` en `nexus-server`) que traduce peticiones REST a operaciones del broker, sin acoplar el núcleo al framework web. Es el plano de control —no el camino caliente—, así que aquí **sí** rigen las excepciones y la traducción central de errores (ver [capítulo 16](#)).

15.2 Recursos y operaciones

Bajo `/api/v1`, recursos en plural y verbos HTTP (sin acciones en la URL):

Método y ruta	Propósito
GET <code>/api/v1/topics</code>	Lista los <i>topics</i> (paginado).
POST <code>/api/v1/topics</code>	Crea un <i>topic</i> ; responde <code>201</code> con cabecera <code>Location</code> .
GET <code>/api/v1/topics/{name}</code>	Describe un <i>topic</i> (resumen + particiones).
DELETE <code>/api/v1/topics/{name}</code>	Borra un <i>topic</i> y sus datos en disco (el <code>.log</code> / <code>.index</code> de cada partición).
GET <code>/api/v1/groups</code>	Lista los grupos de consumidores (paginado).

Fuera de `/api/v1` y **sin autenticación**, el plano de salud/observabilidad:

Ruta	Propósito
GET <code>/healthz</code>	<i>Liveness</i> : ¿el proceso está vivo?
GET <code>/readyz</code>	<i>Readiness</i> : ¿puede recibir tráfico? (disco/Raft/lag).
GET <code>/metrics</code>	Métricas en formato de exposición de Prometheus.

`/healthz` y `/readyz` solo aceptan **GET** (y **HEAD**); cualquier otro método responde **405 Method Not Allowed**, para que una *probe* mal configurada (p. ej. un **POST**) falle de forma explícita en vez de tratarse como una consulta de salud.

La distinción *liveness/readiness* permite que un orquestador reinicie procesos "vivos pero no listos" sin sacarlos de servicio prematuramente (ver [capítulo 12, Observabilidad](#)).

15.3 Autenticación

Las rutas `/api/v1/*` se autentican con **Bearer JWT** (HS256), firmado con el secreto del nodo. La autenticación **solo se exige si el nodo arrancó con** `--jwt-secret`; en ese caso, una petición sin un token válido recibe `401`. El plano de salud/métricas queda siempre sin autenticar para no entorpecer a las sondas y al *scraper*. El detalle de TLS y la postura de seguridad están en el [capítulo 27](#).

15.4 Paginación y errores

- **Colecciones paginadas:** `GET /api/v1/topics` y `GET /api/v1/groups` pagan en lugar de devolver listas sin límite.
- **Errores RFC 7807:** toda respuesta de error usa el esquema `ProblemDetail` (`application/problem+json`), con una **política central** de traducción. Esto da al cliente un formato de error uniforme y predecible (códigos `400` / `401` / `404` / `409` / ...).
- **Validación de nombre de *topic*:** `POST /api/v1/topics` con un nombre inválido (vacío, con espacios o separadores de ruta, `.` / `..`, o de más de 249 caracteres) responde `400`. La regla vive en `TopicManager::validate_topic_name` (**fuentes únicas**), de modo que el protocolo binario nativo aplica exactamente la misma validación —traducida a su código de wire— y ninguna superficie acepta lo que otra rechaza.

15.5 Documentación como contrato

`openapi.yaml` no es solo documentación: es un **artefacto de tooling** (Swagger UI, generación de clientes, *contract testing*). Por eso se mantiene como fichero independiente y este capítulo no reproduce sus esquemas: consúltalos en [docs/openapi.yaml](#). El flujo de autenticación y petición se ilustra en el [diagrama 18](#).

16. Modelo de errores y códigos de wire

Cómo se representa y propaga un fallo en NexusMQ. La regla es **una política por capa**: el mecanismo cambia según la superficie (protocolo, núcleo, plano de control), pero las invariantes transversales no. Decisión de fondo: [ADR-0009](#).

16.1 Tres superficies de error


El broker tiene tres superficies con exigencias distintas, y por eso tres mecanismos:

Superficie	Mecanismo	Por qué
Protocolo / wire	<code>errorCode:i16</code> (código numérico)	Es contrato de red, parte del <i>wire format</i> ; legítimo y estable entre versiones.
Núcleo / hot-path (storage, reactor, consensus)	<code>std::expected<T, Error></code>	El error es un valor de coste predecible; sin <i>unwinding</i> de excepciones en el camino caliente.
Plano de control (admin, configuración)	Excepciones + <code>std::optional</code>	Lógica de aplicación: las excepciones separan el flujo normal del fallo; ausencia → <code>optional</code> .

Esta política reconcilia las dos autoridades de la biblioteca: "excepciones, no códigos de error" rige la **lógica de aplicación**, mientras que en **sistemas/baja latencia** se prefiere un error explícito como valor (`std::expected`). Ambas conviven sin contradicción porque se aplican a capas distintas.

16.2 Traducción en el borde

Los códigos de wire **no se propagan crudos** por el núcleo: se **traducen al modelo interno en el borde** (al decodificar una petición) y de vuelta a un código al codificar la respuesta. El núcleo razona con `Error / expected`, no con enteros del protocolo. Del mismo modo, los errores de librerías de terceros (p. ej. OpenSSL) se **envuelven** en tipos propios para no acoplar el núcleo a su modelo de errores.



16.3 El tipo `Error` y `expected<T>`

El núcleo usa el alias `expected<T> = std::expected<T, Error>` (C++23, que es la razón de subir el estándar y de exigir libC++ en Clang — [ADR-0011](#)). Las corutinas del *hot-path* devuelven `task<expected<T>>`. La propagación se encadena con los monádicos `and_then / or_else`, evitando el ruido de comprobar cada retorno a mano. Todo `Error` aporta **contexto** (qué operación falló y de qué tipo de fallo se trata): nunca se "traga" un error en silencio.

16.4 Taxonomía de códigos del protocolo

El protocolo nativo define un conjunto acotado de códigos `i16` (definidos en `src/protocol/error_code.hpp`) que cubren las familias habituales de un broker, por ejemplo:

- **Entrada inválida:** mensaje/batch demasiado grande (`MESSAGE_TOO_LARGE`), petición malformada (`InvalidRequest`) —incluido un **nombre de *topic* inválido** en `CreateTopic` , validado por `TopicManager` (fuente única) e idéntico en REST y en el protocolo nativo—, versión de API no soportada.
- **Enrutado/topología:** *topic*/partición inexistente, **no soy el líder** de esa partición (el cliente debe redirigir al líder vía *metadata*).
- **Disponibilidad/consistencia:** sin quórum para escribir (postura CP), *timeout* de replicación.
- **Offset/retención:** offset fuera de rango (purgado por retención).

La lista exacta y sus valores son **contrato**: viven en el código y en el [contrato del protocolo](#). Para el subset Kafka, los códigos se mapean a los **error codes de Kafka** en el borde del adaptador (ver [capítulo 14](#)).

16.5 En la API REST

En el plano de control, el borde REST traduce a `ProblemDetail` (**RFC 7807**) con una **política central** (ver [capítulo 15](#)). Es la misma filosofía —una sola política de traducción de errores hacia el exterior— materializada en HTTP en lugar de en el *wire* binario.

17. Mapa de módulos

La traducción del diseño a *targets* de build: qué librerías existen, cómo dependen entre sí y qué se entregó en cada fase. Es la vista de implementación de la [vista de conjunto](#).

17.1 Targets

Un único árbol CMake produce **15 librerías** `nexus-*`, los ejecutables y las herramientas:

- **Librerías:** `nexus-common`, `nexus-io`, `nexus-wire`, `nexus-protocol`, `nexus-storage`, `nexus-reactor`, `nexus-consensus`, `nexus-cluster`, `nexus-broker`, `nexus-kafka`, `nexus-ingress`, `nexus-telemetry`, `nexus-server`, `nexus-client`, `nexus-ffi`.
- **Ejecutables:** `nexusd` (el servidor), y las *tools* `nexus-cli`, `nexus-bench`, `nexus-loadgen`, más `wincheck` (arnés Windows-only).

`nexus-wire` es una librería **INTERFACE** (solo cabeceras: el framing sobre conexión); `nexus-ffi` se compila como **SHARED** (su superficie es una ABI C estable, ver [capítulo 20](#)).

17.2 Grafo de dependencias y regla de capas

Las dependencias **apuntan hacia el núcleo**; ningún *target* depende de otro de su misma capa o superior. La regla la fuerza CMake (`target_link_libraries` con `PUBLIC` / `PRIVATE`). De abajo arriba: `nexus-common` (sin dependencias internas) → `io` / `wire` → `protocol` / `storage` → `reactor` → `consensus` / `cluster` → `broker` / `kafka` → `ingress` / `telemetry` → `server` / `client`; `nexusd` depende de `nexus-server`. El grafo completo —incluidas las aristas exactas— está en el [diagrama 3](#).

Esta disciplina mantiene el núcleo (storage, broker, consenso) **independiente del detalle de I/O y de protocolo**: cuando una capa inferior necesitaría a una superior, se invierte la dependencia con un **puerto** en el consumidor y un **adaptador** arriba (DIP), como en `nexus-telemetry` ([ADR-0017](#)) y en la REST admin ([ADR-0018](#)).

17.3 Mapa fase → targets

Cada fase entregó un subconjunto demoable (ver [diagrama 4](#) y la [historia de desarrollo](#)):

Fase	Targets principales	Entregable
1	nexus-common , nexus-storage , nexus-bench	Motor de log monopartición + benchmarks (I/O bloqueante).
1b	nexus-io , nexus-wire , nexus-protocol , nexus-reactor , nexus-broker , nexus-client	Broker de un nodo <i>thread-per-core</i> ; <i>produce/fetch</i> con cliente nativo.
2	nexus-consensus , nexus-cluster (+ broker)	Raft por partición, <i>failover</i> , grupos de consumidores.
3	nexus-ingress , nexus-telemetry , nexus-server , nexus-cli	Ingress (TLS, REST admin), CLI, métricas.
4	nexus-kafka , nexus-ffi , nexus-loadgen , wincheck (+ IOCP en nexus-io)	Subset Kafka, binding Python, loadgen, port Windows.

El detalle de cada librería está en el [catálogo por subsistema](#).

18. Catálogo por subsistema

Una ficha por librería `nexus-*`: su responsabilidad, sus tipos clave, su **afinidad** de concurrencia y sus invariantes principales. El nivel es "tipos clave + invariantes", no clase-a-clase: el detalle exhaustivo (cada campo y firma) vive en el código fuente de cada subsistema (`src/`). La afinidad sigue la anotación del proyecto: **REACTOR-LOCAL** (de un reactor, no *thread-safe*) · **IMMUTABLE** (solo lectura tras construir) · **CROSS-CORE** (solo se comunica por paso de mensajes) · **THREAD-SAFE**.

nexus-common

Responsabilidad: tipos y utilidades transversales sin dependencias internas. **Tipos clave:** `Bytes` / `span` (vistas no propietarias), `Error` y `expected<T>`, `Record` y `RecordCodec`, `crc32c`, `varint` / `zigzag`, `base64`, `sha256`, `fnv1a`, `compression` (LZ4/Zstd opcional), `task<T>` (corutinas), `move_only_function`; control records de transacción (`ControlRecordType`, `EndTxnMarker`; [ADR-0033](#)). **Afinidad:** mayormente **IMMUTABLE**/valor puro; `task<T>` es **REACTOR-LOCAL** en uso. **Invariantes:** `crc32c` coincide con el hardware (SSE4.2) y el *fallback* software; el codec de `Record` y el de los marcadores de control son *round-trip* (`decode(encode(x)) == x`).

nexus-io

Responsabilidad: I/O asíncrona por *completions* (el proactor) y recursos del SO. **Tipos clave:** `Proactor` (puerto), `IoUringBackend`, `IoctlBackend`, `File`, `Socket`, `Listener`, `AlignedBuffer`, `BlockReader`, `awaitable`; tipos portables `NativeHandle` / `IoResult`. **Afinidad:** **REACTOR-LOCAL** (un anillo `io_uring` por núcleo; sin compartición). **Invariantes:** todo recurso del SO es RAII (se libera en el destructor); toda *completion* comprueba su resultado (puede fallar como una `syscall` síncrona).

nexus-wire

Responsabilidad: *framing* sobre conexión (separar el framing de la codificación pura). **Tipos clave:** `FrameReader` / `FrameWriter` (cabecera `INTERFACE`, [ADR-0013](#)). **Afinidad:** **REACTOR-LOCAL** (por conexión). **Invariantes:** `nexus-protocol` queda **puro** (sin I/O); el framing no interpreta el cuerpo.

nexus-protocol

Responsabilidad: protocolo binario nativo: codificación, frames, versionado y códigos de error. **Tipos clave:** `FrameHeader` (`length:u32`, `apiKey:u16`, `apiVersion:u16`, `correlationId:u32`, `flags:u16`), `Codec`, `messages`, `versioning`, `error_code` (`i16`). **Afinidad:** **IMMUTABLE**/sin estado (codec puro). **Invariantes:** *round-trip* de serialización; los códigos de wire son **contrato** y se traducen en el borde (ver [capítulo 16](#)).

nexus-storage

Responsabilidad: motor de log append-only (Fase 1). **Tipos clave:** `PartitionLog`, `Segment`, `Index` (`IndexEntry`), `LogConfig`, `Retention`, `LogCompactor`, `FetchResult`; cifrado opcional (`SegmentCipher`, `EncryptionKey`; [ADR-0031](#)); tiering opcional (`StorageTier`, `LocalStorageTier`, `TierObjectKey`; [ADR-0032](#)).

Afinidad: REACTOR-LOCAL (pertenece al reactor dueño de la partición); `StorageTier` es un puerto no-propietario que posee el *composition root* y comparte el nodo. **Invariantes:** `logEndOffset` es monótono; la retención nunca borra el segmento activo; cada `RecordBatch` está protegido por CRC32C verificado al leer/recuperar; con tiering, solo se descargan segmentos sellados y el disco local se reclama **solo tras confirmar** la subida (el tier es la autoridad del prefijo frío, sin manifiesto local).

nexus-reactor

Responsabilidad: modelo de ejecución *thread-per-core* y coordinación entre núcleos. **Tipos clave:** `Reactor`, `ReactorPool`, `SpSCQueue`, `MpmcQueue`, `CrossCore / CrossCoreCall`, `PartitionRouter`, `Scheduler`, `Allocator` (por núcleo), `CacheLine`, `PeriodicTimers`. **Afinidad:** `Reactor` **REACTOR-LOCAL**; las colas y `CrossCore / PartitionRouter` son el puente **CROSS-CORE**. **Invariantes:** un reactor por núcleo, *pinned*; nada bloqueante en el reactor; *head/tail* de cada cola en líneas de caché distintas (`alignas`); SPSC con un único productor/consumidor.

nexus-consensus

Responsabilidad: Raft como máquina de estados sin E/S. **Tipos clave:** `RaftNode` (FSM), `RaftLog`, `RaftState / RaftStateStore`, `RaftRpc`, `RaftWire`, `RaftCarrier`, `*MessageSink` (deferred/null). **Afinidad:** **REACTOR-LOCAL** (la FSM la conduce el portador del reactor dueño). **Invariantes:** la FSM no hace I/O (entradas→cola de salidas, `now` inyectado, [ADR-0015](#)); el estado persistente se guarda **antes** de enviar; el índice de entrada Raft es espacio distinto del offset por record ([ADR-0014](#)).

nexus-cluster

Responsabilidad: transporte inter-nodo de los RPC de Raft (plano separado). **Tipos clave:** `RaftTransport`, `RaftLink`, `RaftReceiver`, `PeerDirectory`. **Afinidad:** **CROSS-CORE**/borde de red (rutea por (topic, partition) al reactor dueño). **Invariantes:** sobre de wire `topic|partition|from|to|type|payload` con longitud-prefijo; plano separado del de cliente ([ADR-0025](#)).

nexus-broker

Responsabilidad: dominio del broker: topics, particiones, grupos, offsets, enrutado. **Tipos clave:** `Topic`, `Partition`, `PartitionBase`, `ReplicatedPartition`, `TopicCatalog`, `TopicManager`, `TopicCluster`, `ConsumerGroup`, `GroupCatalog`, `GroupCoordinator`, `OffsetManager`, `ProducerSession` (idempotencia), `CreditWindow` (backpressure), `RequestRouter`; transacciones (`TransactionCoordinator`, `ProducerIdentity`, `TopicPartition`, `PartitionTxnIndex`, `IsolationLevel`, `AbortedTxn`; [ADR-0033](#)). **Afinidad:** **REACTOR-LOCAL** por partición/grupo (cada uno tiene un único dueño; ver [sharding](#)). **Invariantes:** una partición es la unidad de serialización (estilo *actor*); `leaderEpoch` descarta líderes obsoletos; secuencia idempotente por `producerId` (duplicado/hueco); el `TransactionCoordinator` registra la decisión (`Prepare*`) antes de escribir marcadores (2PC recuperable) y el LSO nunca supera el *high-watermark*.

nexus-kafka

Responsabilidad: subconjunto Kafka-compatible (interop `kcat`). **Tipos clave:** `Codec`, `messages`, `produce`, `fetch`, `metadata`, `list_offsets`, `record_batch` (opaco), `gateway`, `error_code` (Kafka). **Afinidad:** adaptador

asíncrono cross-core sobre el broker vivo ([ADR-0029](#)). **Invariantes:** codec por versión (clásico vs flexible); el `RecordBatch` se almacena **opaco**; los códigos se mapean a los de Kafka en el borde (ver [capítulo 14](#)).

nexus-ingress

Responsabilidad: capa de entrada (dos modos) y plano de control HTTP. **Tipos clave:** `Proxy`, `UpstreamPool`, `Tls`, `RestGateway`, `AdminService`, `CircuitBreaker`, `LoadBalancer`, `HealthMonitor` / `HealthCheck`, `RateLimiter`, `ProblemDetail`, `Jwt`, `Pagination`, `Http / Json`, `ConnectionState`. **Afinidad:** `UpstreamPool`
REACTOR-LOCAL (pool por reactor); el resto, por conexión. **Invariantes:** el modo nativo es el primario; TLS opcional con degradación a claro ([ADR-0019](#)); validación en el borde (*fail-fast*).

nexus-telemetry

Responsabilidad: observabilidad: métricas, logs y *tracing*. **Tipos clave:** `metrics` (exposición Prometheus), `logging` (JSON estructurado), `tracing`. **Afinidad:** **THREAD-SAFE** en la agregación/exposición de métricas. **Invariantes:** sin *logging* síncrono caro en el camino caliente; las métricas cubren las cuatro señales de oro (ver [capítulo 12](#)).

nexus-server

Responsabilidad: *composition root* de `nexusd`; ensambla todo y enruta peticiones. **Tipos clave:** `Server`, `Connection`, `AdminApi` / `AdminHttp` / `AdminRouter`, `KafkaAdapter`, `KafkaConnection`, `main`. **Afinidad:** monta el `ReactorPool`; el `RequestRouter` enruta async al reactor dueño. **Invariantes:** el cableado de dependencias vive aquí, no en el dominio (ver [capítulo 19](#)).

nexus-client

Responsabilidad: librería cliente nativa en C++. **Tipos clave:** `Client`, `Producer`, `Consumer`, `DeadLetter`, `Endpoint`. **Afinidad:** usada por aplicaciones externas; el *smart-client* va directo al líder vía *metadata*. **Invariantes:** reacciona a `NOT_LEADER_FOR_PARTITION` redescubriendo el líder; respeta los créditos de *backpressure*.

nexus-ffi

Responsabilidad: frontera ABI C estable para *bindings* (Python vía `ctypes`). **Tipos clave:** `nexus_ffi.h` (API C), `nexus_ffi.cpp` (implementación). **Afinidad:** **frontera**; traduce entre la ABI C y el cliente C++. **Invariantes:** ABI C estable (no C++), por lo que el binding no necesita `python3-dev` ni recompilación ([ADR-0020](#)).

19. Arranque y composition root

Cómo cobra vida un nodo: `nexusd` como *composition root* donde se cablea todo, su configuración 12-factor y sus puertos. El cableado de dependencias ocurre **aquí**, no en el dominio (clean architecture: separar construcción de uso).

19.1 `nexusd` y el composition root

El ejecutable `nexusd` (`src/server/main.cpp`) es el **composition root**: lee la configuración, construye el `Proactor` adecuado a la plataforma, levanta el `ReactorPool` (un reactor por núcleo), instancia el broker, el stack Raft, el ingress y la telemetría, y los **inyecta por constructor**. Ningún componente de dominio instancia su infraestructura: la recibe ya construida (DIP, ver [inyección de dependencias](#)). En C++ esto se materializa con inyección por **constructor** (interfaz + `unique_ptr`) en los bordes y por **parámetro de plantilla** (polimorfismo estático, coste cero) en los caminos calientes.

19.2 Configuración 12-factor

La configuración entra por **flags de línea de comandos** y variables de entorno (config en el entorno, no en la imagen — [ADR-0008](#)), de modo que **el mismo binario** corre en local o en cloud sin cambios. Los **secretos** (p. ej. el de JWT) van por entorno, nunca horneados (ver [capítulo 27](#)). Flags principales de `nexusd`:

Flag	Propósito
<code>--host</code>	Interfaz de escucha (p. ej. <code>0.0.0.0</code>).
<code>--port</code>	Puerto del plano de datos (cliente nativo; <code>9092</code> por convención).
<code>--admin-port</code>	Puerto del plano de operación (REST admin + salud + métricas; <code>9644</code>).
<code>--kafka-port</code>	Puerto del listener Kafka (subset; opcional).
<code>--data-dir</code>	Directorio de datos (logs de partición).
<code>--node-id</code>	Identificador del nodo en el cluster.
<code>--topic</code>	<i>Topic</i> inicial, formato <code>nombre:particiones</code> (p. ej. <code>demo:3</code>).
<code>--jwt-secret</code>	Activa la autenticación JWT en <code>/api/v1/*</code> (si se omite, REST sin auth).
<code>--tls-cert</code>	Cadena de certificado PEM del servidor; con <code>--tls-key</code> activa TLS en el plano de datos (ADR-0019).
<code>--tls-key</code>	Clave privada PEM del servidor (pareja de <code>--tls-cert</code>).
<code>--encryption-key</code>	KEK (256 bits, 64 hex) del cifrado en reposo del log; preferible por env <code>NEXUS_ENCRYPTION_KEY</code> (no aparece en <code>ps</code>). Si se omite, log en claro (ADR-0031).

Los nombres y valores por defecto son contrato operativo; el catálogo completo de configuración (retención, `segment.bytes`, política de `fsync`, etc.) vive en el [capítulo 26](#).

19.3 Puertos y planos

`nexusd` separa los planos también en puertos (ver [diagrama 15](#)):

- **Plano de datos / cliente** (`--port`): *produce/fetch* por el protocolo binario.
- **Plano Kafka** (`--kafka-port`): subset Kafka, interop `kcat` .
- **Plano de operación** (`--admin-port`): REST `/api/v1` , `/healthz` , `/readyz` , `/metrics` .
- **Plano inter-nodo Raft**: RPC de consenso entre réplicas, por su transporte separado ([ADR-0025](#)).

19.4 Arranque, afinidad y apagado limpio

En el arranque, cada reactor se **fija a su núcleo** (afinidad). El port a Windows hace esto y las señales **por plataforma** ([ADR-0028](#)): `make_default_proactor` selecciona `io_uring` o `IOCP`; la afinidad usa la API de cada SO (`SetThreadAffinityMask` en Windows). El **apagado limpio** atiende `SIGTERM` / `SIGINT` (`SetConsoleCtrlHandler` en Windows) para **drenar** el trabajo en curso y cerrar recursos antes de salir; en el camino crítico solo se usan funciones *async-signal-safe* (despertar el bucle vía *self-pipe*/ `eventfd`).

20. Herramientas y bindings

Lo que rodea al servidor: la CLI de operación, los generadores de carga y *benchmark*, el arnés de verificación de Windows y el *binding* de Python. Son piezas de soporte, no del camino caliente, pero esenciales para operar, medir y demostrar el sistema.

20.1 `nexus-cli`

CLI de administración y diagnóstico. Habla con el **plano de operación** (REST `/api/v1`) y/o el plano de datos: crea/lista/describe/borra *topics*, lista grupos de consumidores y produce/ consume de forma puntual. Acepta un *token Bearer* (`--token`) cuando el nodo arranca con `--jwt-secret` . Es el camino humano equivalente a las llamadas REST del [capítulo 15](#). Con `--help / -h / help` (en cualquier posición) imprime el uso y termina con **código 0**; invocada sin argumentos también muestra el uso (con código 1), y un comando u opción desconocidos imprimen el uso por *stderr* y terminan con error.

20.2 `nexus-bench`

Microbenchmarks reproducibles (Google Benchmark) sobre el núcleo —principalmente el *storage engine*— para medir el coste de operaciones concretas (append, lectura, CRC32C, codificación). Se usa para establecer **líneas base** y comparar antes/después de una optimización, con la metodología del [capítulo 23](#).

20.3 `nexus-loadgen`

Generador de carga *end-to-end* contra un nodo/cluster vivo, sobre el cliente nativo (`nexus-client`). Parámetros típicos: `--connections` , `--rate` , `--count` , `--payload` , `--warmup` , `--topic` , `--partition` . Es **open-loop** (tasa fija, independiente de las respuestas) para **evitar la *coordinated omission*** y medir la latencia de cola real bajo una carga representativa (ver [capítulo 23](#)).

20.4 `wincheck`

Arnés de verificación **Windows-only** que confirma el backend IOCP en runtime ([ADR-0023](#)): comprueba `File` (bloqueante y directa), un eco IOCP por *loopback* end-to-end con cierre limpio, y `submit_timer` . Los cuatro casos pasan con MSVC (VS 2026, `/W4 /WX`); fue la herramienta que cerró la deuda de runtime del port a Windows.

20.5 Binding de Python (`nexus-ffi` + `ctypes`)

El *binding* de Python no usa pybind11 sino una **ABI C estable** ([ADR-0020](#)): `nexus-ffi` expone una API en C (`nexus_ffi.h`) compilada como librería **SHARED**, y el lado Python la carga con `ctypes` (en `bindings/python/`). Ventajas: el binding **no necesita `python3-dev`** ni recompilarse contra cada versión de Python (que era el motivo de descartar pybind11), y la frontera C es estable y portable. La ABI C envuelve al cliente nativo (`nexus-client`), de modo que Python produce y consume hablando el mismo protocolo que un cliente C++.

21. Estrategia de pruebas

Cómo se gana confianza en NexusMQ: TDD como base, y un arsenal específico para código de sistemas, concurrente y distribuido. Las pruebas son **código de primera clase**; el no-determinismo se **inyecta**, no se tolera.

21.1 TDD y organización

El desarrollo sigue **TDD** (rojo→verde→refactor) sobre la lógica de dominio, con GoogleTest y nombres `Metodo_Escenario_ResultadoEsperado`. La suite vive en `tests/`, organizada por tipo:

Carpeta	Qué cubre
<code>tests/unit/</code>	Pruebas unitarias por subsistema (una carpeta por librería: <code>common</code> , <code>storage</code> , <code>reactor</code> , <code>consensus</code> , <code>protocol</code> , <code>broker</code> , <code>kafka</code> , <code>ingress</code> , <code>io</code> , <code>wire</code> , <code>telemetry</code> , <code>server</code> , <code>client</code> , <code>ffi</code> , <code>cli</code> , <code>bench</code> , <code>loadgen</code> , <code>cluster</code>).
<code>tests/sim/</code>	Simulación determinista de Raft (<code>raft_sim</code>).
<code>tests/crash/</code>	<i>Crash testing</i> (<code>partition_crash_test</code>).
<code>tests/e2e/</code>	Extremo a extremo: broker, cliente, cluster, admin HTTP, CLI, loadgen.
<code>tests/support/</code>	<i>Helpers</i> : <code>fake_proactor</code> (proactor virtual) y <code>test_certs</code> .

21.2 Property-based y fuzzing

- **Property-based**: en serialización se afirman **invariantes** sobre entradas generadas —el *round-trip* `decode(encode(x)) == x` del `Record` / `RecordBatch` y del codec del protocolo—, con *shrinking* al contraejemplo mínimo.
- **Fuzzing**: los parsers de **entrada no confiable** (frames del protocolo, `RecordBatch`, subset Kafka) se alimentan con datos aleatorios/guiados por cobertura para descubrir *panics*, UB y desbordes. Es obligatorio en todo lo que parsea formato externo.

21.3 Simulación determinista (la pieza clave)

El núcleo de Raft es una **máquina de estados sin E/S** ([ADR-0015](#)), y eso es precisamente lo que permite probarlo de forma **determinista**: en `tests/sim/` se inyecta un **reloj virtual** y una **red virtual** (con `fake_proactor`), y se reproducen *timing*, elecciones de líder y particiones de red de forma **repetible**. Así el consenso cumple **FIRST** (determinismo/independencia) sin *flakiness*: una prueba *flaky* es un bug —de la prueba o del diseño—, no algo tolerable. El no-determinismo se controla **inyectándolo**.

El mismo patrón cubre el **exactly-once transaccional** ([ADR-0033](#)): `tests/sim/transaction_sim.hpp` monta el `TransactionCoordinator` (FSM sin E/S) sobre particiones en memoria con reloj virtual y RNG sembrado, y ejercita el 2PC de punta a punta —init/begin/produce/commit/abort → marcadores → visibilidad `read_committed` — con **entrega parcial de marcadores** y **failover del coordinador**. Los escenarios verifican las invariantes de atomicidad (un commit hace visible **toda** la data; un abort, **ninguna**; una transacción abierta queda retenida por el LSO) e incluyen un **caos** de 300 transacciones con commit/abort aleatorios y

failovers, donde al final se ve **exactamente** el conjunto confirmado. Este arnés destapó y fijó un fallo real de *fencing* en el coordinador.

21.4 Crash y caos

- **Crash testing** (`tests/crash/`): se mata el proceso a mitad de escritura (`kill -9`) y se verifica la **recuperación** —validación de CRC y truncado de la cola *torn*— y que no se pierden datos *committed*.
- **Chaos** (local, sin coste): particionar la red (`tc netem`), limitar recursos (`cgroups`) y matar nodos para verificar *failover* e invariantes tras el fallo ([ADR-0008](#)).

21.5 Sanitizers y detección de carreras

Toda la suite se ejecuta también bajo **sanitizers** (ASan/UBSan), que convierten bugs latentes (UB, accesos fuera de rango, fugas) en fallos visibles. Para el código concurrente —las colas lock-free SPSC/MPMC— se usa **ThreadSanitizer + estrés aleatorio**, porque las carreras no aparecen en pruebas deterministas de un solo hilo. Estos pasos forman parte de la **puerta de calidad** (ver [capítulo 22](#)).

22. Puerta de calidad y CI/CD

Lo que tiene que estar verde antes de cada *commit*. La puerta es **obligatoria** y se ejecuta en local; el CI la replica. Nunca se *pushea* en rojo.

22.1 Los dos compiladores

Todo compila y pasa la suite en **GCC/libstdc++** y **Clang/libc++**. No es redundante: los dos *toolchains* **divergen** en puntos sensibles —en especial `std::expected` y las versiones de `clang-tidy`—, así que un cambio que pasa en uno puede romper en el otro. Clang **requiere libc++** (`-stdlib=libc++`): el `<expected>` de `libstdc++` no compila con Clang por `__cpp_concepts` ([ADR-0011](#)).

```
cmake --preset linux-gcc && cmake --build --preset linux-gcc && ctest --preset linux-gcc
cmake --preset linux-clang && cmake --build --preset linux-clang && ctest --preset linux-clang
```

22.2 Sanitizers, formato y análisis estático

- **Sanitizers:** la build de pruebas corre bajo **ASan/UBSan** (`linux-gcc-asan`) y **ThreadSanitizer** (`linux-gcc-tsan`) para el código concurrente.
- **Formato:** `clang-format --dry-run --Werror` sobre todo `*.hpp / *.cpp` (sin salida = ok).
- `clang-tidy` (autoridad de convenciones) sobre `src/`, con el preset `Clang/libc++`. El `.clang-tidy` versionado manda; sus checks desactivados son **decisiones de proyecto** (`pragma-once`; `pro-bounds-*` / `pro-type-vararg` para búferes de bytes y POSIX variádico; `magic-numbers...`). Se aplica solo a `src/` porque tests y *bench* usan macros de terceros.
- `cppcheck` como análisis estático complementario.
- `-Wall -Wextra -Wpedantic -Werror`: un aviso es un bug en potencia.

22.3 El pipeline de CI

El CI (GitHub Actions, `.github/workflows/ci.yml`) replica la puerta en varios *jobs*:

- **build & test** en matriz [`linux-gcc`, `linux-clang`] (configurar → compilar con *warnings-as-errors* → `ctest`).
- **sanitizers** (ASan/UBSan, `linux-gcc-asan`).
- **ThreadSanitizer** (`linux-gcc-tsan`) para las colas lock-free.

El gate de CI **no es solo build+test**: incluye lint, formato y sanitizers; todo debe pasar.

Estado actual: las GitHub Actions están **desactivadas temporalmente** (cuota); el workflow está versionado como `ci.yml.disabled` y se reactivará al publicar. Mientras tanto, la puerta de calidad se ejecuta **en local** antes de cada *push*.

22.4 Build-once, promote

El artefacto se **construye una sola vez** y se promueve el **mismo binario** entre entornos (dev → staging → prod), sin recompilar por entorno: la diferencia es la **configuración** (12-factor), no el binario (ver [capítulo 19](#) y [ADR-0008](#)). Es coherente con la imagen Docker reproducible del [capítulo 25](#).

23. Rendimiento y benchmarks

Cómo se mide NexusMQ sin engañarse. Este capítulo **explica la metodología**; las cifras concretas y su entorno son contrato y viven en [docs/benchmarks.md](#) — no se reproducen aquí para no duplicar ni desincronizar.

23.1 Principios de medición

- **Mide, no adivines.** Primero correcto y claro; se optimiza **con datos** y solo el cuello de botella dominante (ley de Amdahl). No se micro-optimiza el código frío.
- **Objetivos en percentiles, no en medias.** Se reporta **p50/p99/p999/max**: la media oculta la *long tail* que sufre el usuario peor servido. Se fija un **SLO** de latencia explícito.
- **Baseline + un cambio cada vez.** Sin línea base no hay mejora demostrable; cambiar varias cosas a la vez impide atribuir el efecto.
- **Perfila antes de tocar** (CPU profiler, *flame graphs*) para localizar el *hot path* real.

23.2 Evitar la *coordinated omission*

El error de medición más traicionero. Un cliente **closed-loop** (que espera cada respuesta antes de enviar la siguiente) **subestima la cola** cuando el sistema se satura: deja de enviar justo las peticiones que más tardarían. Por eso NexusMQ mide con un generador **open-loop** (`nexus-loadgen` , ver [capítulo 20](#)): **tasa fija**, independiente de las respuestas, a una carga representativa (no al throughput máximo, que no dice nada de la latencia de cola). Los histogramas son de alta resolución (estilo **HdrHistogram**). El detalle está en [docs/benchmarks.md](#) .

23.3 Qué se mide

- **Throughput** de *produce/fetch* (msg/s y MiB/s) a *batch* y `acks` dados.
- **Latencia** de *produce* (`acks=1` y `acks=quorum`) y de *fetch*, por percentiles.
- **Impacto del `fsync`** (agrupado vs por escritura) y de la replicación de quórum.
- **Lectura** desde *page cache/mmap* vs disco.
- **Microbenchmarks** del núcleo (append, CRC32C, codec) con `nexus-bench` .

Se sigue el **método USE** (utilización, saturación, errores) por recurso (CPU, memoria, disco, red) y se tiene en cuenta el *observer effect*: la propia observabilidad tiene coste.

23.4 Throughput $\neq$ latencia, y escalabilidad

Throughput y latencia se optimizan distinto y a veces se oponen (el *batching* sube throughput pero puede subir latencia). En escalabilidad, la fracción serie pone el techo (Amdahl) y la contención puede **empeorar** al añadir núcleos (USL): por eso el diseño *shared-nothing* reduce la sección crítica a (idealmente) cero —cada partición la sirve su único reactor— antes de añadir núcleos (ver [capítulo 7](#)).

23.5 Entorno y reproducibilidad

Las cifras se toman **en local**, con *hardware* y parámetros documentados (núcleos aislados con `isolcpus / taskset`), nunca en *free tiers* de cloud —que no sirven para medidas serias ([ADR-0008](#))—. El procedimiento exacto de reproducción y los resultados están en [docs/benchmarks.md](#).

24. Portabilidad

Linux primero, Windows después —pero de verdad—. El objetivo primario es **Linux x86-64**; el port a Windows recorrió tres niveles de verificación hasta funcionar en runtime con MSVC.

24.1 Una abstracción pensada para portar

La portabilidad se diseñó desde el principio, no se parcheó al final: la I/O se modela como **proactor** (*completions*), la forma común a **io_uring** (Linux) e **IOCP** (Windows) ([ADR-0002](#)). El núcleo es independiente de plataforma tras ese puerto; cambiar de SO es cambiar de **adaptador** (`io_uring_backend` ↔ `iocp_backend`) y de *preset* (`linux-gcc` / `linux-clang` ↔ `windows-msvc` / `windows-clang-cl`), sin reestructurar. Los tipos portables `NativeHandle` / `IoResult` aíslan el resto.

24.2 Tres niveles de "funciona"

El port a Windows hace explícita una distinción que suele pasarse por alto —**compila ≠ funciona**— recorriéndola por estados (cadena de ADR):

Nivel	Qué garantiza	Hito
Diseño	El backend está diseñado (<code>iocp_backend.hpp</code> , <code>preset windows-msvc</code>); implementación diferida.	ADR-0021
Compile-verified	Compila con headers Win32 reales (MinGW-w64); <code>File</code> / <code>Socket</code> / <code>Listener</code> Win32+Winsock, <code>IoctlBackend</code> sobre <code>GetQueuedCompletionStatusEx</code> / <code>AcceptEx</code> .	ADR-0022
Runtime-verified	Funciona en Windows real con MSVC (VS 2026, <code>/W4</code> / <code>WX</code>): arnés <code>wincheck</code> con <code>File</code> (bloqueante+directa), eco IOCP por <code>loopback</code> y <code>submit_timer</code> — 4/4 PASAN.	ADR-0023

El valor real llegó al **verificar en runtime**: compilar no demostraba que el ciclo *submit*→*completion* funcionara de extremo a extremo.

24.3 Port completo de `nexusd`

[ADR-0028](#) amplía el alcance de "solo `nexus-io` " a `nexusd` **completo** en Windows: backend, **afinidad y señales** por plataforma. `make_default_proactor` elige `io_uring` o IOCP; la afinidad usa la API de cada SO (`SetThreadAffinityMask`); el apagado limpio atiende las señales equivalentes (`SetConsoleCtrlHandler`). Así el servidor entero —no solo la capa de I/O— corre en ambos SO.

24.4 Diferencias por compilador

Portar no es solo el SO, también el **compilador**. El único arreglo de fondo que necesitó el runtime de Windows fue `crc32c.cpp` : GCC/Clang usan *builtins* para detectar e invocar las instrucciones de CRC de SSE4.2; MSVC necesita `__cpuid` + los **intrínsecos** SSE4.2 explícitos. La detección de *CPU features* y su uso se seleccionan con `#if` por compilador, manteniendo un *fallback* software portable. Es un recordatorio de que las mismas instrucciones hardware se expresan distinto en cada *toolchain* —el mismo motivo por el que el proyecto compila siempre en los **dos compiladores** (ver [capítulo 22](#)).

25. Despliegue

Cómo se empaqueta y se levanta NexusMQ: imagen Docker reproducible, un cluster local con docker-compose y un despliegue con estado en Kubernetes. Los artefactos reales viven en [deploy/](#).

25.1 Imagen Docker

La imagen sigue las buenas prácticas (`deploy/Dockerfile`):

- **Build multi-stage:** una etapa compila con el `toolchain C++` y otra ejecuta sobre una **base mínima/distroless**, copiando solo el binario.
- **Usuario no-root** (UID/GID `65532`, `distroless nonroot`): limita el impacto de una intrusión.
- **HEALTHCHECK** cableado a `/readyz` (el plano de operación): el runtime reinicia instancias que no responden de verdad.
- **Tags de versión explícitos** (no `latest` en producción), `.dockerignore` para no copiar artefactos de build, y **secretos por variables de entorno**, nunca horneados.
- Se construye **una sola vez** y se promueve el mismo binario entre entornos (ver [capítulo 22](#)).

25.2 Cluster local con docker-compose

`deploy/docker-compose.yml` levanta el entorno de referencia en una sola máquina (ver [diagrama 21](#)):

- **3 nodos** `nexus1 / nexus2 / nexus3` (imagen `nexusmq:dev`), cada uno con `--port 9092` (plano de datos) y `--admin-port 9644` (operación), `--data-dir /var/lib/nexusmq`, `--node-id` y un `topic` de demo (`--topic demo:3`). Los puertos se exponen sin solapar (`9092/9093/9094` datos; `9644/9645/9646` operación) y cada nodo tiene su **volumen** persistente.
- **Prometheus** (`:9090`) scrapea `/metrics` de los tres nodos.
- **Grafana** (`:3000`) con `datasource` Prometheus aprovisionado.

El cluster de 3 nodos es suficiente para Raft, quórum y *failover* ([ADR-0008](#)). El runtime de cluster multi-nodo (descubrimiento de líder, replicación entre nodos) llegó en fases posteriores; el compose sirve además para validar el empaquetado, la observabilidad y los *probes* sobre varias instancias.

25.3 Kubernetes

`deploy/k8s/` despliega NexusMQ como **StatefulSet** —el broker tiene estado persistente (los logs de partición)— con `volumeClaimTemplates` (un PVC por réplica) y un **Service headless** para DNS estable (`nexusmq-0.nexusmq`, etc.), que es como las réplicas se descubren entre sí (ver [diagrama 22](#)). Detalles:

- **3 réplicas**, `securityContext no-root` (`runAsUser/Group/fsGroup 65532`).
- **Probes** *liveness/readiness* contra el puerto de operación (`/healthz`, `/readyz`).
- Se asumen **límites de CPU/memoria** por pod y un nodo con soporte de **io_uring**.
- **Secretos por entorno**, nunca en la imagen: el secreto de JWT y —si se activa el cifrado en reposo ([ADR-0031](#))— la **KEK** se inyectan como `Secret` montado en `NEXUS_ENCRYPTION_KEY` (`--encryption-key` la

expondría en la línea de proceso). La KEK debe ser **la misma** en toda réplica y a lo largo de reinicios/restores, o los segmentos cifrados quedan ilegibles (ver [capítulo 26](#)).

- **Tiered storage** (opcional, [ADR-0032](#)): si se activa con `--tier-dir / NEXUS_TIER_DIR`, el directorio del tier debe apuntar a un almacén **durable independiente del PVC de datos** —hoy un volumen (p. ej. un PVC compartido o un montaje de objetos), mañana un bucket S3 sobre el mismo puerto `StorageTier` —, porque es la copia autoritativa de los segmentos fríos. Sin el flag, no se descarga nada.

`docker-compose` es para local/dev; Kubernetes, cuando se necesita escala, *self-healing* y orquestación real.

25.4 Cloud-ready, sin coste obligatorio

El diseño es *cloud-ready* (imagen Docker, configuración 12-factor) de modo que el **mismo binario** corre en local o en cloud sin cambios. Una demo desplegada es cubrible con *free tiers* (AWS/Azure/Oracle Always Free) bajo demanda, pero **no es necesaria** para desarrollar, probar ni medir, que se hacen en local sin coste ([ADR-0008](#)).

26. Configuración y operación

Operar un nodo en marcha: cómo se configura, qué puertos usa, qué se observa y qué hacer cuando algo va mal. La configuración es 12-factor (entorno, no imagen).

26.1 Puertos

Plano	Flag	Puerto (convención)
Datos / cliente nativo	<code>--port</code>	9092
Operación (REST <code>/api/v1</code> , <code>/healthz</code> , <code>/readyz</code> , <code>/metrics</code>)	<code>--admin-port</code>	9644
Subset Kafka (interop <code>kcat</code>)	<code>--kafka-port</code>	opcional
Inter-nodo Raft (consenso)	—	transporte interno

26.2 Configuración

Por **flags** y variables de entorno (mismo binario en todos los entornos). Además de los flags de arranque (`--host`, `--node-id`, `--data-dir`, `--topic nombre:particiones`, `--jwt-secret`; ver [capítulo 19](#)), el comportamiento del log y la durabilidad se gobierna por **política** (mecanismo vs política): retención (`retention.ms` / `retention.bytes`), tamaño de segmento (`segment.bytes` / `segment.ms`), compactación, compresión (none/LZ4/Zstd) y política de `fsync` (cada N mensajes / N ms / por *commit*). Borrar un *topic* (`DELETE /api/v1/topics/{name}`) elimina sus datos en disco (el `.log` / `.index` de todas sus particiones) y **recupera el espacio**; no queda estado que "resucite" al re-declarar el nombre. Los **secretos** (p. ej. el de JWT) van por entorno, nunca en la imagen ni en el repositorio (ver [capítulo 27](#)).

Cifrado en reposo (opcional). La KEK de 256 bits se pasa como **64 dígitos hex** por `NEXUS_ENCRYPTION_KEY` (preferido: no aparece en `ps`) o `--encryption-key HEX` (el flag tiene prioridad); sin ella, el log se escribe en claro. Si la clave es inválida, el arranque **aborta** (no degrada en silencio). La KEK **nunca** se persiste ni se commitea; su gestión (generación, custodia, rotación) es responsabilidad del operador vía gestor de secretos. Ver [capítulo 9](#) y [ADR-0031](#).

Almacenamiento por niveles (opcional). Con `--tier-dir RUTA` (o `NEXUS_TIER_DIR`) el broker **descarga los segmentos sellados fríos** a ese directorio objeto y reclama el disco local, sirviendo las lecturas frías por rehidratación transparente (ver [capítulo 9](#), [ADR-0032](#)). Sin el flag, el broker no descarga nada y se comporta como hasta ahora. El directorio del tier debe ser un almacén **durable y distinto del disco de datos** (un montaje de objetos, un volumen compartido; en producción, el punto de evolución hacia S3): es la copia autoritativa de los segmentos fríos, así que su pérdida es pérdida de datos. Si el log va cifrado ([ADR-0031](#)), el tier guarda el **ciphertext tal cual** —basta la misma KEK para leerlo, la clave nunca viaja al tier—.

26.3 Observabilidad en operación

- **Métricas:** `GET /metrics` (Prometheus) — throughput, latencias por percentil, *lag* de consumidores, estado de Raft, créditos de *backpressure*.

- **Dashboards:** Grafana *self-hosted* con *datasource* Prometheus aprovisionado (`deploy/grafana/`), siguiendo las cuatro señales de oro (latencia, tráfico, errores, saturación). Ver [capítulo 12](#) y [diagrama 23](#).
- **Salud:** `/healthz` (liveness) y `/readyz` (readiness: disco/Raft/*lag*), usados por los *probes* y el `HEALTHCHECK` .

26.4 Runbook (esbozo)

- **Arranque/parada:** `docker compose up --build` (local). El apagado atiende `SIGTERM` / `SIGINT` y **drena** el trabajo en curso antes de salir.
- **Backup:** un *snapshot* de `--data-dir` por nodo. **Restore:** arrancar desde ese `data.dir` . Si el log está **cifrado** (ADR-0031), el backup contiene solo ciphertext: hay que restaurar el nodo con **la misma KEK**; sin ella los segmentos son ilegibles (perder la KEK = perder los datos). Con **tiered storage** (ADR-0032), el backup debe cubrir **también** el `--tier-dir` : los segmentos fríos ya no están en `--data-dir` y el tier es su copia autoritativa.
- **Recuperación tras *crash*:** automática al arrancar (validación de CRC + truncado de la cola *torn*); el nodo queda listo en pocos segundos (ver [capítulo 9](#)).
- **Pérdida de quórum (p. ej. 2 de 3 nodos caídos):** por la postura **CP**, las particiones afectadas quedan **no disponibles para escritura** y se recuperan al restaurar nodos. Forzar progreso sin quórum solo mediante un procedimiento **manual y documentado** de *unsafe-recovery* (asume riesgo de pérdida).
- **Rotación de certificados TLS:** recarga en caliente si está disponible, o *rolling restart*.
- **Escalado:** *thread-per-core* escala con el número de núcleos del nodo; el cluster, añadiendo nodos/particiones (la asignación partición→núcleo es `partition % N` , ver [capítulo 7](#)).

27. Seguridad

La postura de seguridad de NexusMQ: cifrado en tránsito, autenticación del plano de control, validación en el borde y mínimo privilegio. Se apoya en la normativa de seguridad de la `BibliotecaDocumentacion` (OWASP, defensa en profundidad).

27.1 Cifrado en tránsito (TLS)

- **TLS 1.3 en el borde:** terminación en la capa de *ingress* mediante OpenSSL con un puente de **BIOs de memoria** sobre el proactor ([ADR-0019](#), ver [capítulo 11](#) y [diagrama 20](#)). La dependencia es **opcional**: si OpenSSL no está, el nodo degrada a texto en claro (útil en dev), pero en redes no confiables **TLS es obligatorio** y los certificados se **validan**.
- **mTLS intra-cluster (contemplado):** ambos extremos presentan y validan certificado, dando identidad criptográfica a cada nodo del plano inter-nodo. Conviene **rotar** los certificados (vida corta, emisión automatizada).

27.2 Autenticación y autorización

- **AuthN ≠ AuthZ.** El plano de control (REST `/api/v1`) se autentica con **Bearer JWT** (HS256), exigido solo si el nodo arranca con `--jwt-secret`; sin token válido → `401` (ver [capítulo 15](#)). Los tokens se validan (firma, expiración).
- **Autorización por recurso** en el servidor, en cada petición (no por ocultar acciones en el cliente). El plano de salud/métricas queda sin auth a propósito, para las sondas y el *scraper*.

27.3 Validación en el borde

Nunca se confía en la entrada del cliente. Todo dato externo —frames del protocolo, RecordBatch, peticiones Kafka, JSON de la REST— se **valida en el borde** (*fail-fast*) contra límites explícitos antes de entrar al núcleo: tamaño máximo de mensaje/*batch* (`MESSAGE_TOO_LARGE`), versiones de API soportadas, y **límites de descompresión** para evitar *decompression bombs* (un *batch* que se expande desmesuradamente). El núcleo asume datos ya válidos (ver [capítulo 16](#)).

27.4 Mínimo privilegio y secretos

- **Usuario no-root** en la imagen y en Kubernetes (UID/GID `65532`), para limitar el impacto de una intrusión (ver [capítulo 25](#)).
- **Secretos por variables de entorno** (o gestor de secretos), **nunca** horneados en la imagen ni commiteados al repositorio; si un secreto se filtra, se **rota** (no basta con borrarlo).
- **Defensa en profundidad:** varias capas (TLS, JWT, validación, aislamiento de proceso), cada componente con los permisos justos, asumiendo que una capa fallará.
- **Mensajes de error sin detalles internos** hacia el exterior (códigos de wire / RFC 7807), para no filtrar información sensible.

27.5 Cifrado en reposo (log)

- **AEAD AES-256-GCM sobre el log**, opcional y con **degradación limpia** ([ADR-0031](#), ver [capítulo 9](#)). Sin clave configurada, o sin OpenSSL, el broker escribe el log **en claro** y se comporta como hasta ahora; con clave, cada `RecordBatch` se persiste cifrado. Reutiliza la dependencia OpenSSL ya presente para TLS (`NEXUS_HAVE_OPENSSL`).
- **KEK por entorno/config, jamás en el repo**. La clave maestra (256 bits) llega por `NEXUS_ENCRYPTION_KEY` (preferido, no aparece en `ps`) o `--encryption-key HEX`; si es inválida, el arranque **aborta** en vez de degradar en silencio a texto plano. La KEK no se persiste: solo deriva, vía **HKDF-SHA256** con una *salt* aleatoria por segmento, una **DEK** distinta por segmento (acota el radio de daño y el número de cifrados por clave).
- **Granularidad por bloque de escritura** (= un `RecordBatch`), nunca por record. **Nonce aleatorio de 96 bits por bloque** (robusto ante el ciclo truncar→re-append del log Raft; la reutilización de un nonce con la misma clave sería catastrófica en GCM: es la **invariante nº 1**). El **tag GCM** autentica cada bloque y sus metadatos de traversal en claro (`base_offset / record_count`), de modo que la lectura por offset funciona **sin descifrar** y toda manipulación se detecta al abrir.
- **Gestión de la KEK a cargo del operador** (gestor de secretos externo). Perderla = perder los datos; filtrarla = perder la confidencialidad. La **rotación de claves** es trabajo futuro documentado (ver [capítulo 30](#)); el formato ya reserva *salt* e identificadores por segmento para soportarla.

27.6 Fuera de alcance

- **Multi-tenancy y ACLs avanzadas** no se abordan en las fases actuales (ver [capítulo 30](#)).
- **Rotación de la clave maestra** de cifrado en reposo (el formato está preparado; la operación de re-cifrado queda como evolución futura).

28. Registro de decisiones (ADR)

Este capítulo es la puerta de entrada al **registro de decisiones de arquitectura** (ADR) de NexusMQ: explica qué es un ADR, la regla de inmutabilidad que rige su ciclo de vida, y ofrece el **índice completo** de los 34 ADR del proyecto, agrupados por tema. Las decisiones íntegras viven en el directorio `../adr/`, una por fichero.

28.1 Qué es un ADR

Un *Architecture Decision Record* (ADR) documenta **una** decisión de arquitectura: la fuerza o problema que la motiva (*Contexto*), lo que se decide (*Decisión*), los efectos positivos y negativos que se aceptan (*Consecuencias*) y las opciones descartadas con su porqué (*Alternativas consideradas*). El valor de un ADR no es la decisión en sí, sino el **rastro del razonamiento**: por qué se eligió esto y no aquello, qué se sacrificó y bajo qué supuestos. Es la pieza de portfolio que evidencia el **criterio de ingeniería**, no solo el resultado.

Cada ADR de NexusMQ sigue la plantilla común (*Contexto · Decisión · Consecuencias · Alternativas consideradas*) y conserva su **estado** y su **fecha**. Cada decisión vive en un fichero individual `adr-NNNN-titulo-corto.md` bajo `../adr/`.

28.2 La regla de inmutabilidad

Una decisión `aceptado` **no se edita**. Si la realidad obliga a cambiarla, no se modifica el ADR existente: se **escribe uno nuevo** que la reemplaza, y el antiguo pasa al estado *reemplazado por adr-NNNN*. La historia de decisiones es inmutable, igual que la historia de git: poder leer la decisión vieja —y por qué se superó— es tan valioso como leer la nueva.

En NexusMQ esto produce una **cadena de reemplazo** visible en el backend de I/O de Windows (IOCP), que se diseñó y verificó en tres pasos sucesivos:

ADR-0021 (diseño fijado, implementación diferida) → **ADR-0022** (implementado, compile-verificado con MinGW) → **ADR-0023** (verificado en runtime con MSVC).

Cada eslabón cae cuando una premisa se demuestra falsa: ADR-0021 asumía que el backend «no era verificable en este entorno»; resultó que el contenedor **sí** podía instalar el cross-compiler MinGW-w64 (ADR-0022), y finalmente se **ejecutó** en una máquina Windows real (ADR-0023). La cadena documenta esa progresión sin reescribir el pasado.

28.3 Índice de los 34 ADR

ADR	Título	Estado	Fecha
0001	Plataforma de desarrollo y <i>target</i> (Linux primero, Windows después)	aceptado	2026-06-07
0002	Modelo de I/O asíncrona (proactor; io_uring primero, IOCP después)	aceptado	2026-06-07
0003	Modelo de replicación (Raft por partición)	aceptado	2026-06-07
0004	Protocolo del plano de datos (binario propio + gateway REST)	aceptado	2026-06-07
0005	Arquitectura de concurrencia (<i>shared-nothing thread-per-core</i>)	aceptado	2026-06-07
0006	Rol del <i>ingress</i> (dos modos: nativo directo + proxy/REST)	aceptado	2026-06-07
0007	Postura de consistencia (CP / PACELC PC-EC)	aceptado	2026-06-07
0008	Viabilidad de coste cero (desarrollo y test gratuitos)	aceptado	2026-06-07
0009	Política de manejo de errores por capa	aceptado	2026-06-10
0010	Entorno de desarrollo (VS Code sobre WSL)	aceptado	2026-06-11
0011	Estándar C++23 + libc++ en Clang (para <code>std::expected</code>)	aceptado	2026-06-11
0012	Backend io_uring directo sobre el uapi del kernel (sin liburing)	aceptado	2026-06-12
0013	Capa <code>nexus-wire</code> para el framing sobre conexión	aceptado	2026-06-13
0014	Modelo del log de Raft (índice = ordinal de entrada; término en sidecar)	aceptado	2026-06-14
0015	RaftNode como máquina de estados síncrona sin E/S	aceptado	2026-06-14
0016	<code>ReplicatedPartition</code> como tipo paralelo a <code>Partition</code>	aceptado	2026-06-15
0017	Target <code>nexus-telemetry</code> para observabilidad	aceptado	2026-06-17
0018	REST admin por puerto/adaptador (<code>AdminService</code> / <code>AdminApi</code>)	aceptado	2026-06-18
0019	TLS opcional vía OpenSSL con puente de BIOs de memoria	aceptado	2026-06-19
0020	<i>Binding</i> de Python vía ABI C estable (<code>nexus-ffi</code> + <code>ctypes</code>)	aceptado	2026-06-20

ADR	Título	Estado	Fecha
0021	Backend IOCP (Windows) — diseño fijado, implementación diferida	reemplazado por adr-0022	2026-06-20
0022	Backend IOCP (Windows) — implementado, compile-verificado con MinGW	reemplazado por adr-0023	2026-06-20
0023	Backend IOCP (Windows) — verificado en runtime con MSVC	aceptado	2026-06-20
0024	Compactación del log de Raft por snapshot	aceptado	2026-06-20
0025	Activación en producción del stack Raft + multi-reactor (transporte inter-nodo)	aceptado	2026-06-21
0026	Sharding por núcleo del plano de datos (partición→núcleo, grupos por hash)	aceptado	2026-06-21
0027	Cableado del modo proxy — <i>pool</i> de conexiones aguas arriba por reactor	aceptado	2026-06-25
0028	Port completo de <code>nexusrd</code> a Windows (backend, afinidad y señales)	aceptado	2026-06-27
0029	Adaptador Kafka asíncrono cross-core sobre el broker vivo	aceptado	2026-06-28
0030	Partición mono-protocolo — guarda cross-protocol nativo/Kafka	aceptado	2026-07-09
0031	Cifrado en reposo del log con AES-256-GCM y framing AEAD por bloque	aceptado	2026-07-12
0032	Almacenamiento por niveles — puerto <code>StorageTier</code> y tier local	aceptado	2026-07-12
0033	Exactly-once multi-partición nativo (transacciones, coordinador y <code>read_committed</code>)	aceptado	2026-07-12
0034	2PC logueado y recuperable (reconciliación con la prohibición del 2PC bloqueante)	aceptado	2026-07-12

28.4 ADR agrupados por tema

Los 34 ADR cubren diez áreas. Cada grupo se resume en una frase; los números enlazan al fichero correspondiente en [../adr/](#).

Plataforma e I/O

[0001](#), [0002](#), [0008](#), [0010](#), [0011](#), [0012](#), [0013](#).

Fijan el terreno: Linux primero y Windows después, modelo **proactor** sobre *completions*, C++23 con libc++ en Clang (que `std::expected` exige), `io_uring` directo sobre el uapi del kernel sin `liburing`, y la capa `nexus-wire` que aloja el framing sobre conexión, todo desarrollable y comprobable a coste cero.

Replicación y consenso

0003, 0007, 0014, 0015, 0016, 0024, 0025.

Definen el corazón distribuido: **Raft por partición** con postura **CP** (PACELC PC/EC), el log de Raft como vista (term, índice) sobre el `PartitionLog`, una FSM síncrona **sin E/S** que el portador conduce, `ReplicatedPartition` paralelo a `Partition`, la compactación por *snapshot* y la activación del stack con transporte inter-nodo real.

Protocolo

0004, 0029, 0030.

Establecen el plano de datos: un **protocolo binario propio** (con *gateway* REST para administración) y, como *stretch*, un **subconjunto Kafka** servido por un adaptador asíncrono que interoperara en vivo con `kcat`, con una **guarda mono-protocolo** que impide mezclar records nativos y Kafka en una misma partición.

Concurrencia

0005, 0026.

La tesis arquitectónica: **shared-nothing thread-per-core** (un reactor *pinned* por núcleo) con **sharding** del plano de datos (partición→núcleo por $p \% N$, grupos por $\text{hash}(\text{id}) \% N$) para evitar la contención.

Ingress y seguridad

0006, 0018, 0019, 0027, 0031.

El borde del sistema y la protección de datos: *ingress* en dos modos (nativo directo y proxy *opt-in*), REST admin desacoplado por **puerto/adaptador** (DIP), TLS/mTLS opcional con puente de BIOs de memoria sobre el proactor, el *pool* de conexiones aguas arriba por reactor que cablea el modo proxy, y el **cifrado en reposo** del log (AES-256-GCM opcional con DEK por segmento y framing AEAD por bloque), que reutiliza la misma dependencia OpenSSL que TLS.

Almacenamiento

0032.

La retención larga a bajo coste: el **almacenamiento por niveles** (*tiered storage*) descarga los segmentos sellados fríos a un puerto `StorageTier` (con adaptador local por defecto e interfaz orientada a fichero, lista para un adaptador S3 futuro), reclama el disco local **solo tras confirmar** la subida y **rehidrata** de forma transparente al leer un offset frío, interoperando con el cifrado en reposo (sube el *ciphertext* tal cual).

Transacciones

0033, 0034.

El **exactly-once multi-partición** (nativo, *effectively-once* honesto): marcadores de control COMMIT/ABORT, un **coordinador de transacciones** como FSM sin E/S con su propio grupo Raft, el **LSO** por partición y el aislamiento `read_committed` (con filtrado de abortados), y el *fencing* por época de productores y coordinadores. El 2PC que lo sostiene es **logueado y recuperable** (la decisión se registra en Raft antes de escribir marcadores; un failover la re-conduce), reconciliando la atomicidad multi-partición con la prohibición del 2PC en memoria bloqueante.

Observabilidad

[0017](#).

Un target dedicado `nexus-telemetry` que concentra métricas Prometheus y logging estructurado, evitando esparcir la instrumentación por todas las capas.

Windows

[0021](#) → [0022](#) → [0023](#), [0028](#).

La portabilidad a Windows: la **cadena de reemplazo** del backend IOCP (diseño → MinGW → runtime con MSVC) y, sobre ella, el port completo de `nexusd` (backend, afinidad de hilos y señales).

Lenguajes y errores

[0009](#), [0020](#).

Dos decisiones transversales: la **política de errores por capa** (`expected` en el hot-path, excepciones en el plano de control, códigos de wire traducidos en el borde) y el *binding* de Python vía una **ABI C estable** consumida con `ctypes`.

28.5 Dónde está cada decisión

El registro vivo y completo es el directorio `../adr/`, con su propio [README](#) e índice. Este capítulo lo resume y lo contextualiza; para leer una decisión entera —contexto, consecuencias y alternativas— se va al fichero correspondiente.

29. Historia de desarrollo

Retrospectiva del proyecto por fases. NexusMQ se construyó **por capas**, cada una autocontenida y demoable, registrando las decisiones de arquitectura como ADR a medida que surgían. Aquí se resume el recorrido y los aprendizajes; el catálogo de decisiones vive en [docs/adr/](#) y el capítulo 28.

29.1 Filosofía de avance

El principio rector fue **incrementos pequeños y siempre compilables**, con TDD (rojo→verde→refactor) y una puerta de calidad en local antes de cada *commit* (dos compiladores, sanitizers, formato, `clang-tidy`). La ambición se persiguió como **profundidad dentro de una sola tesis arquitectónica** (*thread-per-core* + Raft por partición), no como amplitud. Cada decisión de calado quedó como ADR; un ADR aceptado no se edita, se reemplaza (ver [capítulo 28](#)).

29.2 Fase 1 — Storage engine

Motor de log monopartición con **I/O bloqueante y sin reactor** (decisión deliberada: validar correctitud y durabilidad antes que rendimiento). Hitos: `Record` + **CRC32C** por hardware con *fallback* software; `Segment` (`.log` + `.index`); `PartitionLog` (secuencia de segmentos, *rolling*, recuperación con validación de CRC y truncado de la cola *torn*); política de `fsync`; retención por tiempo/tamaño; primeros *benchmarks*.

Aprendizajes: la recuperación ante *crash* y la corrupción silenciosa (*torn writes*) exigen *checksums* por registro verificados al leer; la durabilidad real depende de `fsync` / `fdatsync`, no de `write`.

29.3 Fase 1b — Reactor + broker monolítico

Aparece el **reactor thread-per-core propio** sobre el proactor (`io_uring` + corutinas C++23), el **protocolo binario** (capa `nexus-wire` para el framing — [ADR-0013](#)), el cliente nativo y los flujos *produce/fetch* con **backpressure por créditos**. Aquí se consolidan dos decisiones mayores: **C++23 + libc++ en Clang** por `std::expected` ([ADR-0011](#)) y **io_uring directo sobre el uapi**, sin liburing ([ADR-0012](#)).

Aprendizajes: bajo *thread-per-core*, **nada bloqueante puede vivir en el reactor** (un `fsync` o un `malloc` que entre al kernel congela el núcleo) → todo I/O pasa por el proactor y se usan *allocators* por núcleo.

29.4 Fase 2 — Distribución (Raft por partición)

Replicación y consenso con **Raft por partición**. Decisiones clave: el **log de Raft es el WAL**, con el **índice de entrada** como espacio distinto del **offset por record** ([ADR-0014](#)); `RaftNode` como **máquina de estados síncrona sin E/S** —entradas `tick / on_*` con `now` inyectado→ cola de mensajes— que habilita la **simulación determinista** ([ADR-0015](#)); `ReplicatedPartition` como tipo paralelo a `Partition` ([ADR-0016](#)); grupos de consumidores y rebalanceo.

Aprendizajes: separar el **núcleo de consenso de la E/S** es lo que hace Raft *testable* de forma determinista (reloj/red virtuales), cumpliendo FIRST sin *flakiness*.

29.5 Fase 3 — Ingress y operación

Plataforma operable y observable: *ingress* en **dos modos** (nativo/proxy — [ADR-0006](#)), **TLS opcional** vía OpenSSL con puente de BIOs de memoria sobre el proactor ([ADR-0019](#)), **API REST de administración** por puerto/adaptador ([ADR-0018](#)), CLI, y observabilidad con el target `nexus-telemetry` ([ADR-0017](#)): métricas Prometheus, logs JSON, *health/readiness*.

Aprendizajes: un puente **TLS síncrono sobre I/O asíncrona** se resuelve con *memory BIOs* (OpenSSL procesa en memoria; el socket asíncrono mueve los bytes cifrados), evitando acoplar la librería de TLS al modelo de *completions*.

29.6 Fase 4 — *Stretch* y producción

Activación del stack distribuido y funcionalidades avanzadas: **transporte inter-nodo real** con plano separado y portador por partición ([ADR-0025](#)); **compactación por snapshot** del log de Raft ([ADR-0024](#)); **sharding por núcleo** del plano de datos ([ADR-0026](#)); **modo proxy** con *upstream pool* por reactor ([ADR-0027](#)); **subconjunto Kafka-compatible** asíncrono cross-core con interop `kcat` ([ADR-0029](#)); *binding* de Python por ABI C ([ADR-0020](#)); y el **port a Windows** (IOCP), que recorrió tres estados —diseño, compile-verificado con MinGW y, finalmente, **verificado en runtime con MSVC**— hasta el **port completo de** `nexusrd` ([ADR-0021](#) → [0022](#) → [0023](#); [ADR-0028](#)).

Aprendizajes: "compila" ≠ "funciona"; el valor real del port a Windows llegó al **verificarlo en runtime**. El único arreglo de fondo fue portar `crc32c.cpp` a MSVC (`__cpuid` + intrínsecos SSE4.2), lo que evidencia que las *CPU features* se detectan y usan distinto según el compilador.

29.7 Estado actual

Fases 1→4 implementadas; el árbol compila y pasa la suite con GCC/libstdc++ y Clang/libc++, y el backend Windows está verificado en runtime con MSVC. Las **GitHub Actions** están desactivadas temporalmente (cuota) y se reactivan al publicar; la puerta de calidad se mantiene en local. La documentación se está consolidando en su forma final (esta misma).

30. Limitaciones y trabajo futuro

Qué **no** hace NexusMQ (a propósito) y por dónde podría crecer. Acotar el alcance es una decisión de ingeniería: mantiene el proyecto profundo en una sola tesis arquitectónica en lugar de disperso. Base: el alcance declarado del proyecto y las consecuencias registradas en los ADR.

30.1 Limitaciones conscientes (fuera de alcance)

- **Compatibilidad total con Kafka.** Solo se implementa un **subconjunto** (`ApiVersions` / `Metadata` / `Produce` / `Fetch` y lo necesario para `kcat`), no las 70+ *API keys* versionadas ni el *consumer group protocol* completo ([ADR-0004](#), [ADR-0029](#)).
- **Transacciones en el subset Kafka y *exactly-once* de entrega literal.** El *exactly-once* multi-partición **sí** está implementado en la **superficie nativa** (transacciones con coordinador, marcadores de control, LSO y `read_committed`, [ADR-0033](#) / [ADR-0034](#)); es *effectively-once* **honesto** (deduplicación + visibilidad atómica), no una entrega *exactly-once* literal (inalcanzable ante fallos arbitrarios). Queda fuera: exponer transacciones en el **subset Kafka** (coherente con la partición mono-protocolo, [ADR-0030](#)).
- **Adaptador S3 real y offload asíncrono del tiered storage.** El **tiered storage** **sí** está implementado (puerto `StorageTier` + adaptador local, offload de segmentos sellados y rehidratación transparente, [ADR-0032](#)); lo que queda como trabajo futuro es un **adaptador S3** sobre el mismo puerto (tras `find_package`), la **descarga asíncrona** en un hilo de mantenimiento (hoy es síncrona en la rotación), una **caché de rehidratación** persistente (hoy se baja el segmento entero por lectura fría) y la recuperación ante **pérdida del disco local**.
- **Multi-tenancy y ACLs avanzadas** no se abordan en las fases actuales.
- **Rotación de la clave maestra (KEK) de cifrado en reposo.** El cifrado en reposo **sí** está implementado (AES-256-GCM opcional, [ADR-0031](#)); lo que queda como trabajo futuro es la **rotación** de la KEK (re-cifrado en caliente). El formato ya reserva *salt* e identificadores por segmento para soportarla.
- **Dashboard gráfico propio:** la observabilidad se expone vía Prometheus/CLI; un panel Grafana es opcional y *self-hosted*.
- **HLC y ordenación causal entre particiones.** El orden es por **offset** dentro de una partición; no hay relojes lógicos híbridos entre particiones.

30.2 Deudas acotadas

- **CI desactivado temporalmente.** Las GitHub Actions están en pausa por cuota; la puerta de calidad se ejecuta en local y se reactivará el CI al publicar (ver [capítulo 22](#)).
- **Madurez del modo proxy.** El modo nativo (*smart-client* al líder) es el primario y el más optimizado; el modo proxy con *upstream pool* ([ADR-0027](#)) es secundario y opt-in.
- **Escala de muchos grupos Raft.** Raft por partición implica un grupo (y su *heartbeat*) por partición; no es problema a escala de portfolio, pero a escala de miles de particiones requeriría agrupación de *heartbeats* y rebalanceo más sofisticado ([ADR-0003](#)).
- **Profundidad opcional de I/O.** *Direct I/O* (`O_DIRECT`) con caché/*readahead* propios quedó como profundidad medida, no como camino por defecto.

30.3 Líneas de evolución posibles

- **Ampliar el subset Kafka** hacia más *API keys* y versiones según demanda real de herramientas del ecosistema.
- **Adaptador S3 del tiered storage** sobre el puerto `StorageTier` ya existente (ADR-0032), más offload asíncrono y caché de rehidratación, para retención larga a bajo coste en la nube.
- **Lecturas desde *followers*** (*opt-in*, con garantías documentadas) para repartir la carga de lectura sin romper la postura CP.
- **Pre-vote / leadership transfer / learners** de Raft (de la tesis de Ongaro) para *failover* más suave y reconfiguración de membresía.
- **Optimización medida** del camino caliente (registered buffers/fixed files de *io_uring*, *allocators* NUMA-aware, *hugepages*) allí donde el *profiling* lo justifique.
- **Demo de despliegue en cloud** (el diseño ya es *cloud-ready*, 12-factor) con infraestructura como código, bajo demanda y sin coste recurrente ([ADR-0008](#)).

Apéndice A. Bibliografía

Fuentes canónicas que sustentan las decisiones de diseño de NexusMQ. Coinciden con la autoridad de la `BibliotecaDocumentacion` (fundamentos de sistemas, concurrencia, rendimiento, datos distribuidos).

Datos distribuidos y consenso

- Kleppmann, M. *Designing Data-Intensive Applications*. O'Reilly, 2017. (DDIA)
- Ongaro, D.; Ousterhout, J. *In Search of an Understandable Consensus Algorithm (Raft)*. USENIX ATC, 2014.
- Ongaro, D. *Consensus: Bridging Theory and Practice* (tesis; *pre-vote, leadership transfer, learners, snapshots*).
- Petrov, A. *Database Internals*. O'Reilly. (Storage engines, replicación, consenso.)
- Apache Kafka — *Documentation*: diseño del log particionado, *high-watermark* y formato *record batch v2*.

Arquitectura de brokers de referencia

- Redpanda — arquitectura *thread-per-core* / *shared-nothing* (sobre Seastar) y Raft por partición.
- Seastar — *framework* asíncrono (referencia conceptual del reactor *per-core*: `submit_to`, *futures*, *shared-nothing*).

Concurrencia y rendimiento

- Herlihy, M.; Shavit, N. *The Art of Multiprocessor Programming*. (Concurrencia, lock-free, consenso.)
- Williams, A. *C++ Concurrency in Action*. (Modelo de memoria, atómicos, lock-free.)
- Gregg, B. *Systems Performance*. (Método USE, *profiling*, latencia.)
- Tene, G. *How NOT to Measure Latency* / HdrHistogram. (*Coordinated omission*, percentiles.)
- Drepper, U. *What Every Programmer Should Know About Memory*. (Caché, NUMA, localidad.)

Sistemas, SO e I/O

- Bryant, R.; O'Hallaron, D. *Computer Systems: A Programmer's Perspective* (CS:APP).
- Kerrisk, M. *The Linux Programming Interface* (TLPI). (`syscalls`, `fsync`, `mmap`.)
- Axboe, J. *Efficient IO with io_uring*. (Documento de diseño de `io_uring`.)

C++ y diseño

- Meyers, S. *Effective Modern C++*.
- Stroustrup, B.; Sutter, H. *C++ Core Guidelines*.
- Stroustrup, B. *A Tour of C++*.
- Nygard, M. *Release It!*. (Circuit Breaker, Bulkhead, patrones de estabilidad.)
- Martin, R. C. *Clean Code / Clean Architecture*.

Las convenciones de proyecto (naming, errores, testing, concurrencia, memoria, rendimiento, redes, datos distribuidos, seguridad, CI/CD) están normalizadas en la `BibliotecaDocumentacion` , que es la autoridad de estilo importada por el `CLAUDE.md` .

Diagrama 1: Contexto del sistema (C4 nivel 1)

NexusMQ visto como una caja negra y los actores y sistemas externos que interactúan con él: productores y consumidores (cliente nativo y `kcat` por el subset Kafka), administradores (REST/CLI), Prometheus (scrape de `/metrics`) y los demás nodos del propio cluster.





Diagrama 2: Contenedores de un nodo (C4 nivel 2)

Vista interna de un proceso `nexusd` : los tres planos (datos/cliente, Raft inter-nodo y administración REST), el *reactor pool* thread-per-core que ejecuta la lógica del broker, y el almacenamiento append-only en disco. Cada reactor es dueño exclusivo de un subconjunto de réplicas de partición; la interacción entre núcleos es paso de mensajes (SPSC), nunca estado compartido.






Diagrama 3: Grafo de dependencias de targets

Dependencias internas entre las 15 librerías `nexus-*`, los ejecutables (`nexusrd`, `nexus-cli`, `nexus-bench`, `nexus-loadgen`) y la librería compartida `nexus-ffi`. Refleja el grafo real de dependencias del proyecto: las capas suben de abajo (`nexus-common`, sin dependencias internas) hacia arriba (`nexus-server` / `nexus-client`). Regla forzada en CMake: un target nunca depende de otro de su misma capa o superior. Una flecha `A --> B` significa "A depende de B".




Diagrama 4: Mapa fase → targets

Qué librerías y ejecutables se entregan en cada fase del plan de desarrollo. Las fases son incrementales: cada una se apoya en lo construido antes. Estado as-built: las fases 1→4 están implementadas, con el cierre 4b (Windows, deuda diferida y benchmarks).

Tabla resumen

Fase	Foco	Targets entregados
1	Monohilo + I/O bloqueante	nexus-common , nexus-storage (I/O bloqueante), nexus-bench , nexus-tests (unit/property/crash)
1b	Reactor + mono-nodo	nexus-io (proactor), nexus-reactor , nexus-protocol , nexus-wire , nexus-broker (mono-nodo), nexus-client , nexus-server (mono-nodo); tests de integración
2	Distribuido (Raft)	nexus-consensus , nexus-cluster , broker distribuido (grupos, rebalanceo); tests sim/chaos
3	Ingress + observabilidad	nexus-ingress , nexus-telemetry , nexus-cli , deploy/ (Docker, Prometheus, Grafana, k8s)
4	Stretch	direct I/O, nexus-kafka (subset), nexus-ffi (binding Python), backend IOCP (Windows)
4b	Cierre	bloque W (nexusd Windows completo), bloque D (deuda diferida), bloque L (nexus-loadgen + benchmarks)

Diagrama





Diagrama 5: Topología thread-per-core (shared-nothing)

Cómo NexusMQ materializa el modelo *shared-nothing thread-per-core* (ADR-0005): el `ReactorPool` crea N `Reactor`, uno por núcleo físico, y fija cada hilo a su núcleo (`pthread_setaffinity_np`). Cada `Reactor` es **dueño** de todo su estado reactor-local —su anillo `io_uring` (`Proactor`), su `ArenaAllocator`, su `CoroScheduler`, sus temporizadores y el subconjunto de réplicas de partición que le tocan ($p \% N$)— y **no comparte nada mutable** con los demás. El único canal entre reactores es el paso de mensajes: cada reactor expone un `CrossCoreMailbox` con una cola `SpscQueue` lock-free por núcleo origen; `Reactor::submit_to` encola en la cola del destino y lo despierta (`Proactor::wake`). Así no hay locks ni *cache ping-pong* en el plano de datos.



Las flechas continuas son propiedad (cada reactor posee su estado local). Las flechas discontinuas son el **único** acoplamiento entre núcleos: trabajo movido por `submit_to` a la `SpvcQueue` del buzón destino, seguido de un `wake`. Cada cola SPSC tiene un único productor (el núcleo origen) y un único consumidor (el reactor dueño), con `head_ / tail_` en líneas de caché distintas (`alignas`) para evitar *false sharing*.

Diagrama 6: Sharding del plano de datos por núcleo

Cómo se reparte el estado entre los N reactores sin compartir nada mutable (ADR-0026, sobre ADR-0005). Cada pieza de estado tiene un **dueño único**, lo que la hace linealizable sin locks: un único núcleo serializa todas las operaciones sobre ella. Dos reglas de ubicación gobiernan el plano de datos:

- **Partición** → **núcleo dueño** = `partition % N` (lo fija `PartitionRouter::owner_core`, la misma regla que `ReactorPool::reactor_for`). El log y la pila Raft de cada partición viven **solo** en su reactor dueño; el resto de núcleos ni la instancian.
- **Grupo de consumidores** → **núcleo coordinador** = `hash(group_id) % N` con `hash` = **FNV-1a** sobre los bytes del `group_id` (contrato interno de ubicación, no viaja por *wire*). La membresía (`GroupCoordinator`) y los offsets confirmados (`OffsetManager`) viven en un solo núcleo, el coordinador del grupo.


Si la conexión la atiende un núcleo distinto del dueño/coordinador, la operación se enruta con `call_on` (petición/respuesta cross-core por el buzón SPSC); si coincide, es un *fast-path* local sin salto. Los metadatos de topics son la excepción: inmutables entre cambios y replicados por valor a cada núcleo, se validan localmente sin cross-core.



El reparto por $\text{partition} \% N$ y por $\text{FNV-1a}(\text{group_id}) \% N$ da a cada shard un dueño único: no hay un `TopicManager` ni un coordinador global con lock, sino confinamiento por reactor. El coste es que tocar una partición o un grupo de otro núcleo paga un salto cross-core (ver [topología](#) y [secuencia del proactor](#)).

Diagrama 7: Secuencia de una operación de E/S sobre el proactor

El ciclo de una operación de E/S asíncrona modelada como *proactor* por *completions* (ADR-0002): una corrutina hace `co_await` sobre un `awaitable` (`ReadAwaitable`, `RecvAwaitable`, `WriteAwaitable` ...), que **encola** la operación en el anillo `io_uring` del reactor (`Proactor::submit_*`) y suspende la corrutina sin bloquear el hilo. El bucle del reactor (`poll_once`) sigue atendiendo otras tareas; cuando no hay nada que hacer, **bloquea** en `wait_completions` cediendo la CPU. Al terminar la operación, el reactor drena la *completion* del anillo y ejecuta su callback, que guarda el resultado (`result_`) y reanuda la corrutina justo donde quedó. En `await_resume`, el resultado estilo `io_uring` (`>= 0` éxito, `< 0` = `-errno`) se traduce a `expected<T>` (modelo de errores del núcleo, ADR-0009).



Las *completions* se sirven **fuera** del scheduler de corrutinas: `submit_*` nunca ejecuta el callback de forma síncrona (reentraría en una corrutina aún suspendiéndose), siempre se difiere a `wait_completions / run_completions`. El `buffer` y, en `connect`, la dirección deben sobrevivir hasta la *completion*: viven en el *frame* de la corrutina que hace `co_await`. Para enrutar a otro núcleo antes o después de la E/S, ver [sharding](#) y [topología](#).


Diagrama 8: Layout del log de una partición

El log de una partición es una secuencia *append-only* de **segmentos** sellados más un **segmento activo**; cada segmento es un par de ficheros `.log` (los `RecordBatch` en orden de *offset*) y `.index` (índice disperso *offset*→posición). Este diagrama detalla esa estructura física, el byte-layout de la cabecera de batch y la mecánica de *seek*.

Fuentes: `src/storage/partition_log.hpp`, `src/storage/segment.hpp`, `src/storage/index.hpp`, `src/common/record.{hpp,cpp}`. Contrato de bytes: `../protocol.md` (§ «Registros y batches»). Diseño: capítulo 9 (Almacenamiento).

Composición: `PartitionLog` → `Segment` → (`.log` / `.index`)

Un `PartitionLog` ordena sus `Segment` por *offset* base; el último es el **activo** (recibe `append`). Al superar el activo `segment_bytes` (por defecto 64 MiB en `LogConfig`, configurable como `segment.bytes`), el siguiente `append` **rota**: sella el activo (`seal` : persiste el `.index` y `fsync`) y abre uno nuevo en `log_end_offset()`. Afinidad de todos estos tipos: **REACTOR-LOCAL** (no *thread-safe*).



- **Nombrado de ficheros:** cada segmento se nombra con su *offset* base a **20 dígitos** con relleno de ceros, de modo que el orden lexicográfico coincide con el orden de *offset* (`Segment` : `00000000000000000000.log` / `.index`).
- **Estados del segmento** (`Segment::State`): `Active` (admite `append` ; es el último del log) → `Closed` (sellado, índice persistido, solo lectura). La retención (Diagrama 9) borra después segmentos `Closed` enteros.
- **Offsets del log** (`PartitionLog`): `log_start_offset()` (base del primer segmento), `log_end_offset()` (siguiente *offset* a asignar) y `recovery_point()` (hasta dónde está sincronizado a disco estable, garantía de durabilidad).

Byte-layout del `.log` : secuencia de `RecordBatch`

El `.log` es una concatenación de `RecordBatch` (estilo Kafka v2) escritos en orden por su *offset* base. El batch viaja **intacto** por el log y la replicación: es la unidad de escritura y de entrada de Raft (ADR-0014). El payload de records se trata como **bytes opacos** a este nivel.

```
.log = [ RecordBatch ][ RecordBatch ][ RecordBatch ]... (append-only)
```

`RecordBatch` (little-endian; cabecera fija = `kHeaderSize` = 36 bytes):

offset	campo	tipo	notas
0	base_offset	i64	offset del primer record (NO cubierto por el CRC)
8	length	i32	bytes tras este campo (NO cubierto por el CRC)
12	crc	u32	CRC32C; cubre desde attrs (16) hasta el final
16	attrs	u16	códec de compresión (2 bits bajos) + flags
18	producer_id	i64	productor idempotente (-1 = ninguno) región
26	producer_epoch	i16	época del productor cubierta
28	base_sequence	i32	secuencia base (idempotencia) por el CRC
32	record_count	i32	nº de records del payload
36	records[]	bytes	blob opaco (puede ir comprimido, F5)

Notas fieles al código (`src/common/record.cpp`):

- **length** cuenta los bytes **tras** el propio campo `length`: `encoded_size = 12 (offset+length) + length`, o equivalentemente `kHeaderSize + records.size()`.
- El **CRC32C cubre** `[attrs .. fin]`, es decir, la cola de cabecera (desde el byte 16) más el blob de records. `base_offset`, `length` y `crc` quedan **fuera** del CRC: por eso el log puede **reasignar** `base_offset` al anexas (el líder asigna el *offset* autoritativo) sin invalidar la integridad.
- **Compresión (F5)**: los **2 bits bajos** de `attrs` indican el códec (0 =None, 1 =LZ4, 2 =Zstd). El broker guarda y replica el blob comprimido como opaco; solo el cliente lo descomprime. Ver [../protocol.md](#).
- **Decodificación defensiva** (`decode / peek`): se acota `length` (no negativo, `total ≤ bytes disponibles`) antes de derivar el tamaño; un batch *torn* (escrito a medias por un *crash*) se detecta así y por el CRC. Invariante de serialización: `decode(encode(x)) == x`.

Byte-layout de cada `record` dentro del blob

Cada record del blob va con prefijo de longitud (estilo Kafka v2, `src/common/record_codec.hpp`):

```
record = length:varint(zigzag) | attributes:i8 | timestampDelta:varint |
        offsetDelta:varint | keyLen:varint(-1=nulo) | key |
        valueLen:varint(-1=nulo) | value | headerCount:varint | headers[]
```

- El **offset absoluto** de un record se reconstruye al decodificar como `base_offset + offsetDelta`.
- Un record con `value` nulo es un **tombstone** (marca de borrado por clave para la compactación; ver Diagrama 9).
- Topes anti-DoS al decodificar entrada no confiable: `kMaxRecordsPerBatch` (1 000 000), `kMaxHeadersPerRecord` (10 000), `kMaxRecordBytes` (64 MiB descomprimido).

Byte-layout del `.index` : índice disperso (`SparseIndex`)

El `.index` **no** indexa cada batch, sino uno aproximadamente cada `index_interval_bytes` (por defecto 4096 en `LogConfig`): un compromiso espacio/tiempo que mantiene el índice pequeño y permite *seek* con búsqueda binaria más un barrido corto del `.log`.

```
.index = [ IndexEntry ][ IndexEntry ]... (ordenadas estrictamente por offset)
```

IndexEntry (little-endian; kEntrySize = 8 bytes):

offset	campo	tipo	notas
0	relative_offset	u32	offset absoluto - base_offset del segmento
4	file_position	u32	byte donde empieza ese batch en el <code>.log</code>

- `relative_offset` = *offset* absoluto - base del segmento; cabe en `u32` porque el segmento está acotado por `segment_bytes`. Ambos campos crecen de forma **estrictamente monótona** a lo largo del índice (invariante).
- `SparseIndex` posee el fichero `.index` (RAII) y mantiene las entradas en memoria como espejo del disco; `maybe_append(offset, file_position, batch_len)` siembra una entrada solo cuando el intervalo lo exige; `flush()` persiste lo pendiente y hace `fsync` (al sellar); `reset()` lo vacía para reconstruirlo durante `recover`.

Mecánica de *seek* (fetch desde un offset)



- `PartitionLog::read` localiza el segmento por *offset*, delega en `Segment::read` y, si no se llena `max_bytes` y quedan datos, **continúa en el segmento siguiente** (lectura cruzando segmentos) hasta `log_end_offset()`. `OutOfRange` si el *offset* es anterior a `log_start_offset()`.
- `Segment::read` no revalida el CRC (eso es de `recover`); ante un batch *torn* al final, se detiene.

Recuperación al arrancar (`Segment::recover`)

Al abrir el log, `PartitionLog::open` descubre los `.log` del directorio, abre todos los segmentos y **recupera el activo**: recorre los batches desde el inicio validando `length` y CRC32C, se detiene en el primer batch incompleto o corrupto (la cola *torn* de un *crash*), **trunca el `.log`** justo tras el último batch válido y **re-siembra el `.index`**. Así se fija `log_end_offset()` y `recovery_point`.

Durabilidad (`FsyncPolicy`)

`PartitionLog::maybe_sync` aplica la política de `fsync` configurada (`LogConfig::fsync_policy`) tras cada `append`:

Política	Cuándo hace fsync	Compromiso
None	Nunca explícitamente (durabilidad solo por el SO)	Máximo rendimiento
Interval	Al acumular <code>fsync_interval_bytes</code> (def. 1 MiB)	Equilibrado (por defecto)
Commit	En cada <code>append</code>	Durabilidad por escritura, el más lento

Tras un fallo, solo lo sincronizado hasta `recovery_point` está garantizado. Cada `seal` (rotación) sincroniza el segmento y avanza `recovery_point` a `log_end_offset`.

Diagrama 9: Retención y compactación del log

El log de una partición se acota por dos mecanismos independientes: la **retención** borra segmentos sellados enteros cuando superan `retention.ms / retention.bytes`, y la **compactación por clave** (`LogCompactor`) conserva solo el último record por clave. Este diagrama detalla ambos flujos tal como los implementa `nexus-storage`.


Fuentes: `src/storage/partition_log.{hpp,cpp}` (`enforce_retention`), `src/storage/retention.hpp` (`RetentionPolicy`), `src/storage/log_compactor.{hpp,cpp}` (`LogCompactor`). Diseño: [capítulo 9 \(Almacenamiento\)](#). Mecanismo vs política: el storage ofrece el mecanismo; la política la fija el llamante.


1. Retención por segmentos sellados enteros (`PartitionLog::enforce_retention`)

La retención **nunca borra a media trama ni el segmento activo**: la reclamación física es siempre por **segmentos** `closed` **completos**. Recorre del más antiguo al más nuevo mientras quede más de un segmento (`segments_.size() > 1`) y el más antiguo sea **elegible**; en cuanto el más antiguo deja de serlo, el resto tampoco lo es y se detiene.

Criterios de elegibilidad (`RetentionPolicy`, ambos opcionales con `< 0` = sin límite):


- **Por tamaño** (`retention_bytes`): el **total** de bytes del log supera `retention_bytes`.
- **Por tiempo** (`retention_ms`): la edad del segmento, tomada del `mtime` de su `.log`, supera `retention_ms`. (Los records aún no llevan *timestamp*; cuando lo lleven, podrá usarse el *timestamp* máximo del segmento.)





Efectos de borrar un segmento (fieles a `enforce_retention`): se quita del frente del vector (lo que **cierra sus descriptores por RAIL**), se eliminan los ficheros `.log` e `.index`, se descuenta su tamaño del total y se **avanza** `log_start_offset()` hasta la base del nuevo primer segmento.

Ciclo de vida del segmento



`eligible` y `deleted` son fases lógicas del ciclo de vida; en el código el estado persistente del `Segment` es solo `Active` / `Closed`, y la elegibilidad se evalúa dentro de `enforce_retention`.


2. Compactación por clave (`LogCompactor`)


Política **alternativa/complementaria** a la retención por tiempo/tamaño (§6.5): conserva, **por clave, solo el record más reciente** (la última aparición en orden de *offset*); las apariciones anteriores se descartan. Es REACTOR-LOCAL y **sin estado mutable**. Los *offsets* originales se **preservan** (pueden quedar huecos), igual que en Kafka.

Reglas (de `compact`):

- **Records sin clave** (`key == nullopt`): se conservan **siempre** (la compactación solo colapsa por clave).

- **Record con clave reemplazado** por otro posterior con la misma clave: se descarta (`records_superseded`).
- **Tombstone** (record con `value == nullopt`): supera a los anteriores de su clave y, salvo que se construya el `LogCompactor` con `retain_tombstones = true` , se **descarta también él** (`tombstones_dropped`), haciendo desaparecer la clave del log compactado.





`CompactionStats` reporta la pasada: `records_in` , `records_kept` , `records_superseded` , `tombstones_dropped` .

Lectura del log completo (`compact_log`)

`compact_log(log)` lee **todos** los records del `PartitionLog` (de `log_start_offset()` a `log_end_offset()`) por trozos de hasta 4 MiB, decodificando cada `RecordBatch` (`peek` para el tamaño, `decode` con validación de CRC, `decode_records` para el blob, descomprimiéndolo si procede) y los compacta preservando los *offsets* absolutos. Devuelve error de E/S o `Corrupt` si el log está dañado; incluye defensas anti bucle infinito (sin progreso de `next_offset` o lectura vacía).


Relación entre ambos mecanismos

- La **retención** es física y gruesa (segmentos enteros); reclama espacio por antigüedad/tamaño sin mirar el contenido.
- La **compactación** es lógica y por clave; produce un conjunto de records compactado (la materialización a nuevos segmentos es responsabilidad del llamante, no de `LogCompactor`).
- Existe además un recorte de **prefijo por snapshot de Raft** (`PartitionLog::truncate_prefix_to` , ADR-0024): pieza simétrica de la retención que borra segmentos sellados enteros por debajo de un *offset* preciso (reclamación física por segmentos; la exactitud en el índice la lleva el `RaftLog`). Distinto de la política de tamaño/tiempo de este diagrama.

Ver también el [Diagrama 8](#) (layout del log y segmentos) y [../protocol.md](#) (formato del `RecordBatch` y *tombstones*).

Diagrama 10: Estados y transiciones de una réplica Raft

Ciclo de vida del rol de un `RaftNode` por partición (`Follower` $\rightleftharpoons$ `PreCandidate` $\rightleftharpoons$ `Candidate` $\rightleftharpoons$ `Leader`), con la fase de *pre-vote* (§9.6) y la transferencia ordenada de liderazgo (§3.10) tal como las implementa `src/consensus/raft_node.hpp` (ADR-0003/0015).




Regla transversal (cualquier rol): observar un `term` mayor en cualquier RPC degrada el nodo a `Follower` y adopta ese término (`become_follower`). Un `learner` (§4.2.1) nunca se postula: replica el log sin votar ni contar para el quórum.

Diagrama 11: Replicación y confirmación a quórum

(acks=quorum)


Camino de escritura con Raft por partición: el productor envía al líder, este añade la entrada al log, la replica con `AppendEntries`, y cuando una mayoría confirma avanza `commit_index` (= *high-watermark*) y responde (§7.8, ADR-0003/0014). Una entrada de Raft es un `RecordBatch`; `ReplicatedPartition::produce` propone y la escritura es durable cuando `high_watermark()` la supera.



El `commit_index` es la *high-watermark*: el offset de partición del `last_offset` de la entrada en `commit_index` (ADR-0014). `acks=0` responde sin esperar; `acks=1`, tras el *append* local del líder; `acks=quorum` (por defecto), tras el *commit* de Raft. Solo se cuenta en el quórum a los miembros votantes (los `learner` replican pero no cuentan).

Diagrama 12: Failover y elección de líder


Cuando el líder cae, un seguidor agota su *election timeout* sin recibir *heartbeats*, se postula incrementando el término, difunde `RequestVote` y, al reunir mayoría, se convierte en líder y reanuda la replicación (§5.2, ADR-0003/0015). El diagrama omite la fase de *pre-vote* previa (§9.6) para centrarse en el *failover*.



El estado persistente (término y voto) se guarda con `fsync` **antes** de responder al RPC (regla §5 de Raft): lo gobierna `persistent_state_dirty()` y lo ejecuta el `RaftCarrier` antes de transportar. Ningún dato confirmado con `acks=quorum` se pierde mientras sobreviva la mayoría del grupo: el nuevo líder tiene, por la restricción de elección, todas las entradas *committed*.

Diagrama 13: Espacios de coordenadas (índice de entrada Raft vs offset por record)

NexusMQ mantiene **dos espacios de coordenadas distintos** (ADR-0014): el **índice de Raft** es el ordinal de cada entrada (1-based, +1 por entrada), mientras que el **offset de partición** es por *record* (un `RecordBatch` de N records ocupa N offsets). Una entrada de Raft equivale a un `RecordBatch`, así que cada índice mapea a un **rango** de offsets `[base_offset, last_offset]`. El `RaftLog` posee ese mapeo y lo persiste en el sidecar `raft-meta`.




Correspondencia que mantiene el sidecar `raft-meta` (`term:i64` | `base_offset:i64` | `last_offset:i64` | `type:u8` , 25 B/entrada):

Índice Raft	term	base_offset	last_offset	Records del batch
1	t1	0	1	2
2	t1	2	2	1
3	t2	3	5	3

El algoritmo de Raft opera sobre índices contiguos (`prev_log_index` , `commit_index` , `truncate_from`); la capa de partición traduce al espacio de offsets. La **high-watermark** visible a consumidores = `last_offset` de la entrada en `commit_index` (`offsets_at(commit_index)`). La resolución de conflictos `truncate_from(index)` recorta el `PartitionLog` por la **frontera de batch** `base_offset(index)` , dejando los `RecordBatch` intactos en disco.

Diagrama 14: Compactación por snapshot e `InstallSnapshot`


El log replicado es el WAL y crece sin techo; la compactación por *snapshot* (ADR-0024) fija una **base** (`last_included_index`, `last_included_term`, `last_included_offset`), descarta el prefijo aplicado y permite poner al día a un seguidor demasiado rezagado con `InstallSnapshot` en vez de re-replicar desde el índice 1 (§7 del paper). En NexusMQ el "estado" del snapshot **es la propia base** (índice/término/offset): los datos viven en el `PartitionLog`.



Coherente con ADR-0015 (FSM sin E/S): instalar un snapshot es una transición síncrona que reposiciona la base del log; la E/S durable la hace el `RaftLog` /portador, no el `RaftNode`. La compactación es *best-effort*: un fallo de E/S deja el log intacto y se reintenta en el próximo `tick`.

Diagrama 15: Planos de red (cliente vs inter-nodo Raft)

NexusMQ separa el **plano de cliente** (produce/fetch contra el líder, sobre el framing de `nexus-wire`) del **plano inter-nodo de Raft** (`AppendEntries` / `RequestVote` / `InstallSnapshot`), que viaja por su **propio puerto y conexiones persistentes** (ADR-0025). El plano inter-nodo usa el sobre `RaftEnvelope` (`topic` | `partition` | `from` | `to` | `type:u8` | `payload`) con prefijo de longitud sobre TCP, sin `FrameHeader` / `ApiKey`, para mantener ambos protocolos ortogonales.




El `RaftTransport` (sumidero `RaftMessageSink`) mantiene una conexión TCP persistente por peer, resolviendo `NodeId` -> `PeerAddress` (host + **puerto inter-nodo**) vía `PeerDirectory`. Es *best-effort*: Raft reenvía en el próximo `tick`. A diferencia del `call_on` cross-core (local y síncrono), un RPC a un nodo remoto **no vuelve** al completarse: su respuesta llega después como **otro** sobre (notificación asíncrona, ADR-0025). El `RaftCarrier` vive en el reactor dueño de la partición (`core = partition % cores`), respetando *shared-nothing*.

Diagrama 16: Layout de la cabecera del frame nativo

El protocolo binario propio de NexusMQ (plano de datos, puerto 9092) es **longitud-prefijo**: toda trama empieza con una cabecera de **14 bytes** (`FrameHeader::kEncodedSize`) seguida del payload. Los enteros son **little-endian** y de ancho fijo. El lector lee 4 bytes (`length`) y luego exactamente `length` bytes más (resto de cabecera + payload). Contrato: [../protocol.md](#) ; código: [../src/protocol/frame.hpp](#) .

Byte-layout (little-endian)



Campo	Offset	Tamaño	Tipo	Descripción
length	0	4	u32	Bytes tras este campo (resto de cabecera + payload) = 10 + payload .
apiKey	4	2	u16	Operación (ver tabla de ApiKeys).
apiVersion	6	2	u16	Versión del esquema de esa operación (negociada vía ApiVersions).
correlationId	8	4	u32	Eco petición↔respuesta; lo elige el cliente.
flags	12	2	u16	Bits de control (ver abajo).
payload	14	var.	bytes	Cuerpo específico de la operación (length - 10 bytes).

La cabecera codificada ocupa 14 bytes; `length` (= `length_for(payload)`) cuenta solo los 10 bytes de cabecera posteriores al propio campo más el payload. El lector valida una cota inferior (debe caber el resto de cabecera) y una **cota superior** anti-DoS (`max_frame` , por defecto **16 MiB**).

Campo flags

Bit	Nombre	Significado
0x0001	credit update	La trama acarrea una actualización de créditos (control de flujo / <i>backpressure</i>).

ApiKeys

Valor	ApiKey	Descripción
0	ApiVersions	Negociación de versiones soportadas.
1	Metadata	Brokers del clúster y topics/particiones.
2	Produce	Publica RecordBatch en una partición.
3	Fetch	Lee registros desde un offset.
4	OffsetCommit	Confirma el offset consumido de un grupo.
5	OffsetFetch	Recupera el offset confirmado de un grupo.
6	JoinGroup	Une un miembro a un grupo de consumidores.
7	SyncGroup	Distribuye la asignación de particiones del grupo.
8	Heartbeat	Mantiene viva la pertenencia al grupo.
9	LeaveGroup	Abandona el grupo.
10	CreateTopic	Crea un topic.
11	DeleteTopic	Borra un topic.

Diagrama 17: Petición/respuesta del subconjunto Kafka

El *listener* compatible con Apache Kafka (`nexusd --kafka-port <N>`) habla el *wire format* de Kafka: **big-endian**, *framing* `Size:INT32` y cabeceras **clásicas o flexibles** según API y versión. El `RecordBatch` v2 de Kafka viaja como **blob opaco** (el broker no lo reinterpreta). Contrato: [../kafka.md](#) ; código:

```
../../src/server/kafka_connection.hpp , ../../src/kafka/codec.hpp .
```

Framing (big-endian)

Cada mensaje —petición y respuesta— va longitud-prefijo con un `Size:INT32` big-endian, seguido de la cabecera correspondiente y el cuerpo de la API.

Campo	Tamaño	Tipo	Descripción
Size	4	INT32	Bytes del resto del mensaje (cabecera + cuerpo), big-endian.
cabecera	var.	—	Cabecera de request/response (clásica o flexible, ver abajo).
cuerpo	var.	—	Cuerpo de la API negociada (<code>Produce</code> / <code>Fetch</code> / <code>Metadata</code> / <code>ListOffsets</code> / <code>ApiVersions</code>).


Clásico vs flexible (*tagged fields*)

El codec elige el formato **por API y versión** según el umbral `flexible_since` : una versión `>=` su umbral es **flexible** (arrays/strings *compact* con longitud en `UNSIGNED_VARINT` y *tagged fields*); por debajo es **clásica**.

API	flexible_since	Cabecera petición	Cabecera respuesta
<code>Produce</code>	9	v1 clásica / v2 flexible	v0 clásica / v1 flexible
<code>Fetch</code>	12	v1 clásica / v2 flexible	v0 clásica / v1 flexible
<code>ListOffsets</code>	6	v1 clásica / v2 flexible	v0 clásica / v1 flexible
<code>Metadata</code>	9	v1 clásica / v2 flexible	v0 clásica / v1 flexible
<code>ApiVersions</code>	3	v1 clásica / v2 flexible	siempre v0 (regla de Kafka)

Por eso las versiones que negocia `librdkafka 2.x` (`Produce` v7, `Fetch` v11) van en formato **clásico**, mientras que `Metadata` v9, `ListOffsets` v7 y `ApiVersions` v3 van en **flexible**. **Excepción:** `ApiVersions` responde **siempre** con cabecera v0 aunque su cuerpo sea flexible.


Intercambio cliente (`kcat` / `librdkafka`) ↔ gateway




El `correlationId` espeja petición↔respuesta (igual que Kafka). En `Fetch` el blob se reconstruye reescribiendo solo el `baseOffset` : barato, porque el CRC32C de Kafka v2 cubre desde `attributes` en adelante, así que no hay que recalcularlo. Un `Fetch` sin datos devuelve un `MessageSet` **presente de longitud 0**, nunca `null` (-1), que librdkafka rechazaría como corrupto.

Diagrama 18: Flujo REST admin con JWT

El plano de administración de NexusMQ es una API REST bajo `/api/v1` servida en el **puerto de operación** (`nexusd --admin-port <N>` , sin valor por defecto), separada del plano de datos binario. Las rutas `/api/v1/*` se autentican con **Bearer JWT** (HS256, firmado con el secreto del nodo) **solo si** el nodo arrancó con `--jwt-secret` ; en ese caso devuelven `401` sin un token válido. Los errores siguen **RFC 7807** (`application/problem+json`). Los *endpoints* de salud/métricas (`/healthz` , `/readyz` , `/metrics`) van **sin autenticar**. Contrato: [../openapi.yaml](#) .





Notas del contrato


- **Validación del token en el borde:** la API comprueba la **firma** (HS256 con el secreto del nodo) y la **expiración** antes de servir cualquier ruta `/api/v1/*`. Si `--jwt-secret` no está activo, no se exige token.
- **Política de errores central (RFC 7807):** toda respuesta de error usa `ProblemDetail` (`application/problem+json`) con al menos `title` y `status`. El estándar contempla además `403` (no autorizado) para autorización por recurso, aunque el contrato actual detalla `400` / `401` / `404` / `405`.
- **Códigos por operación** (según `openapi.yaml`): `GET /api/v1/topics` → `200` / `400` / `401`; `POST /api/v1/topics` → `201` / `400` / `401` / `405`; `GET /api/v1/topics/{name}` → `200` / `401` / `404`; `DELETE /api/v1/topics/{name}` → `204` / `401` / `404` / `405`; `GET /api/v1/groups` → `200` / `400` / `401` / `405`.
- **Paginación:** las colecciones aceptan `page` (≥ 1 , def. 1) y `size` (1–100, def. 20).

Diagrama 19: Ingress en dos modos — nativo directo vs proxy

El *ingress* de NexusMQ soporta **dos modos** con una jerarquía explícita (ADR-0006): el **nativo directo** (primario) y el **proxy** (secundario, *opt-in*, cableado en el plano de datos por ADR-0027). El nativo prioriza el rendimiento; el proxy, la conveniencia para clientes "tontos" y HTTP, asumiendo a sabiendas un salto extra y la ruptura del *zero-copy*. Fuentes: `../adr/adr-0006-ingress-dos-modos.md`, `../adr/adr-0027-modo-proxy-upstream-pool.md`, `src/ingress/proxy.hpp`, `src/ingress/load_balancer.hpp`, `src/ingress/upstream_pool.hpp`.

Modo nativo directo (primario)


El *smart-client* conoce la topología: pide *metadata*, descubre el **líder** de cada partición y le habla **directamente** por el plano de datos. Sin proxy, sin salto extra, sin romper el *zero-copy*.



- El cliente **gestiona la metadata** y el descubrimiento de líder (coste asumido en el cliente).
- Camino caliente sin intermediarios: máxima latencia/throughput por defecto.

Modo proxy (secundario, opt-in)

El cliente "tonto" no conoce la topología: se conecta al *ingress*, que **enruta** su tramo por *consistent-hashing* (`LoadBalancer`, anillo FNV-1a con *vnodes*) y **releva** sus tramas (petición/respuesta a nivel de trama, `Proxy::forward`) a una conexión obtenida del `UpstreamPool`. Cada reactor tiene su propio *pool* (`REACTOR-LOCAL`, sin locks, *shared-nothing*).



- **route**: `Proxy::route(key)` delega en `LoadBalancer::pick` con *consistent-hashing* (mínima perturbación al añadir/quitar nodos); devuelve `nullopt` si el anillo está vacío.


- **acquire / release** : el `UpstreamPool` entrega una conexión **en préstamo exclusivo** (reúsa una ociosa de la *free-list* del nodo o **diala** una nueva con `Socket::async_connect` , sin congelar el reactor) y la recupera al cerrar el cliente; la *free-list* está **acotada** (`max_idle_per_node` , def. 8) para no fugar descriptores.
- **Préstamo exclusivo**: garantiza que **no se intercalan** tramas de dos clientes en la misma conexión aguas arriba (corrección del relevo).
- **Dos `PeerDirectory` distintos**: el del plano de datos (este) es una **instancia separada** del de Raft (ADR-0025); mismo tipo, distinta instancia.

Trade-offs (por qué dos modos, no uno)

Aspecto	Nativo directo	Proxy
Camino	cliente → líder	cliente → ingress → nodo
Salto extra	0	1 (asumido)
<i>Zero-copy</i>	sí	se rompe (copia en el relevo)
Cliente	<i>smart</i> (gestiona metadata)	<i>tonto</i> / HTTP
Activación	por defecto	<i>opt-in</i>

Diagrama 20: Puente TLS — OpenSSL síncrono sobre el proactor asíncrono

NexusMQ termina **TLS 1.3** (y, intra-clúster, **mTLS**) en el *ingress* (§7.9). OpenSSL es la librería elegida, pero su E/S es **síncrona/bloqueante**, mientras que el broker es *thread-per-core* **asíncrono** sobre un `Proactor` (`io_uring`). La solución (ADR-0019) es un **puente de BIOs de memoria**: OpenSSL nunca toca el descriptor; cifra/descifra contra dos `BIO` en memoria (`rbio` / `wbio`) y el transporte se hace de forma asíncrona vaciando/alimentando esos BIOs por el `Proactor` . Así la criptografía corre en línea, pero el socket es no bloqueante. Fuentes: [../adr/adr-0019-tls-opcional-openssl-bios.md](#) , `src/ingress/tls.hpp` (`TlsContext` / `TlsConnection`).



Cómo funciona el bucle (qué hace cada pieza)

- TlsContext** (THREAD-SAFE, RAII sobre `SSL_CTX`): fábricas `server` / `client` cargan el material PEM (cadena de certificado, clave privada) y, si se da una CA, configuran **mTLS** (`SSL_VERIFY_PEER` |

`FAIL_IF_NO_PEER_CERT`). `accept / connect` abren una `TlsConnection` fijando el rol del *handshake*.

- `TlsConnection` (REACTOR-LOCAL, *solo movable*): posee el `SSL*` y el `Socket`. Las primitivas OpenSSL (`SSL_do_handshake / SSL_read / SSL_write`) operan **solo contra los BIOs de memoria**:
 - ante `WANT_WRITE`, `flush_outgoing` **vacía** el `wbio` al socket (`async_send`);
 - ante `WANT_READ`, `feed_incoming` **alimenta** el `rbio` con lo leído del socket (`async_recv`); un retorno de `0` byte significa que el par cerró (EOF / `close_notify`).
- `peer_principal()`: extrae el **CN** del certificado del par para *authz* (mTLS).


Acoplamiento opcional (coste cero, ADR-0008)

El build usa `find_package(OpenSSL)`. Si está presente, compila `ingress/tls.{hpp,cpp}` y define `NEXUS_HAVE_OPENSSL` (toda la cabecera vive bajo `#ifdef NEXUS_HAVE_OPENSSL`); si no, el plano TLS se **omite por completo** y el broker arranca **en claro**. El CI instala `libssl-dev` para ejercer el *path* TLS (compilación, tests, sanitizers y clang-tidy).

Coste asumido: el puente de BIOs añade una copia intermedia *ciphertext* ↔ *socket*; es aceptable porque el throughput TLS lo domina la cifra, no esa copia.

Diagrama 21: Despliegue local con Docker Compose

El `docker compose` de `deploy/` levanta **3 nodos** `nexusd` + **Prometheus** + **Grafana** para validar el empaquetado, la observabilidad y los *probes* de salud sobre varias instancias. En Fase 3 los tres nodos son **brokers independientes** (el runtime de clúster multi-nodo —descubrimiento de líder, replicación entre nodos— llega en fases posteriores). Cada `nexusd` expone dos puertos: el **plano de datos** (`9092` , protocolo binario *framed* con `correlation_id`) y el **puerto de operación** (`9644` : `/healthz` , `/readyz` , `/metrics` , `/api/v1/...`). Fuente: `../../deploy/docker-compose.yml` , `../../deploy/prometheus.yml` .



Detalles del despliegue (fieles al compose)


- **Imagen** `nexusmq:dev` : build multi-stage (Ubuntu para compilar → **distroless** `cc` , no-root) desde la raíz del repo (`deploy/Dockerfile`). El `HEALTHCHECK` reutiliza `nexus-cli diagnostics` (distroless no trae `shell` ni `curl`); el contenedor pasa a *healthy* solo cuando `/healthz` y `/readyz` responden OK. `restart: unless-stopped` en todos los servicios.
- **Mapeo de puertos en localhost** : `nexus1 9092/9644` , `nexus2 9093/9645` , `nexus3 9094/9646` (el puerto interno es `9092/9644` en los tres; cambia el lado del host).
- **Persistencia**: un volumen de datos por nodo (`nexusN-data` → `/var/lib/nexusmq`), más `prometheus-data` y `grafana-data` .
- **Prometheus** (`:9090`): raspa `/metrics` (`metrics_path: /metrics`) de los tres por su **nombre de servicio** en compose (`nexus1:9644` , `nexus2:9644` , `nexus3:9644`), `scrape_interval: 15s` , etiqueta `cluster: local` ; `depends_on` de los tres nodos.
- **Grafana** (`:3000`): login anónimo (rol `Admin`), `datasource` Prometheus **provisionado** desde `grafana/datasources.yml` ; `depends_on` de Prometheus.


Requisito del host: el kernel debe soportar **io_uring** (el broker usa el backend `io_uring` directo, ADR-0012).

Ver el flujo de scrape end-to-end en [23-pipeline-observabilidad.md](#) y el despliegue a escala en [22-despliegue-kubernetes.md](#) .

Diagrama 22: Despliegue en Kubernetes — StatefulSet + Service headless

El broker tiene **estado persistente** (logs de partición), de ahí el `StatefulSet` (3 réplicas) con `volumeClaimTemplates` (un **PVC por réplica**) y un `Service headless` (`clusterIP: None`) que da DNS estable a cada réplica (`nexusmq-0.nexusmq`, `nexusmq-1.nexusmq`, ...). Los *probes* van sobre el **puerto de operación** (`ops`, 9644): **liveness** `/healthz`, **readiness** `/readyz`. Fuentes: [../../deploy/k8s/statefulset.yaml](#), [../../deploy/k8s/service.yaml](#).






Detalles del manifiesto (fieles a `deploy/k8s/`)

- **StatefulSet** (`replicas: 3` , `serviceName: nexusmq`): identidad y almacenamiento estables por réplica; `volumeClaimTemplates` crea un **PVC data de 1Gi (ReadWriteOnce)** por pod, montado en `/var/lib/nexusmq`.
- **Service headless** (`clusterIP: None`): no balancea por VIP; expone DNS por pod y agrupa los puertos `data` (9092) y `ops` (9644). El líder de partición se descubre por *metadata* (no por el Service), coherente con el modo nativo directo (ver [19-modo-nativo-vs-proxy.md](#)).
- **Probes sobre el puerto ops** :
 - **liveness** `httpGet /healthz` (`initialDelay 5s` , `period 10s` , `failureThreshold 3`): ¿sigue vivo el proceso? Un fallo justifica reiniciar el pod.
 - **readiness** `httpGet /readyz` (`initialDelay 3s` , `period 5s` , `failureThreshold 3`): ¿puede recibir tráfico? Pasa solo con el arranque terminado y los *probes* (disco, Raft, *lag*) sanos; un `fail` retira el pod del balanceo sin matarlo.
- **Contenedor endurecido (hardening)**: `runAsNonRoot` (`uid/gid 65532` , `fsGroup 65532`), `readOnlyRootFilesystem: true` , `allowPrivilegeEscalation: false` , `capabilities.drop: [ALL]` .
- **Recursos**: `requests cpu 250m / mem 128Mi` ; `limits cpu 1 / mem 512Mi` .

La imagen `nexusmq:dev` debe estar disponible para el clúster (build + push a un registry, o `kind load docker-image nexusmq:dev`) y el nodo debe soportar **io_uring**. Aplicar con `kubectl apply -f deploy/k8s/` y seguir con `kubectl rollout status statefulset/nexusmq` .

Diagrama 23: Pipeline de observabilidad — métricas y logs

La observabilidad de NexusMQ es *self-hosted* (Prometheus + Grafana en Docker). El broker **alimenta** una `MetricsRegistry` (THREAD-SAFE, en `nexus-telemetry`) desde las capas del plano de datos (broker/reactor: tasa de produce/fetch, *lag*, `commit_index` /term de Raft, latencias) y la **expone** en `/metrics` por el **puerto de operación** (9644), en **formato de exposición Prometheus** (`text/plain; version=0.0.4`). Prometheus **raspa** ese endpoint periódicamente y Grafana lo consulta como *datasource*. En paralelo, el proceso emite **logs JSON** estructurados (con niveles y *correlation IDs*). Fuentes: [capítulo 12 \(Observabilidad\)](#), `src/telemetry/metrics.hpp`, `../..../deploy/prometheus.yml`, `../..../deploy/docker-compose.yml`.



Cómo fluye (fiel al código y al deploy)

- **Origen de las métricas** (§7.6, §9 ADR-0017): la `MetricsRegistry` vive en `nexus-telemetry` (no en `nexus-server`, un exe no enlazable, ni en `nexus-ingress`, que crearía el ciclo `broker → ingress`). Las capas inferiores **registran** métricas; el gateway REST y el servidor las **exponen** en `/metrics`.
- **Modelo pull**: Prometheus **raspa** (no recibe *push*); en el compose, `scrape_interval: 15s`, `metrics_path: /metrics`, `targets` por nombre de servicio (`nexus1:9644`, `nexus2:9644`, `nexus3:9644`) con etiqueta `cluster: local` (ver [21-despliegue-docker-compose.md](#)).
- **Endpoint sin autenticar**: `/metrics`, `/healthz` y `/readyz` van **sin token** (`security: []`), a diferencia de `/api/v1/*` que usa Bearer JWT (ver [18-flujo-rest-jwt.md](#)).
- **Grafana**: consulta Prometheus por **PromQL** y pinta *dashboards* / dispara alertas; *datasource* provisionado desde `grafana/datasources.yml`.
- **Logs JSON**: estructurados, con niveles y *correlation IDs* para *tracing* de peticiones; emitidos a la salida estándar para que el orquestador/colector los agregue.

Señales y SLOs (cómo se usan)

Las métricas materializan las **cuatro señales de oro** (latencia, tráfico, errores, saturación) y el método **USE**, base de los SLOs en percentiles (**p95/p99/p999**, nunca solo la media). Las cifras reales de rendimiento viven en [../benchmarks.md](#) (no se inventan aquí).


Diagrama 24: Almacenamiento por niveles (tiered storage)

Con un tier configurado (`--tier-dir`), el log de una partición se parte en un **prefijo frío** —los segmentos sellados más antiguos, descargados a un almacén de objetos y reclamados del disco local— y un **suffix caliente** —los segmentos que siguen en disco, incluido el activo—. La descarga es opcional y con **degradación limpia**: sin tier, el prefijo frío está siempre vacío y el comportamiento es byte-idéntico al de hoy. Este diagrama detalla el puerto `StorageTier`, el ciclo de descarga/reclamación, la lectura transparente por rehidratación y las operaciones destructivas *tier-conscientes*.

Fuentes: `src/storage/storage_tier.{hpp,cpp}` (`StorageTier`, `TierObjectKey`), `src/storage/local_storage_tier.{hpp,cpp}` (`LocalStorageTier`), `src/storage/partition_log.{hpp,cpp}` (`offload_sealed_to_tier`, `read`, `open`, `truncate_prefix_to`, `reset_to`). Diseño: [capítulo 9 \(Almacenamiento\)](#), §9.7, ADR-0032. Layout base del log: [Diagrama 8](#); retención/compactación: [Diagrama 9](#).

1. Prefijo frío + suffix caliente sobre el puerto `StorageTier`

El `PartitionLog` depende de la **interfaz** `StorageTier` (inversión de dependencias), no de una nube concreta. El adaptador por defecto `LocalStorageTier` copia a un directorio objeto local; un adaptador S3 futuro implementaría el mismo contrato tras `find_package`. La clave de objeto `TierObjectKey` es determinista y jerárquica, de modo que listar el tier reconstruye el prefijo frío sin ningún manifiesto local.




- **La contigüidad del log (sin huecos)** implica que las **bases ordenadas** bastan para reconstruir el rango de cada segmento frío: el rango de una base es `[base, siguiente_base)`. `log_start_offset()` sigue siendo la base más antigua (esté fría o caliente); descargar **no cambia** el rango del log.
- **Clave de objeto** `TierObjectKey` → `"<topic>/<partition>/<base:020>.<ext>"` (p. ej. `demo/0/0000000000000000008000.log`), con `SegmentFileKind` ∈ `{Log, Index}`. `encode()` / `decode()` son inversas (invariante de round-trip); el relleno a 20 dígitos preserva el orden lexicográfico = orden de offset.

- **Puerto orientado a fichero:** `put_file` / `fetch_file` / `contains` / `object_size` / `remove` / `list_segment_bases` , todos `expected<...>` . Un segmento **es** un fichero, así que descargar y rehidratar son copias (sin cargar segmentos en RAM); `LocalStorageTier` sube con **copia atómica** (temporal hermano + `rename`).

2. Ciclo descargar → reclamar (`offload_sealed_to_tier`)


Con un tier configurado, cada **rotación** de segmento (sellado del activo, [Diagrama 8](#)) dispara la descarga de los sellados, *best-effort* (un fallo del tier no aborta la rotación: el segmento se queda local y se reintenta, idempotente). Se sube del **más antiguo al más nuevo** y **solo tras confirmar** la subida se borran los ficheros locales.



- **Nunca el segmento activo:** solo se descargan segmentos `Closed`. **Nunca se reclama sin confirmar:** el orden es *subir* → *verificar* → *borrar local* → *marcar frío*, así que un *crash* a mitad deja el segmento local intacto (reintento idempotente). `tiered_segment_count()` expone cuántos segmentos están fríos.
- **Interoperación con el cifrado (ADR-0031):** el `.log` / `.index` se suben **tal cual** (bytes opacos). Si el log va cifrado, el tier guarda **ciphertext**; la KEK nunca viaja al tier.

3. Lectura transparente por rehidratación (`PartitionLog::read`)


`read(offset)` sirve el suffix caliente directamente desde disco (camino de siempre) y, para un offset del prefijo frío, **rehidrata** el segmento a un temporal, lo sirve y limpia el temporal con **RAII**. El llamante no distingue frío de caliente: el offset, el rango y el `next_offset` son idénticos.



- **Orden de destrucción (RAII):** el `Segment` se cierra **antes** de que `TmpGuard` borre el directorio temporal, para que los ficheros estén cerrados al eliminarlos. `read` es lógicamente `const` (el temporal es un efecto de lado transitorio; no hay caché persistente — bajar el segmento entero por lectura fría es correcto pero no óptimo; una caché de rehidratación es trabajo futuro).
- `first_local_base()` es la base del primer segmento **local**; por debajo de ella, el offset vive en el prefijo frío.

4. Reapertura: el tier es la autoridad (`PartitionLog::open`)

Al reabrir, el prefijo frío se reconstruye **listando el tier** (`list_segment_bases(topic, partition)`), sin un manifiesto local que pudiera desincronizarse. Las bases que **también existen localmente** (descarga confirmada pero sin reclamar por un *crash*) se descartan del prefijo: el segmento local es autoritativo.



5. Operaciones destructivas *tier-conscientes*

Las operaciones que borran o reescriben el log se hacen conscientes del prefijo frío para no dejar objetos huérfanos ni reescribir historia comprometida:

Operación	Comportamiento con prefijo frío
<code>truncate_prefix_to</code> (compactación / snapshot de Raft, ADR-0024)	Borra del tier (<code>remove</code>) los segmentos fríos que quedan por debajo del corte antes de descartarlos; simétrica de la retención.
<code>reset_to</code> (InstallSnapshot)	Borra del tier todos los segmentos fríos (<code>remove</code>) además de los locales; el log se reinicia limpio.
<code>truncate_to</code> (truncado de cola de Raft)	Rechaza (<code>Unsupported</code>) truncar dentro del prefijo frío: es historia ya comprometida, que Raft nunca reescribe (solo trunca colas no comprometidas, que están calientes).
<code>enforce_retention</code> (retención por tiempo/tamaño, Diagrama 9)	No toca el <i>hot set</i> local mientras haya prefijo frío: los datos más antiguos ya están en el tier a bajo coste.

Recuperación ante **pérdida del disco local** (árbol local vacío con objetos en el tier) queda fuera de alcance: se prioriza el reinicio normal, que conserva al menos el segmento activo local (ADR-0032, *Consecuencias*).


Diagrama 25: Transacciones y 2PC logueado (exactly-once nativo)

El *exactly-once* multi-partición (ADR-0033 / ADR-0034) se apoya en un `TransactionCoordinator`: una **máquina de estados sin E/S** (mismo patrón que `RaftNode` y `GroupCoordinator`) que conduce un *two-phase commit* **logueado y recuperable, no bloqueante**. El coordinador **registra la decisión** (`PrepareCommit` / `PrepareAbort`) en su propio grupo Raft **antes** de escribir ningún marcador; el portador transporta las **órdenes de marcador** a cada partición participante y las acusa. Este diagrama detalla la FSM de una transacción, el flujo feliz del 2PC, la recuperación ante *failover* del coordinador y la visibilidad `read_committed` por LSO.

Fuentes: `src/broker/transaction_coordinator.{hpp,cpp}` (`TransactionCoordinator`, `TransactionState`, `MarkerWrite`, `ProducerIdentity`), `src/broker/partition_txn_index.{hpp,cpp}` (`PartitionTxnIndex`, `IsolationLevel`, `AbortedTxn`), `src/common/control_record.{hpp,cpp}` (`EndTxnMarker`, `build_control_batch`). Diseño: [capítulo 10 §10.8](#), [capítulo 9 §9.8](#), [ADR-0033](#), [ADR-0034](#). Contrato de wire: [../protocol.md](#).

1. FSM de una transacción en el coordinador

Una transacción vive el ciclo `Ongoing` → `Prepare*` (decisión registrada) → `Complete*` (todos los marcadores acusados). El registro de la decisión **antes** de escribir marcadores es lo que hace el 2PC recuperable: un coordinador que arranca y ve un estado `Prepare*` sabe que debe **re-emitir** los marcadores que falten (`resume_pending`), no dejar a los participantes bloqueados esperando.




- Sin participantes, `commit` / `abort` concluye de inmediato (`Complete*`) sin emitir marcadores.

- **Fencing por época:** una época **inferior** a la autoritativa (`current_epoch_`) es **Fenced** ; una **superior** (o un estado `Complete*`) inicia una transacción nueva, expulsando a la anterior. La época autoritativa **sobrevive** a que la transacción concluya, de modo que un zombi en `CompleteAbort` con época vieja no puede re-abrir.
- `tick(now)` aborta las transacciones `Ongoing` que superan el timeout (`kDefaultTxnTimeout` , 60 s), liberando el LSO.

2. Flujo feliz del 2PC (init → begin → produce → commit)


El productor obtiene su identidad con `init_producer_id` , abre la transacción, declara participantes y publica batches transaccionales; al confirmar, el coordinador registra `PrepareCommit` y **luego** encola un `MarkerWrite` por participante, que el portador escribe como **batch de control** y acusa.



- El batch de datos arrastra `producer_id` + época en la cabecera, reutilizando la **idempotencia** de `ProducerSession` (dedup por secuencia + fencing por época).
- El batch de control lleva `EndTxnMarker {type, coordinator_epoch, version}` ; el `coordinator_epoch` **sella** el marcador para el fencing en el failover.
- **ABORT** es simétrico: `PrepareAbort` → marcadores `Abort` → `CompleteAbort` ; los batches de datos de la transacción nunca se hacen visibles.

3. Recuperación ante *failover* del coordinador (2PC recuperable)


Si el coordinador cae **después** de registrar la decisión pero **antes** de que todos los marcadores se acusen, el nuevo líder reconstruye su estado desde el grupo Raft, adopta una **época mayor** y **re-conduce** la decisión ya registrada. No hay espera bloqueante: los marcadores re-emitidos llevan la nueva época y los antiguos quedan fencing-eados.



- La partición **descarta** (idempotente) marcadores con `coordinator_epoch` obsoleto: un marcador rezagado del líder viejo no puede deshacer ni duplicar la decisión del nuevo.
- Coherente con la postura **CP**: cerrar transacciones nuevas exige quórum en el grupo del coordinador; si no hay quórum, no se decide (no se diverge).

4. Visibilidad `read_committed` y LSO por partición

En lectura, `PartitionTxnIndex` mantiene el conjunto de transacciones abiertas y de rangos abortados. El **LSO** (*last stable offset*) es el mínimo *first-offset* de transacción abierta, acotado por el *high-watermark*; `read_committed` entrega solo hasta el LSO y **filtra** los records abortados y los propios marcadores de control.



- Atomicidad:** un `Commit` hace visible **toda** la data de la transacción; un `Abort`, **ninguna**; una transacción **abierta** retiene el LSO (nada suyo ni posterior es visible en `read_committed` hasta que cierre).
- `PartitionTxnIndex` se mantiene incrementalmente (`on_data` / `on_marker` / `evict_below`); el algoritmo `filter_committed` procesa los marcadores en línea para activar/desactivar cada rango abortado por `producer_id`. Estas invariantes están cubiertas por la **simulación determinista** (`tests/sim/transaction_sim.hpp`), incluido un caos de 300 transacciones con *failover*.

Registro de decisiones de arquitectura (ADR)

Cada decisión de arquitectura de NexusMQ vive en un fichero `adr-NNNN-titulo-corto.md`, con las secciones **Contexto · Decisión · Consecuencias · Alternativas consideradas** (plantilla en `../.. /BibliotecaDocumentacion/patrones/plantilla-adr.md`).

Una decisión **aceptado** **no se edita**: si cambia, se **reemplaza** por un ADR nuevo que la marca como *reemplazada por adr-NNNN*. La historia de decisiones es inmutable. El recorrido narrado de estas decisiones vive en el capítulo [28 de la documentación técnica](#).

ADR	Título	Estado	Fecha
0001	Plataforma de desarrollo y <i>target</i> (Linux primero, Windows después)	aceptado	2026-06-07
0002	Modelo de I/O asíncrona (proactor; io_uring primero, IOCP después)	aceptado	2026-06-07
0003	Modelo de replicación (Raft por partición)	aceptado	2026-06-07
0004	Protocolo del plano de datos (binario propio + gateway REST)	aceptado	2026-06-07
0005	Arquitectura de concurrencia (<i>shared-nothing thread-per-core</i>)	aceptado	2026-06-07
0006	Rol del <i>ingress</i> (dos modos: nativo directo + proxy/REST)	aceptado	2026-06-07
0007	Postura de consistencia (CP / PACELC PC-EC)	aceptado	2026-06-07
0008	Viabilidad de coste cero (desarrollo y test gratuitos)	aceptado	2026-06-07
0009	Política de manejo de errores por capa	aceptado	2026-06-10
0010	Entorno de desarrollo (VS Code sobre WSL)	aceptado	2026-06-11
0011	Estándar C++23 + libc++ en Clang (para <code>std::expected</code>)	aceptado	2026-06-11
0012	Backend io_uring directo sobre el uapi del kernel (sin liburing)	aceptado	2026-06-12
0013	Capa <code>nexus-wire</code> para el framing sobre conexión	aceptado	2026-06-13
0014	Modelo del log de Raft (índice = ordinal de entrada; término en sidecar)	aceptado	2026-06-14
0015	RaftNode como máquina de estados síncrona sin E/S	aceptado	2026-06-14
0016	<code>ReplicatedPartition</code> como tipo paralelo a <code>Partition</code>	aceptado	2026-06-15
0017	Target <code>nexus-telemetry</code> para observabilidad	aceptado	2026-06-17
0018	REST admin por puerto/adaptador (<code>AdminService</code> / <code>AdminApi</code>)	aceptado	2026-06-18
0019	TLS opcional vía OpenSSL con puente de BIOs de memoria	aceptado	2026-06-19
0020	<i>Binding</i> de Python vía ABI C estable (<code>nexus-ffi</code> + <code>ctypes</code>)	aceptado	2026-06-20

ADR	Título	Estado	Fecha
0021	Backend IOCP (Windows) — diseño fijado, implementación diferida	reemplazado por adr-0022	2026-06-20
0022	Backend IOCP (Windows) — implementado, compile-verificado con MinGW	reemplazado por adr-0023	2026-06-20
0023	Backend IOCP (Windows) — verificado en runtime con MSVC	aceptado	2026-06-20
0024	Compactación del log de Raft por snapshot	aceptado	2026-06-20
0025	Activación en producción del stack Raft + multi-reactor (transporte inter-nodo)	aceptado	2026-06-21
0026	Sharding por núcleo del plano de datos (partición→núcleo, grupos por hash)	aceptado	2026-06-21
0027	Cableado del modo proxy — <i>pool</i> de conexiones aguas arriba por reactor	aceptado	2026-06-25
0028	Port completo de <code>nexusrd</code> a Windows (backend, afinidad y señales)	aceptado	2026-06-27
0029	Adaptador Kafka asíncrono cross-core sobre el broker vivo	aceptado	2026-06-28
0030	Partición mono-protocolo — guarda cross-protocol nativo/Kafka	aceptado	2026-07-09
0031	Cifrado en reposo del log con AES-256-GCM y framing AEAD por bloque	aceptado	2026-07-12
0032	Almacenamiento por niveles — puerto <code>StorageTier</code> y tier local	aceptado	2026-07-12
0033	Exactly-once multi-partición nativo (transacciones, coordinador y <code>read_committed</code>)	aceptado	2026-07-12
0034	2PC logueado y recuperable (reconciliación con la prohibición del 2PC bloqueante)	aceptado	2026-07-12

ADR-0001: Plataforma de desarrollo y *target* (Linux primero, Windows después)

- **Estado:** aceptado
- **Fecha:** 2026-06-07

Contexto

El autor desarrolla en Windows con Visual Studio, pero el dominio del proyecto —un broker de mensajería— se despliega de forma natural en Linux y contenedores. Además, el ecosistema de *tooling* de alto rendimiento (perf, flamegraphs, io_uring, hugepages, NUMA) es Linux. Existe, por tanto, una tensión entre el entorno de trabajo preferido (Visual Studio) y la plataforma natural del dominio (Linux), y se desea no renunciar a ninguno de los dos.

Decisión

Se adopta **Linux** (x86-64, Docker) como *target* primario, desarrollado **desde Visual Studio vía WSL2** (workload "Linux development with C++"), con **CMake + vcpkg** como sistema de build y de dependencias portables. El *target* **Windows nativo** queda como un **objetivo posterior comprometido** —no descartado—, que se aborda tras consolidar la plataforma Linux.

Consecuencias

- (+) Encaje con el dominio y con el *tooling* esperado por los perfiles de sistemas/HFT, conservando a la vez el IDE preferido.
- (+) La portabilidad se diseña desde el inicio sin pagar por adelantado su coste completo.
- (+) La estructura de **solución única** (un único árbol CMake) **no bloquea** el *target* Windows posterior: el mismo árbol cambia de *preset* a MSVC y solo añade el adaptador **IOCP** en `src/io/`, sin reestructurar (ver §5.2).
- (–) Se asume la fricción de WSL2 y la de mantener un *toolchain* multiplataforma.

Alternativas consideradas

- **Windows nativo (IOCP/RIO) como primario:** descartado como primario por encaje de dominio y de *tooling*, aunque sería un diferenciador; se mantiene como fase posterior.
- **Cross-platform total desde el día 1:** descartado por el coste de mantener dos backends de I/O y de fichero antes de tener producto.

ADR-0002: Modelo de I/O asíncrona (proactor; io_uring primero, IOCP después)

- **Estado:** aceptado
- **Fecha:** 2026-06-07

Contexto

El plano de datos del broker es I/O intensiva, por lo que el modelo de E/S asíncrona es una decisión central. Los dos *targets* previstos (Linux y Windows) ofrecen modelos asíncronos: io_uring e IOCP, **ambos basados en completions**. En cambio, epoll es un modelo *readiness-based*, conceptualmente distinto.

Decisión

Modelar la capa de I/O como **proactor**: la interfaz consiste en enviar una operación asíncrona y recibir una *completion*. El **backend será io_uring ahora e IOCP después**. Las **coroutines de C++20** se asientan sobre este proactor.

El storage engine arranca con I/O **bloqueante** (Fase 1) y adopta io_uring como **optimización medida**. Bajo el reactor *thread-per-core*, **todo** el I/O —incluido `fsync`— pasa por io_uring, porque nada bloqueante puede vivir en el reactor (matiz R6). El *direct I/O* con caché propia queda como profundidad opcional de la Fase 4.

Consecuencias

- (+) Una sola forma de I/O para ambos *targets*; coroutines naturales; un anillo por núcleo encaja con la arquitectura *shared-nothing*.
- (+) La portabilidad queda como capacidad documentada, sin necesidad de doble implementación inicial.
- (–) Un proactor es más complejo que un *reactor* epoll directo; si hiciera falta epoll, se emularía como *completion*.
- (–) Prohibir bloqueos en el reactor exige una disciplina asíncrona total (allocators por núcleo, `fsync` asíncrono).

Alternativas consideradas

- **Reactor epoll (*readiness*):** descartado como forma canónica por no mapear bien a IOCP (Windows).
- **Librería asíncrona externa (ASIO/Seastar):** descartada para el núcleo por ser una pieza de aprendizaje central; Seastar se valora solo como referencia conceptual.

ADR-0003: Modelo de replicación (Raft por partición)

- **Estado:** aceptado
- **Fecha:** 2026-06-07

Provisional revisable: se reconfirma con los *benchmarks* de la Fase 1; si cambia, se **reemplaza** por un ADR nuevo (no se edita).

Contexto

La Fase 2 requiere replicar particiones y tolerar caídas de líder. Existen dos arquitecturas de referencia:

- **Raft por partición** (modelo Redpanda): cada partición es su propio grupo Raft, y el log de Raft es el log de la partición.
- **ISR estilo Kafka:** el consenso se usa solo para metadatos/controller, y los datos se replican por primario-backup con *high-watermark*.

Decisión

Adoptar **Raft por partición**: un **único mecanismo** de ordenación, replicación y elección por partición. El *high-watermark* se deriva del `commitIndex` de Raft, y el modelo de `acks` (§4.3) se asienta sobre su *commit*.

Se prefiere por ser **conceptualmente uniforme, formalmente especificado y testeable de forma determinista** —lo que sirve al objetivo de *correctitud demostrable*— y porque compone con la arquitectura *shared-nothing* (un grupo Raft anclado a un núcleo).

Consecuencias

- (+) Un solo mecanismo que razonar y probar; *failover* sin pérdida de datos *committed*; encaje con *thread-per-core*.
- (+) Base natural para el modelo de ACK y la postura CP (ver ADR-0007).
- (–) Coste de **quórum en cada escritura** (latencia de mayoría) en el camino caliente.
- (–) Muchas particiones implican muchos grupos Raft y, por tanto, mucho *heartbeat*; no es problemático a escala de portfolio, pero sí relevante a escala de miles de particiones.

Alternativas consideradas

- **ISR estilo Kafka:** ofrece mayor throughput potencial, pero introduce más piezas (controller, gestión de ISR, *high-watermark* separado) y más superficie de error; descartado por complejidad y por ser el diseño "de hace 14 años".
- **Raft por partición:** elegido (ver Decisión).

ADR-0004: Protocolo del plano de datos (binario propio + gateway REST)

- **Estado:** aceptado
- **Fecha:** 2026-06-07

Contexto

El plano de datos necesita un protocolo. Hay dos caminos en tensión:

- Un **binario propio** maximiza el aprendizaje y el control (framing, varint, *multiplexing/correlation IDs*, versionado, control de flujo) y compone sin *impedance mismatch* con la arquitectura *shared-nothing*.
- La **compatibilidad con Kafka** daría ecosistema (kcat, consolas, clientes), pero obliga a implementar una especificación ajena y enorme (más de 70 *API keys* versionadas, *record batch v2*, *consumer group protocol...*), atando el diseño y *front-loading* un esfuerzo ingrato.

Decisión

Implementar un **protocolo binario propio** para las fases nucleares, acompañado de un **gateway REST** para interoperabilidad temprana (cubre el "¿funciona con herramientas reales?" vía HTTP/curl/Postman).

Se difiere un **subconjunto Kafka-compatible** (*ApiVersions* / *Metadata* / *Produce* / *Fetch*) a la **Fase 4** como *stretch*: basta para la demo "kcat habla con mi broker" sin apostar el proyecto a la especificación completa. El titular "Kafka-compatible" queda así **recuperable más tarde** sin pagar su coste por adelantado.

Consecuencias

- (+) Control total del protocolo; aprendizaje de diseño de protocolos (lo que el proyecto quiere demostrar); libertad para ajustarlo a *shared-nothing* y al modelo de créditos.
- (+) Interoperabilidad inmediata vía REST.
- (–) Sin ecosistema Kafka "gratis" hasta la Fase 4.
- (–) El cliente nativo hay que escribirlo (ya estaba en alcance, OE-2).

Alternativas consideradas

- **Compat Kafka desde el inicio:** ofrece ecosistema instantáneo, pero a costa de un esfuerzo enorme e ingrato, riesgo de *uncanny valley* (compatibilidad parcial que casi funciona) y un diseño atado antes de existir; descartado para el núcleo y diferido como subconjunto de la Fase 4.
- **Binario propio + REST:** elegido (ver Decisión).

ADR-0005: Arquitectura de concurrencia (*shared-nothing thread-per-core* con reactor propio)

- **Estado:** aceptado
- **Fecha:** 2026-06-07

Provisional revisable tras los *benchmarks* de la Fase 1; si cambia, se **reemplaza** por un ADR nuevo.

Contexto

El plano de datos exige un modelo de concurrencia. Hay dos familias en juego:

- **Thread-pool con estado compartido** (modelo Kafka clásico): *locks* sobre estructuras compartidas.
- **Shared-nothing thread-per-core** (modelo Redpanda/Seastar): un reactor por núcleo, estado por núcleo y paso de mensajes.

El proyecto prioriza la profundidad de sistemas, la *correctitud demostrable* y estar en el estado del arte.

Decisión

Adoptar **shared-nothing thread-per-core: un reactor por núcleo** (*pinned*), cada uno dueño de su anillo **io_uring**, su **allocator** y su subconjunto de particiones; la comunicación entre reactores se hace **solo por colas SPSC cross-core** (estilo `submit_to`).

Se **construye un reactor mínimo propio** sobre `io_uring` + corutinas C++20 y **no** se usa Seastar (dependencia pesada, Linux-only; "construir" demuestra más que "usar" y encaja con la política §3.4 de hacer el núcleo a mano). Seastar queda como **referencia conceptual**. La decisión es **provisional revisable** tras los *benchmarks* de la Fase 1.

Consecuencias

- (+) Elimina la clase de bug más cara (carreras sobre estado compartido); cachés y NUMA locales; sin *locks* en el camino caliente; estado del arte.
- (+) Compone con Raft por partición (un grupo anclado a un núcleo) y con `io_uring` (un anillo por núcleo).
- (–) **Disciplina asíncrona total:** nada bloqueante en el reactor (un `fsync`, `malloc` o *lock* que entre al kernel congela el núcleo), lo que exige `fsync` asíncrono y *allocators* por núcleo.
- (–) Coordinación *cross-core* explícita (SPSC + *wakeup*).
- (–) Si se adopta *direct I/O*, hay que implementar caché/*readahead* propios (no se usa el *page cache*).

Alternativas consideradas

- **Thread-pool con work-stealing / estado compartido:** más simple de arrancar, pero demuestra el diseño de hace 14 años, introduce contención y la clase de bug que queremos eliminar; descartado como primario.

- **Usar Seastar:** ahorra construir el reactor, pero demuestra menos, es Linux-only y pesado; descartado como dependencia, retenido como referencia.

ADR-0006: Rol del *ingress* (dos modos: nativo directo + proxy/REST)

- **Estado:** aceptado
- **Fecha:** 2026-06-07

Contexto

En un plano de datos de alto rendimiento, interponer un proxy en el camino caliente añade un salto y rompe el *zero-copy*. Pero exigir siempre un *smart-client* excluye a los clientes simples y a HTTP. Existe, por tanto, una tensión explícita entre rendimiento y conveniencia.

Decisión

Soportar **dos modos** con una jerarquía explícita:

1. **Nativo directo** (primario): un *smart-client* que va al **líder** de la partición vía *metadata*, sin proxy.
2. **Proxy/REST** (secundario, *opt-in*): el *ingress* enruta clientes "tontos" mediante *consistent hashing* y expone un **gateway REST**, asumiendo el salto extra a sabiendas.

Se documenta como **dos modos con *trade-offs***, no como "un *ingress* que lo hace todo".

Consecuencias

- (+) Máximo rendimiento por defecto y conveniencia/interoperabilidad bajo demanda; demuestra **criterio** en vez de incoherencia.
- (–) Dos caminos que mantener y documentar; el cliente nativo debe gestionar *metadata* y el descubrimiento de líder.

Alternativas consideradas

- **Solo proxy:** simple para el cliente, pero penaliza el camino caliente; descartado como único.
- **Solo smart-client:** óptimo en rendimiento, pero excluye a clientes simples y a HTTP; descartado como único.

ADR-0007: Postura de consistencia (CP / PACELC PC-EC)

- **Estado:** aceptado
- **Fecha:** 2026-06-07

Contexto

Todo sistema replicado debe elegir, ante una partición de red, entre **consistencia** y **disponibilidad** (CAP); y, en operación normal, entre **latencia** y **consistencia** (PACELC). El proyecto prioriza la correctitud y se apoya en Raft, que requiere quórum para progresar.

Decisión

NexusMQ es un sistema **CP**: ante una partición de red, una partición de datos que se quede sin **quórum** de su grupo Raft **deja de aceptar escrituras** y, por tanto, no diverge.

En términos de PACELC es **PC/EC**: ante una **Partición** elige **Consistencia**, y en condiciones normales (**E**lse) también prioriza **Consistencia** sobre **Latencia** (las escrituras esperan al quórum cuando se usa `acks=quorum`).

La lectura por defecto se sirve desde el **líder**, hasta el *high-watermark*. Las lecturas *stale* desde *followers* son **opt-in** y quedan documentadas.

Consecuencias

- (+) No hay divergencia ni pérdida de datos *committed*; el comportamiento es coherente con Raft y con el objetivo de *correctitud demostrable*.
- (+) Modelo mental simple para el usuario.
- (–) Una partición minoritaria queda **no disponible** para escritura durante un *split*; se acepta como precio de la consistencia.

Alternativas consideradas

- **AP (alta disponibilidad, escrituras en minoría con reconciliación posterior):** ofrece mayor disponibilidad pero abre la puerta a la divergencia y a los conflictos; es incoherente con el modelo de log ordenado y con Raft. Descartada.

ADR-0008: Viabilidad de coste cero (desarrollo y test gratuitos; cloud como *target* opcional)

- **Estado:** aceptado
- **Fecha:** 2026-06-07

Contexto

El proyecto se **orienta** a despliegue en Azure/AWS, pero su valor formativo y de portfolio no debe depender de gasto recurrente en cloud. Conviene fijar explícitamente que todo el ciclo de trabajo se puede realizar de forma gratuita.

Decisión

Realizar **todo** el desarrollo, el testing (unitario, de integración y *crash/chaos*) y el *benchmarking* **en local, sin coste**:

- *Toolchain* y dependencias **open source**.
- Cluster de 3 nodos mediante **Docker Compose**.
- *Chaos* con `tc netem` y `cgroups`.
- CI en **GitHub Actions** (gratis en repositorios públicos / *free tier* en privados).
- Observabilidad **Prometheus + Grafana** *self-hosted*.

El despliegue en **cloud** es un **objetivo de diseño** (imagen Docker, principios 12-factor) y, como mucho, una **demo opcional** cubrible con *free tiers* (AWS/Azure/Oracle Always Free), nunca un requisito de gasto. Los *benchmarks* se miden **en local**, ya que los *free tiers* no sirven para obtener cifras serias.

Consecuencias

- (+) Barrera de entrada económica nula y reproducibilidad del ciclo completo.
- (+) El diseño *cloud-ready* permite una demo desplegada si se desea.
- (–) Una demo en cloud real con *hardware* serio sí costaría dinero (egress, almacenamiento, instancias encendidas); se mitiga con IaC bajo demanda.
- (–) Los *free tiers* no permiten *benchmarks* representativos; se asume y por eso se miden en local.

Alternativas consideradas

- **Depender de cloud para test/bench:** descartada por el coste y por la peor reproducibilidad de los *benchmarks*.

ADR-0009: Política de manejo de errores por capa (excepciones / `std::expected` / códigos de wire)

- **Estado:** aceptado
- **Fecha:** 2026-06-10

Contexto

`principios/manejo-errores.md` prescribe **excepciones**, no **códigos de error** para la **lógica de negocio de aplicación**, mientras que `stacks/cpp` avala `std::expected / error_code` en **código de sistemas y baja latencia**. El broker tiene **tres superficies de error** distintas: el **protocolo de red** (contrato), el **núcleo de sistemas** (camino caliente) y el **plano de control** (admin/REST). Hay que fijar qué mecanismo rige en cada una para no contradecir la normativa ni pagar el coste de las excepciones en el *hot path*.

Decisión

Política por capa, alineada con la biblioteca:

- **Protocolo / wire (§7.2.2):** **códigos de error numéricos** (`errorCode:i16`) como **contrato**; se **traducen al modelo interno en el borde**, no se propagan crudos por el núcleo (`manejo-errores` : "los códigos de error de protocolo... son legítimos").
- **Núcleo de sistemas / camino caliente** (storage, reactor, consensus): `std::expected<T,E>` (o `std::error_code / Result`) — el error es un **valor**, de coste predecible; **sin excepciones en el hot path**. Se evaluará `-fno-exceptions` solo con **justificación medida** (coste de *unwinding* / latencia de cola).
- **Plano de control / aplicación** (admin, configuración): **excepciones para lo excepcional** más `std::optional` para la ausencia de valor; en el **borde REST**, traducción a `ProblemDetail` (RFC 7807) (§7.6).
- **Invariantes transversales (no cambian):** aportar **contexto** en el error; **validar en el borde** (*fail-fast*, §7.9); mantener **una sola política central**; **nunca tragar** un error; y **envolver** los errores de librerías de terceros (liburing/OpenSSL) en tipos propios.

Consecuencias

- (+) Coherente con `principios/manejo-errores.md` y con `stacks/cpp` ; sin coste de excepciones en el camino caliente; modelo de error de cara al cliente estándar (códigos en binario, RFC 7807 en REST).
- (–) Hay que **propagar** `expected` **a mano** (mitigado con los monádicos `and_then / or_else`) y mantener la **traducción en los bordes** entre los tres modelos.

Alternativas consideradas

- **Excepciones en todo (incluido el hot path):** contradice la baja latencia (*unwinding* no determinista) y la guía de sistemas de `stacks/cpp` ; descartada para el núcleo.
- **Códigos de error en todo (incluida la aplicación):** contradice `manejo-errores.md` para la lógica de aplicación; descartada fuera del núcleo/contrato.

ADR-0010: Entorno de desarrollo (VS Code sobre WSL; reemplaza el IDE de ADR-0001)

- **Estado:** aceptado (reemplaza la elección de IDE de ADR-0001)
- **Fecha:** 2026-06-11

Reemplaza la elección de IDE de ADR-0001. El resto de ADR-0001 (*target* Linux primero, WSL2, CMake + vcpkg, Windows después) **sigue vigente**; ADR-0001 no se edita (un ADR aceptado se reemplaza, no se modifica).

Contexto

ADR-0001 fijó desarrollar **desde Visual Studio** (workload "Linux development with C++") sobre WSL2. El código del proyecto vive **dentro del sistema de ficheros de WSL** (`/home/...` , visible desde Windows como `\\ws1.localhost\...`).

El modelo CMake+WSL de Visual Studio **asume que el código reside en el FS de Windows** y lo sincroniza a WSL con `rsync` ; al abrir una carpeta que ya vive en WSL sobre el *share* `\\ws1.localhost` , VS **no activa la integración CMake** (no genera caché, no aparecen *targets* ni "Elemento de inicio"), con cuelgues al cerrar. Se verificó con **VS 2026 (18.7)**: presets válidos (`cmake --list-presets` OK), `enableCMake: true` y componentes Linux/WSL instalados — el bloqueo es de **diseño de VS**, no de configuración.

Decisión

Migrar el IDE a **VS Code conectado a WSL** (extensiones **Remote-WSL** + **CMake Tools** + **C/C++**), abriendo el proyecto en su ruta Linux real (`code .` desde WSL). CMake Tools consume el **mismo CMakePresets.json** y permite configurar, compilar, ejecutar y **depurar (gdb) nativo** en WSL, sin copias ni `rsync` . El código permanece en WSL (mejor I/O que `/mnt/c`).

Se **estandariza** en los presets `linux-gcc/clang/asan` (Ninja, los mismos que el CI) y se eliminan los presets `ws1-ubuntu*` (Makefiles) y los *vendor maps* `microsoft.com/VisualStudioSettings` introducidos para VS.

Consecuencias

- (+) El IDE trabaja donde vive el código: sin `rsync` , sin cuelgues, **un único CMakePresets.json** para IDE, CI y terminal, con idéntico *toolchain* (gcc/gdb/cmake).
- (+) Experiencia gráfica equivalente (configurar/compilar/ejecutar/depurar).
- (+) Menos superficie de configuración (un solo conjunto de presets).
- (–) Se renuncia a Visual Studio como IDE (preferencia previa del autor) para este proyecto.
- (–) Recuperar VS exigiría mover el repo al FS de Windows — descartado por el flujo *Linux-first*.

Alternativas consideradas

- **Mover el repo a `C:\` y seguir en Visual Studio (modelo `rsync` de VS):** funcional, pero el origen pasa a Windows, con peor rendimiento de I/O en WSL2 y fricción de *line endings*/permisos; contradice *Linux-first*. Descartado.
- **Forzar VS sobre `\\ws1.localhost`:** no es un flujo soportado; es la causa de la no-activación y de los cuelgues. Descartado.
- **VS Code + Remote-WSL:** elegido (ver Decisión).

ADR-0011: Estándar C++23 + libc++ en Clang (para

`std::expected`)

- **Estado:** aceptado (refina el mecanismo de ADR-0009, no lo reemplaza)
- **Fecha:** 2026-06-11

Refina el mecanismo de ADR-0009 (no lo reemplaza). ADR-0009 fija `expected<T> = std::expected<T, Error>` en el núcleo; este ADR registra las **consecuencias de toolchain** de esa decisión, descubiertas al implementar el modelo de errores en M2.

Contexto

`std::expected` es **C++23**, pero el proyecto se fijó en C++20 (`cxx_std_20`). Al implementar `error.hpp` se constató, además, que **Clang 18 + libstdc++ no compila** `<expected>` ni siquiera en C++23: el `<expected>` de libstdc++ exige `__cpp_concepts >= 202002L` y Clang 18 reporta `201907L`. GCC (libstdc++) sí lo compila (`__cpp_concepts = 202002L`).

Sin solución, el *lane* de Clang del CI —y **clang-tidy**, que parsea con el frontend de Clang— quedarían rotos en todo fichero que use el modelo de errores.

Decisión

Subir el estándar a `cxx_std_23`. GCC compila con **libstdc++** (por defecto). **Clang** compila con **libc++** (`-stdlib=libc++`), fijado **globalmente** en el preset `linux-clang` y en el CI (build + lint), de modo que también las dependencias traídas por FetchContent (GoogleTest/Benchmark) usen libc++ y no haya choque de ABI.

`clang-tidy` consume el `compile_commands.json` de ese preset, así que parsea con libc++. Se documenta en `CLAUDE.md` (hechos del proyecto) y se requiere `libc++-dev` / `libc++abi-dev` donde se use Clang.

Consecuencias

- (+) `std::expected` disponible y **probado en ambos compiladores** (GCC/libstdc++ y Clang/libc++); se conserva la cobertura de Clang y de clang-tidy.
- (+) Modelo de error de cara al cliente estándar (sin coste de excepciones en el camino caliente, ADR-0009).
- (–) Conviven **dos** librerías estándar (libstdc++ con GCC, libc++ con Clang): hay que instalar libc++ donde se compile con Clang; algo más de superficie de toolchain.
- (–) El estándar mínimo sube de C++20 a C++23 (el toolchain objetivo lo soporta de sobra).

Alternativas consideradas

- `expected` **propio (C++20) sobre** `std::variant`: portable sin libc++ y sin subir de estándar, pero se aparta del mecanismo elegido en ADR-0009 (`std::expected`); descartado por preferencia explícita de mantener el tipo estándar.

- `std::expected` **solo con GCC (sin lane Clang)**: simple, pero pierde la cobertura de Clang y deja **clang-tidy** sin poder parsear el modelo de errores; descartado.

ADR-0012: Backend `io_uring` directo sobre el uapi del kernel (sin liburing)

- **Estado:** aceptado (precisa el diseño detallado de `nexus-io`, no cambia el diseño)
- **Fecha:** 2026-06-12

Precisa el diseño detallado de `nexus-io` (no cambia el diseño): el diseño detallado anotaba el backend del `Proactor` como «`io_uring (liburing)`». Este ADR registra que la **implementación** habla con `io_uring` **directamente** por el uapi del kernel, sin la biblioteca `liburing`. El **puerto** `Proactor` y sus **contratos no cambian**; solo el backend.

Contexto

El backend `io_uring` (R5) debe cumplir la **puerta de calidad**: compilar y testear **en local y en CI**, en GCC y Clang, bajo sanitizers. En el entorno de desarrollo no hay `sudo` para instalar `liburing-dev` y `vcpkg` no está *bootstrapeado* (se cae a `FetchContent`); `liburing` usa *autotools* (no CMake), así que vendorizarla de forma reproducible es frágil.

En cambio, el **uapi del kernel** (`<linux/io_uring.h>`) está presente tanto en local (WSL2, kernel 6.18) como en el *runner* de CI (ubuntu-24.04), y `io_uring` funciona en tiempo de ejecución en local (probado: `io_uring_setup` OK, `IORING_FEAT_SINGLE_MMAP`).

Decisión

Implementar `IoUringBackend` **directamente sobre el uapi**: `io_uring_setup` / `io_uring_enter` vía `syscall`, anillos SQ/CQ mapeados con `mmap` (se exige `IORING_FEAT_SINGLE_MMAP`), barreras *acquire/release* sobre los índices compartidos con el kernel y SQEs gestionadas a mano. **Cero dependencias externas**: el mismo binario compila en todas partes solo con cabeceras del kernel.

CMake compila el backend solo donde existe `<linux/io_uring.h>` (define `NEXUS_HAVE_IOURING`); el *smoke-test* hace E/S real y se **omite en ejecución** (`GTEST_SKIP`) si `io_uring` no está disponible (kernel viejo, *seccomp* del CI). Toda la gestión cruda (fd, mmap, ops en vuelo) queda confinada en un *pimpl* RAII, sin filtrar el uapi al resto del árbol.

Consecuencias

- (+) Sin dependencias ni instalación: build idéntica en local y CI, sin `sudo /vcpkg/autotools`.
- (+) Control total del anillo (afín al *shared-nothing* y al objetivo de aprender sistemas) y *hot-path* sin biblioteca intermedia.
- (+) Validado en local en los cuatro *lanes* (GCC/Clang/ASan/TSan) porque `io_uring` corre aquí.
- (–) Reimplementamos lo que `liburing` ofrece hecho (setup de anillos, *helpers* de SQE): más código propio que mantener y más superficie de error de bajo nivel.
- (–) Acceso a uniones del `io_uring_sqe` (ABI del kernel): obliga a desactivar `cppcoreguidelines-pro-type-union-access` (igual criterio que `pro-bounds-*` / `pro-type-vararg` para código de sistemas).

- (–) `wake()` queda como *no-op* hasta R6 (requiere registrar un `eventfd` en el anillo).

Alternativas consideradas

- **liburing vía `liburing-dev` (`apt`):** lo estándar, pero requiere `sudo` (no disponible) y añade una dependencia de sistema a instalar en cada entorno; descartado por la restricción del entorno.
- **liburing vendorizada (`FetchContent/ExternalProject`):** reproducible sin `sudo`, pero liburing usa *autotools* (genera cabeceras con `./configure`): wrapper frágil en CMake y más lento en CI; descartado por complejidad frente a la opción sin dependencias.

ADR-0013: Capa `nexus-wire` para el framing sobre conexión

(`FrameReader` / `FrameWriter`)

- **Estado:** aceptado
- **Fecha:** 2026-06-13

Contexto

Este ADR **refina el diseño detallado** (no cambia el diseño del protocolo): el diseño detallado original ubicaba `FrameReader` / `FrameWriter` en `protocol/frame.hpp`, pero el grafo de dependencias fija `nexus-protocol` → `common` y «protocolo puro (encode/decode, sin E/S ni async)». La decisión resuelve ese conflicto entre dos fuentes de verdad.

`FrameReader` / `FrameWriter` leen y escriben tramas longitud-prefijo (§7.2) sobre un `Socket` mediante el `Proactor`: necesitan `nexus-io` (`Socket`, `Proactor`) y corrutinas (`task<expected<T>>`). Colocarlos en `nexus-protocol` obligaría a que el protocolo —hoy puro encode/decode, testable y fuzzeable sin E/S— dependiera de `nexus-io` y de la maquinaria `async`, contradiciendo el grafo (`protocol` → `common`) y el principio de capas limpias. Los consumidores del framing-sobre-conexión (`broker`, `client`, `ingress`, `server`) ya dependen tanto de `io` como de `protocol`.

Decisión

Se crea un target nuevo, `nexus-wire` (`src/wire/`), que depende de **common + io + protocol** y aloja `Frame`, `FrameReader` y `FrameWriter`. `nexus-protocol` se mantiene **puro** (codec, `FrameHeader`, mensajes, códigos de error: solo→`common`, sin E/S ni `async`, independientemente testeable). `broker/client/ingress/server` dependen de `nexus-wire` para el transporte de tramas. El `Buffer` de `nexus-common` gana `extend` / `truncate` (cola mutable para `recv` sin copia intermedia), que usa `FrameReader`.

Consecuencias

- (+) `nexus-protocol` queda independiente de E/S: la (de)serialización se prueba y fuzzea sin tocar sockets ni `io_uring`.
- (+) Separación de responsabilidades clara (`protocol` = bytes; `wire` = tramas sobre conexión) y reutilizable por todos los consumidores.
- (+) Grafo acíclico y descendente (`wire` → {`common`, `io`, `protocol`}).
- (–) Un target más en el árbol (15 en total) y una desviación respecto a la ubicación prevista en el diseño detallado original.
- (–) `read_frame` expone el payload como vista **dentro del búfer del lector** (válida hasta la siguiente lectura): zero-copy a cambio de una invariante de vida documentada.

Alternativas consideradas

- `nexus-protocol` **depende de io** (`FrameReader` en `protocol/frame_io.hpp`): sigue el diseño detallado original y evita un target nuevo, pero rompe la pureza del protocolo (lo acopla a `io_uring/async`) y el grafo `protocol` → `common`; descartado por el autor a favor de capas limpias.

- `FrameReader` **genérico en** `nexus-io` (**sin conocer** `FrameHeader`): mantiene `io` → `common`, pero parte el concepto de «trama» en dos capas y se aparta del `read_frame()` → `Frame` del diseño detallado original; descartado.

ADR-0014: Modelo del log de Raft (índice = ordinal de entrada; término en sidecar)

- **Estado:** aceptado
- **Fecha:** 2026-06-14

Contexto

Este ADR **refina el diseño detallado** (no cambia ADR-0003): concreta *cómo* `RaftLog` es «una vista (`term`, `index`) sobre el `PartitionLog`» cuando el formato de `RecordBatch` (§5.4) no lleva campo de término y los offsets del log son **por record** (un batch abarca varios offsets).

ADR-0003 fija que «el log de Raft **es** el log de la partición». Al implementarlo surgen dos fricciones:

1. El `RecordBatch` (la unidad de replicación, §5.4) **no tiene** campo de término, y añadirse lo cambiaría el formato en disco y su CRC (toca todo `nexus-storage`).
2. El offset de partición es **por record** (un batch de N records ocupa N offsets), mientras que Raft razona con un **índice por entrada**. Igualar «índice = offset» obligaría a entradas de un solo record (mata el *batching*, contrario al §5.4) o a partir batches al truncar.

Decisión

Una **entrada de Raft** ↔ un `RecordBatch`. El **índice de Raft es el ordinal de la entrada** (1-based, +1 por entrada, contiguo), **espacio distinto** del offset de partición (por record). `RaftLog` envuelve un `PartitionLog` (que almacena los bytes de cada entrada y asigna sus offsets) y **posee el mapeo** `índice → (term, base_offset, last_offset, type)`.

El **término** (y el resto de metadatos por entrada) se persiste en un **sidecar** de registros de tamaño fijo (`raft-meta`, 25 B/entrada: `term:i64 | base_offset:i64 | last_offset:i64 | type:u8`), append-only y truncable; así el log de partición conserva `RecordBatch` **intactos** (el *fetch* del consumidor los lee sin desenvolver) y la recuperación del término no exige tocar el formato del batch. El *high-watermark* visible (espacio de offsets) = `last_offset` de la entrada en `commit_index`. La resolución de conflictos (`truncate_from(index)`) → `PartitionLog::truncate_to(base_offset(index))` (frontera de batch, ADR/C3) + truncado del sidecar.

Consecuencias

- (+) `RecordBatch` y `nexus-storage` quedan **sin cambios** (formato y CRC estables); el *fetch* sirve batches tal cual.
- (+) El algoritmo de Raft opera sobre índices contiguos +1 (formulación estándar del *paper*; sin aritmética de offsets).
- (+) El sidecar de tamaño fijo hace `term_at` / `last_term` / recuperación $O(1)$ /lineal triviales.
- (–) Dos espacios de coordenadas (índice de entrada vs offset de record) que la capa de partición reconcilia (el *high-watermark* traduce de uno a otro).
- (–) Un fichero sidecar por partición además del `.log` / `.index`.
- (–) El mapeo se persiste por duplicado parcial (`base` / `last` son derivables del log escaneándolo), a cambio de un `open` simple sin re-escanear el log.

Alternativas consideradas

- **Añadir** `leader_epoch` /**term** a la cabecera del `RecordBatch` (estilo Kafka v2): fiel a «el log es el log», pero cambia el formato en disco y el CRC, e impacta todo `nexus-storage` y sus tests; descartado para no reabrir un formato ya estabilizado en Fase 1.
- **Índice = offset+1 con entradas de un solo record**: iguala ambos espacios, pero elimina el *record batch* como unidad (contradice §5.4 y el modelo Kafka); descartado.
- **Anidar el** `RecordBatch` **del cliente dentro de un marco Raft** (term/type + payload como records del batch del log): término durable sin sidecar, pero cambia la semántica del offset a *por batch* (rompe el modelo por record de la Fase 1b) y obliga al *fetch* a desenvolverse; descartado.

ADR-0015: RaftNode como máquina de estados síncrona sin E/S (entradas→salidas)

- **Estado:** aceptado
- **Fecha:** 2026-06-14

Contexto

Este ADR **refina el diseño detallado** (no cambia ADR-0003 ni la mecánica de Raft): el diseño detallado original modela `RaftNode` con `propose / replicate_to` como **corrutinas** y un puerto `RaftTransport` (`task<expected<...>> send_append/send_vote`). La decisión reorganiza esa frontera sin alterar el algoritmo.

El objetivo nº1 de Fase 2 es la **correctitud demostrable** de Raft mediante **simulación determinista** con reloj y red virtuales (§8.1). Si `RaftNode` hace E/S por dentro (corrutinas que `co_await` un transporte), el reloj y la red quedan **dentro** del nodo y la prueba determinista exige inyectar un proactor/transport asíncrono y conducir corrutinas — friccionando con FIRST y con la reproducibilidad. El patrón estándar de implementaciones de Raft probadas (etcd/raft, TigerBeetle, ongaro) es un **núcleo sin E/S**: el nodo consume *entradas* (ticks de reloj, RPC recibidos) y produce *salidas* (mensajes a enviar, entradas a aplicar); el tiempo, la red y el disco viven **fuera**.

Decisión

`RaftNode` (`src/consensus/raft_node.hpp/.cpp`) es una **máquina de estados síncrona y sin E/S**: sin `RaftTransport`, sin corrutinas, sin reloj propio.

- **Entradas:** `tick(now)`, `on_request_vote(now, args) → reply`, `on_append_entries(now, args) → reply`, `on_request_vote_reply(now, from, reply)`, `on_append_entries_reply(now, from, reply)`, `propose(batch)` (C6).
- **Salidas:** una cola de mensajes salientes proactivos (`RaftMessage{from, to, payload}` con `payload = variant` de los RPC) drenable con `take_messages()`; las entradas confirmadas se exponen vía `commit_index()` (el broker lee el log hasta ahí).

El **reloj se inyecta** como `MonoTime now` en cada entrada (los *timeouts* de elección/heartbeat son aritmética pura sobre `now`); la **aleatorización** del *election timeout* usa un RNG sembrado (`random_seed + self`), reproducible. En producción, un adaptador del reactor traduce: temporizador→`tick`, RPC recibido→`on_*`, mensajes de `take_messages()`→envíos por `nexus-wire` (se cablea en la integración con el broker, C9). Respecto al diseño detallado original: se **añade** `now` a las firmas de los manejadores (determinismo) y se **sustituye** el par `propose: task<...> + RaftTransport` por `propose` síncrono + cola de salida (el adaptador asíncrono vive fuera del núcleo).

Consecuencias

- (+) Simulación **determinista** trivial: el arnés (C8) tiene un reloj virtual y una red virtual (cola de mensajes con retardos/particiones programables) y dirige N `RaftNode` reproduciblemente; cero hilos, cero E/S real en el test del algoritmo.
- (+) El núcleo de Raft se razona y prueba aislado de `io_uring`/corrutinas.

- (+) Encaja con *shared-nothing*: un `RaftNode` por partición, dirigido por su reactor.
- (–) Hace falta un **adaptador** (reactor↔nodo) que el diseño detallado original no nombraba (se añade en C9).
- (–) El emisor debe drenar `take_messages()` tras cada entrada (contrato explícito).

Alternativas consideradas

- `RaftNode` con **corrutinas** + `RaftTransport` (**diseño detallado literal**): menos piezas en producción, pero mete reloj/red dentro del nodo y complica la prueba determinista (el objetivo nº1); descartado.
- **Núcleo sin E/S con *callbacks* de envío** (en vez de cola drenable): equivalente, pero los *callbacks* reintroducen acoplamiento y dificultan inspeccionar las salidas en el test; se prefiere la cola explícita.

ADR-0016: `ReplicatedPartition` como tipo paralelo a `Partition` (composición de la pila Raft)

- **Estado:** aceptado
- **Fecha:** 2026-06-15

Contexto

Este ADR **refina el diseño detallado** (no cambia ADR-0003/0015): el diseño detallado original preveía **mutar** `Partition` para intercalar `RaftNode` y convertir `produce / fetch` en `task<expected<...>>`. La decisión mantiene `Partition` intacta y añade un tipo nuevo, sin alterar el algoritmo ni la frontera de E/S de ADR-0015.

En C9 hay que dar a la partición respaldo Raft (`acks=quorum` , `high-watermark = commit_index` , ADR-0003). La `Partition` de la Fase 1b funciona con `ack` local y sirve al broker e2e que ya pasa. Dos fricciones al mutarla in situ:

1. La pila de consenso es **autorreferencial** — `PartitionLog` $\leftarrow$ `RaftLog` (ref) $\leftarrow$ `RaftNode` (ref)—, así que un tipo con esos miembros por valor no sería **movible** sin invalidar referencias internas.
2. `RaftNode` es una **FSM sin E/S** (ADR-0015) que un portador externo debe conducir (`tick / on_* / take_messages`), contrato que aún no existe en el broker (llega con el *routing* multi-reactor, C11).

Mutar `Partition` ahora mezclaría ambos modelos (ack local vs quorum) en un tipo en uso y arriesgaría el camino e2e verde.

Decisión

Se añade `ReplicatedPartition` (`src/broker/replicated_partition.{hpp,cpp}`) como **tipo paralelo** a `Partition` , sin tocar esta última. Compone la pila por `unique_ptr` (`PartitionLog` + `RaftLog` + `RaftNode`): las direcciones de heap son estables, por lo que las referencias internas siguen válidas y el objeto es **movible** (move por defecto, copia borrada).

`produce` (solo líder; `Unsupported` si no) aplica la idempotencia por productor (§5.9, reutilizada de `Partition`) y **propone** la entrada al `RaftNode` , traduciendo el índice de Raft asignado a su último offset de partición vía `RaftLog::offsets_at` ; `high_watermark()` = offset (exclusivo) de la entrada en `commit_index` (0 $\Rightarrow$ `log_start_offset`). La FSM **no se conduce sola**: `raft()` expone la superficie para que el portador (reactor o arnés) la dirija; en C9 se valida con **enrutado directo/simulado** (test con reloj y red virtuales que comprueba que una escritura no es visible hasta el quorum). El **cambio en caliente** del broker a `ReplicatedPartition` (con transporte real) se difiere a **C11**.

Consecuencias

- (+) `Partition` y el broker e2e quedan **intactos** (sin riesgo en el camino verde); la unidad de partición replicada queda lista y probada aislada.
- (+) Tipo **movible** pese a la pila autorreferencial (los `unique_ptr` fijan las direcciones).

- (+) Reutiliza idempotencia y `PartitionLog` / `RaftLog` sin duplicar lógica.
- (+) `produce` síncrono (la FSM no hace E/S, ADR-0015); cuando llegue el reactor, el portador drena `take_messages()` y espera a `commit_index`.
- (–) **Dos** tipos de partición conviviendo hasta C11 (deuda temporal explícita).
- (–) El cliente de `ReplicatedPartition` debe conducir `raft()` (contrato externo, como en ADR-0015).

Alternativas consideradas

- **Mutar `Partition` (diseño detallado literal):** un solo tipo, pero rompe su movilidad por la pila autorreferencial, mezcla ack local/quorum en un tipo en uso y arriesga el e2e verde antes de tener el portador (C11); descartado.
- **`RaftNode` por valor dentro de la partición:** evita una indirección, pero el tipo deja de ser movable (referencias internas colgantes al mover) y complica almacenarlo en contenedores del broker; descartado a favor de los `unique_ptr`.
- **Fusionar ambos tras C11** (un tipo con modo local/quorum): posible evolución futura; hoy se prefiere separar para no acoplar la Fase 1b a la 2.

ADR-0017: Target `nexus-telemetry` para observabilidad (métricas/logs) bajo el broker

- **Estado:** aceptado
- **Fecha:** 2026-06-17

Contexto

Este ADR **refina el diseño detallado** (no cambia ninguna decisión de arquitectura previa): el diseño detallado original ubicaba `metrics.{hpp,cpp}` dentro de `nexus-server`, que es el **ejecutable** del broker. La decisión mueve la observabilidad a una **biblioteca** propia para respetar el grafo de dependencias.

La `MetricsRegistry` es **THREAD-SAFE** y la **alimentan** capas del plano de datos (broker/reactor: tasa de produce/fetch, *lag*, `commit_index` /term de Raft, latencias) mientras que la **exponen** el gateway REST (`nexus-ingress`, que tiene un `MetricsRegistry`) y el servidor (`/metrics`). Si viviera en `nexus-server` (un *exe*, no enlazable como dependencia) ninguna biblioteca inferior podría registrar métricas; y colocarla en `nexus-ingress` crearía una dependencia ascendente `broker → ingress` (ciclo de capas). Lo mismo aplica al logger JSON estructurado (lo usa todo el árbol). `nexus-common` se reserva para vocabulario mínimo (tipos, errores, bytes); una registry con mutex, familias y render Prometheus no encaja ahí.

Decisión

Se crea el target `nexus-telemetry` (`src/telemetry/`), que **depende solo de** `nexus-common` y se sitúa **bajo** broker/ingress/server en el grafo. Aloja `MetricsRegistry` (contadores/gauges/histogramas + exposición Prometheus) y, más adelante, el logger JSON estructurado. La registry es THREAD-SAFE con un **mutex que protege solo la estructura** (alta de series y recorrido en `render`); las **actualizaciones de valor** (`inc / set / observe`) son **atómicas y sin candado** (lock-free en el camino caliente). Cualquier capa (broker, reactor, ingress, server) enlaza `nexus-telemetry` para registrar o exponer.

Consecuencias

- (+) Grafo de dependencias **acíclico**: el plano de datos registra sin depender de capas superiores.
- (+) Observabilidad **testable en aislamiento** (sin red ni servidor).
- (+) `nexus-common` se mantiene mínimo.
- (+) Registro de valores **lock-free**; solo el alta de una serie nueva toma el mutex.
- (–) Un target más que mantener.
- (–) El *sharding* por núcleo de los contadores (cero contención total) queda como optimización futura medida; hoy basta con atómicos.

Alternativas consideradas

- `metrics` en `nexus-server` (**diseño detallado literal**): imposible que las bibliotecas inferiores registren métricas (un *exe* no es dependencia); descartado.
- `metrics` en `nexus-ingress` : crea el ciclo de capas `broker → ingress` ; descartado.

- `metrics` **en** `nexus-common` : mete infraestructura con estado (mutex, familias, render) en la capa de vocabulario mínimo; descartado por cohesión.

ADR-0018: REST admin por puerto/adaptador (AdminService en ingress, AdminApi en server)

- **Estado:** aceptado
- **Fecha:** 2026-06-18

Contexto

Este ADR **refina el diseño detallado** (no cambia ninguna decisión de arquitectura previa): el diseño detallado original ubicaba `admin_api.{hpp,cpp}` dentro de `nexus-server` y, a la vez, hacía que `RestGateway` (en `nexus-ingress`) tuviera un `AdminApi`. Eso crea un **ciclo de capas** `ingress → server` (la pasarela usa la API) y `server → ingress` (el `Server` posee la `Ingress`). La decisión rompe el ciclo con **inversión de dependencias**, igual que ADR-0017 hizo con la telemetría.

El `RestGateway` (plano de ingress) traduce HTTP↔dominio y necesita ejecutar operaciones de administración (crear/borrar/describir/listar topics y grupos). La lógica de esas operaciones vive sobre `TopicManager / GroupCoordinator`, que son del **broker** (capa inferior a server, pero `ingress` **no** depende de broker en el grafo: `ingress → common, io, protocol, wire`). Si el gateway dependiera de un `AdminApi` concreto alojado en `nexus-server`, `ingress` dependería de `server` (que ya depende de `ingress`): ciclo.

Decisión

Se define el **puerto** `AdminService` (interfaz abstracta) y sus **DTOs** (`CreateTopicSpec`, `TopicSummary`, `PartitionInfo`, `TopicDescription`, `GroupSummary`) en `nexus-ingress` (`ingress/admin_service.hpp`), como tipos de datos planos sin dependencia del broker. El `RestGateway` depende solo de `AdminService`. El **adaptador** concreto `AdminApi` (en `nexus-server`, `server/admin_api.{hpp,cpp}`) **implementa** `AdminService` sobre `TopicManager` y un *group lister* inyectado (`std::function`), traduciendo los tipos del broker a los DTOs del puerto. La enumeración de grupos es **reactor-local** (cada `GroupCoordinator` vive en su reactor), así que se inyecta como función desde el cableado del server (I14), no se acopla al puerto. Se añade a `TopicManager` un accesor de observabilidad `list_metadata()` (control-plane).

Consecuencias

- (+) Grafo **acíclico**: `ingress` define el puerto (sin nuevas dependencias), `server` implementa el adaptador (ya depende de `ingress` y `broker`).
- (+) `RestGateway` es **testable** con un doble de `AdminService` sin levantar broker.
- (+) Los DTOs del REST quedan **desacoplados** de los tipos internos (ADR-0009: traducción en el borde).
- (–) Una capa de traducción DTO↔dominio en el adaptador.
- (–) El listado de grupos cross-core real se materializa en el cableado (I14), no en el puerto.

Alternativas consideradas

- `AdminApi` **concreto en** `nexus-server`, **referenciado por** `ingress` (**diseño detallado literal**): crea el ciclo `ingress ↔ server`; descartado.

- `AdminApi` en `nexus-broker` : tendría que implementar la interfaz `AdminService` de `ingress` ⇒ `broker` → `ingress` (dependencia **ascendente**, prohibida); descartado.
- `RestGateway` como router genérico de *handlers* (`std::function`): rompe el ciclo, pero diluye el contrato de administración en *callbacks* sin tipado; el puerto explícito documenta mejor la API y es más fiel al diseño detallado original.

ADR-0019: TLS opcional vía OpenSSL con puente de BIOs de memoria sobre el Proactor

- **Estado:** aceptado
- **Fecha:** 2026-06-19

Refina el diseño detallado (no cambia ninguna decisión previa): el diseño detallado original ya situaba `TlsContext / TlsConnection` sobre OpenSSL en `nexus-ingress`. Este ADR fija **cómo** se integra OpenSSL (síncrono por diseño) con el modelo `proactor` asíncrono y **qué grado de dependencia** es OpenSSL en el build.

Contexto

El plano de `ingress` (ADR-0006) termina TLS 1.3 y, intra-clúster, mTLS. La librería elegida es OpenSSL (madura, ubicua), pero su API de E/S es **bloqueante/síncrona** y `NexusMQ` es **thread-per-core asíncrono** sobre un `Proactor` (`io_uring`, ADR-0005/0002). Además, OpenSSL es una dependencia de sistema pesada que no siempre está presente (por ejemplo, entornos mínimos de CI o builds de desarrollo), y el broker debe poder **arrancar en claro** para pruebas locales y despliegues sin TLS.

Decisión

Se toman tres decisiones coordinadas:

1. **Acoplamiento opcional.** El build usa `find_package(OpenSSL)`; si está presente, compila `ingress/tls.{hpp,cpp}` y define `NEXUS_HAVE_OPENSSL` (público). Si no, el plano TLS se **omite por completo** (cabecera y `.cpp` guardados con `#ifdef`, tests con `GTEST_SKIP`) y el broker funciona en claro. El CI instala `libssl-dev` para **sí** ejercer el path TLS (compilación, tests, sanitizers y clang-tidy).
2. **Puente de BIOs de memoria.** `TlsConnection` no deja que OpenSSL toque el descriptor; usa dos `BIO` de memoria (`rbio / wbio`). El bucle de `handshake / async_recv / async_send` llama a la primitiva OpenSSL y, ante `WANT_READ / WANT_WRITE`, **vacía** el `wbio` al socket y **alimenta** el `rbio` desde el socket mediante el `Proactor` asíncrono. Así la criptografía corre en línea pero el transporte es no bloqueante.
3. **Fábricas en el contexto.** `TlsContext::server / client` cargan material PEM y configuran la verificación (mTLS = `SSL_VERIFY_PEER|FAIL_IF_NO_PEER_CERT` + CA); `accept / connect` crean la `TlsConnection` fijando el rol del handshake. `peer_principal()` extrae el CN del certificado del par para authz.

Consecuencias

- (+) El núcleo asíncrono **no se contamina** con E/S bloqueante; TLS encaja tras el mismo `Proactor` que el resto.
- (+) Build y despliegue **sin OpenSSL** siguen siendo válidos (degradación a claro), cumpliendo coste-cero (ADR-0008).
- (+) `TlsContext / TlsConnection` se prueban por loopback con certificados autofirmados generados en el test (una vía, mTLS con principal, y fallo de verificación).

- (–) El puente BIO añade una copia intermedia ciphertext↔socket (aceptable; el throughput TLS lo domina la cifra, no la copia).
- (–) La compilación condicional obliga a `#ifdef` en cabecera, `.cpp` y tests.

Alternativas consideradas

- **BIO propio sobre el Proactor (custom BIO method):** evita una copia, pero exige implementar un `BIO_METHOD` con semántica de reintento correcta y es mucho más frágil; el puente de BIOs de memoria es el patrón canónico y suficiente.
- **OpenSSL como dependencia obligatoria (vcpkg/sistema):** simplifica el build, pero rompe coste-cero y el arranque en claro para desarrollo; descartado a favor del acoplamiento opcional.
- **Otra librería (BearSSL/mbedtls/rustls-ffi):** menor huella, pero peor ergonomía/cobertura y menos familiar; OpenSSL ya estaba fijado en el diseño detallado original.

ADR-0020: *Binding* de Python vía ABI C estable (`nexus-ffi` + `ctypes`) en lugar de pybind11

- **Estado:** aceptado
- **Fecha:** 2026-06-20

Ajusta el alcance previsto (la fase F9 contemplaba «*binding* Python (pybind11) si el entorno lo soporta»): fija **cómo** se expone NexusMQ a Python cuando el entorno **no** soporta construir extensiones de CPython.

Contexto

F9 (Fase 4) pide un *binding* de Python. La opción por defecto (pybind11) compila una **extensión nativa de CPython**, que necesita las **cabeceras de desarrollo de Python** (`Python.h` , `pyconfig.h`) y una *toolchain* de extensiones. El entorno de desarrollo y los *runners* de CI **no** las tienen (solo el intérprete; sin `python3-dev` , sin `pip` , sin `sudo` para instalarlas), de modo que una extensión pybind11 **no se podría compilar ni verificar** aquí — chocaría con la puerta de calidad (TDD, «nunca pushear en rojo», verificar en local en los dos compiladores).

Decisión

Exponer un subconjunto **puro y transversal** del núcleo tras una **frontera C** `extern "C"` en un target nuevo `nexus-ffi` , compilado como **librería compartida** (`libnexus-ffi.so`), y consumirla desde Python con `ctypes` (módulo `bindings/python/nexusmq.py`). La ABI (`src/ffi/nexus_ffi.h`) cubre: versión, **CRC32C** (integridad de records) y el codec de **contexto de traza W3C** `traceparent` (F8). Las ventajas son tres:

1. Se compila con el **propio compilador de C++** (sin cabeceras de Python), así que entra en la puerta de calidad (GCC/Clang/ASan + clang-tidy sobre `src/ffi/nexus_ffi.cpp`).
2. Se verifica con **cualquier** intérprete de Python presente (prueba de humo `bindings/python/smoke_test.py` con `ctypes`).
3. La ABI C es **estable** y sirve a otros lenguajes (Rust/Go/Node FFI), no solo a Python.

Para enlazar los archivos estáticos del núcleo dentro de la `.so` , `nexus-common` y `nexus-telemetry` se marcan `POSITION_INDEPENDENT_CODE` .

Consecuencias

- (+) *Binding* **realmente verificado** en este entorno (ABI por GoogleTest en la puerta de calidad; lado Python por la prueba de humo), no código sin compilar.
- (+) Sin dependencias nuevas de build (ni pybind11 ni `python3-dev`); CI intacto.
- (+) La frontera C es reutilizable por otros lenguajes.
- (–) Ergonomía más baja que pybind11 (gestión manual de tipos/ `ctypes` , sin objetos Python ricos automáticos) y superficie acotada a funciones puras (no expone aún el cliente productor/consumidor).
- (–) Introduce la primera librería **compartida** del árbol (y PIC en dos targets base).

Alternativas consideradas

- **pybind11 (extensión de CPython):** mejor ergonomía, pero **no construible ni verificable** sin `python3-dev /toolchain` en este entorno/CI; quedaría como código sin compilar, contra la normativa. Reconsiderable si el entorno gana las cabeceras de desarrollo.
- **Cabeceras de Python vendoreadas a mano (prefijo local, como OpenSSL en ADR-0019):** `pyconfig.h` es **generado por la build de CPython** y específico de plataforma; replicarlo a mano es frágil y los *runners* de CI tampoco lo tendrían. Descartado.
- **Servicio REST + cliente HTTP en Python:** ya existe el gateway REST (Fase 3), pero eso es interoperabilidad de red, no un *binding* en proceso; complementario, no sustituto.

ADR-0021: Backend IOCP (Windows) — diseño fijado, implementación diferida

- **Estado:** reemplazado por adr-0022
- **Fecha:** 2026-06-20

Cierra F10 (Fase 4, *stretch*, marcada «[limitado] — no verificable en este entorno»): decide **cómo** encajaría IOCP en la arquitectura y **por qué** la implementación se difiere.

Contexto

F10 pide un backend de E/S para **Windows** (IOCP) en `nexus-io` y un preset `windows-msvc`. IOCP es, como `io_uring`, un modelo **proactor** (se inicia la operación y el SO notifica al completarse), así que conceptualmente encaja en el puerto `Proactor` (ADR-0002/0005) sin tocar el bucle del reactor. Pero hay dos obstáculos duros:

1. **No es verificable en este entorno:** el desarrollo y el CI son **solo Linux** (WSL), sin *toolchain* MSVC ni Windows SDK; no se puede compilar ni probar nada de Win32 aquí, y la normativa prohíbe *pushear* código no verificado como si funcionara.
2. **Alcance real:** NexusMQ es **Linux-nativo de arriba abajo** — `io_uring`, `O_DIRECT`, `eventfd`, `sockets` POSIX, `fcntl`, `file descriptors` `int` en el propio puerto `Proactor`. Un backend IOCP útil exige **portar también File y Socket** a Win32 (`HANDLE / SOCKET`, `ReadFile / WriteFile` con `OVERLAPPED`, `Winsock`, `AcceptEx`), un esfuerzo transversal desproporcionado para un ítem *stretch*.

Decisión

Fijar el diseño y diferir la implementación.

1. Se documenta el mapeo IOCP → `Proactor` operación a operación en `src/io/iocp_backend.hpp` (`IocpBackend` : `Proactor`, *pimpl* que oculta `<windows.h>` / `<winsock2.h>`): `CreateIoCompletionPort` para el puerto y asociación de cada `HANDLE / SOCKET`; `ReadFile / WriteFile` (con `Offset / OffsetHigh`), `WSARecv / WSASend`, `AcceptEx`, `FlushFileBuffers`, *waitable timers*; `GetQueuedCompletionStatusEx` para drenar *completions* en **lote** (espera con *timeout* hasta el `deadline`); `PostQueuedCompletionStatus` para *wake*; traducción de `dwNumberOfBytesTransferred / GetLastError` al `result` estilo `io_uring` del puerto.
2. Todo el encabezado va bajo `#ifdef _WIN32` y **sin** `.cpp`: en Linux es vacío, no entra en la build ni en la puerta de calidad (no rompe nada).
3. Se añade el preset `windows-msvc` como **andamio**, oculto fuera de Windows por `condition`.

Consecuencias

- (+) El diseño Windows queda **registrado y concreto** (declaración + mapeo), demostrando que el puerto `Proactor` es portable a otro proactor sin cambiar el reactor.
- (+) Cero impacto en el árbol Linux y en CI (encabezado vacío bajo `#ifdef`, preset condicionado).
- (+) Honestidad de verificación: no se publica un IOCP «de mentira» sin compilar.

- (–) F10 **no** entrega un backend funcional: queda como diseño + andamio.
- (–) El port real requerirá, antes que `IocpBackend`, abstraer `File / Socket` del POSIX (trabajo futuro fuera de Fase 4).

Alternativas consideradas

- **Implementar `IocpBackend` completo (con `.cpp`) ahora:** imposible de compilar/verificar aquí; sería código no probado contra la normativa (TDD, «nunca en rojo»). Descartado.
- **Job de CI en *runner* Windows:** GitHub ofrece `windows-latest`, pero el árbol entero no compila en MSVC (POSIX por doquier); habilitar un build Windows real es el *port* completo, no F10. Descartado por alcance.
- **Capa de compatibilidad POSIX en Windows (Cygwin/MSYS2 o Winsock+wepoll):** permitiría reusar el código POSIX, pero no es IOCP nativo (objetivo de F10) y añade dependencias; descartado.

ADR-0022: Backend IOCP (Windows) — implementado y compile-verificado con MinGW (reemplaza ADR-0021)

- **Estado:** reemplazado por adr-0023
- **Fecha:** 2026-06-20

Reemplaza ADR-0021. Aquel difirió la implementación IOCP por considerarla *no verificable en este entorno* (sin MSVC/SDK; CI solo Linux). Esa premisa **ya no se sostiene**: el entorno **sí** dispone (vía `apt`) del cross-compiler **MinGW-w64** con headers Win32 reales, que permite **compilar y enlazar** el código Windows sin una máquina Windows. Decisión del autor: llevar Windows al mismo nivel de desarrollo que Linux.

Contexto

ADR-0021 dejó `iocp_backend.hpp` como diseño bajo `#ifdef _WIN32` y `File / Socket` como POSIX puro, con `int fd` en el puerto `Proactor`. El obstáculo declarado era la verificación. Con MinGW-w64 disponible, el código Win32 se puede compilar con `-Wall -Wextra -Wpedantic -Werror` contra los headers reales (`<windows.h>`, `<winsock2.h>`, `<mswsock.h>`) y enlazar contra `ws2_32 / mswsock` — cubriendo la inmensa mayoría de errores (firmas, uso de API, tipos). Solo queda fuera la verificación en **runtime** (requiere Windows real), que se asume como deuda explícita acotada.

Decisión

Implementar el port Windows de la capa de E/S y verificarlo por compilación+enlace con MinGW.

1. `NativeHandle` (= `int` en POSIX, `uintptr_t` en Windows) sustituye a `int fd` en el puerto `Proactor`, `File` y `Socket`; el `IoResult` del `Completion` se ensancha a `intptr_t` para alojar un `SOCKET / HANDLE` aceptado (en Linux, sin cambio de comportamiento).
2. `File` y `Socket / Listener` ganan su rama `#if defined(_WIN32)` (Win32: `CreateFileA / ReadFile / WriteFile` CON `OVERLAPPED`, `FlushFileBuffers`, `SetEndOfFile`, `GetFileSizeEx`, `FILE_FLAG_NO_BUFFERING` como `O_DIRECT`; Winsock: `socket / connect / bind / closesocket`, `WSAStartup` `RAII`).
3. `iocp_backend.cpp` implementa `IocpBackend` sobre `CreateIoCompletionPort / GetQueuedCompletionStatusEx / PostQueuedCompletionStatus`, CON `AcceptEx`, temporizadores por *timeout* de la espera y la maquinaria Win32 confinada en un *pimpl* `Port`.
4. CMake compila `iocp_backend.cpp` y enlaza Winsock en `WIN32`.
5. `tools/verify-windows-io.sh` reproduce la verificación cruzada.

Consecuencias

- (+) `nexus-io` (la capa que aísla la plataforma) es **Windows-capaz y compile/enlace-verificada**, demostrando que el puerto `Proactor` es portable a otro proactor sin tocar el reactor.
- (+) Cero impacto en Linux: el cambio `NativeHandle / IoResult` es *type-identical* (alias de `int / intptr_t`), 599 tests verdes en GCC y Clang/libc++.

- (+) La verificación es **honest**a: compila y enlaza con toolchain Windows real, no es código «a ciegas».
- (–) **Runtime no verificado** en Windows (sin máquina/CI Windows): deuda explícita acotada — un job `windows-latest` lo cerraría al reactivar el CI.
- (–) El **resto del servidor** (reactor *pinning* con `pthread_setaffinity_np`, `nexusrd` con señales POSIX/eventfd) sigue siendo Linux-nativo: un `nexusrd` Windows completo es trabajo futuro fuera de este alcance; lo entregado es la **capa de E/S** portable.

Alternativas consideradas

- **Mantener ADR-0021 (solo diseño)**: desaprovecha que MinGW está disponible; deja Windows sin avanzar pese a poder verificarlo. Descartado por decisión del autor.
- **Solo refactor portable (sin los `.cpp` Win32)**: verificable en Linux pero no entrega el backend. Descartado a favor del port completo.
- **Job de CI en `windows-latest` para runtime**: cerraría la deuda de runtime, pero el CI está desactivado por cuota (se reactiva al publicar) y el árbol completo aún no compila en Windows (POSIX fuera de `nexus-io`). Aplazado.

ADR-0023: Backend IOCP (Windows) — verificado en runtime sobre Windows con MSVC (reemplaza ADR-0022)

- **Estado:** aceptado
- **Fecha:** 2026-06-20

Reemplaza ADR-0022. Aquel **implementó y compile-verificó** el backend IOCP con MinGW-w64, pero dejó como deuda explícita acotada la verificación en **runtime** («Runtime no verificado en Windows ... un job `windows-latest` lo cerraría»). Esa deuda **ya no aplica**: el código se ha **ejecutado** en una máquina Windows real con MSVC y funciona. El diseño no cambia; ADR-0023 lo eleva de *compile-verificado* a *runtime-verificado* (mismo patrón que ADR-0021→0022).

Contexto

ADR-0022 cerró con `nexus-io` compile/enlace-verificado contra headers Win32 reales vía cross-compiler, pero **nunca ejecutado** (sin MSVC ni máquina Windows). MinGW (GCC) no ve las divergencias de MSVC (por ejemplo, `__builtin_*`, atributos `[[gnu::*]]`) ni cubre el **comportamiento en ejecución** (asociación de handles/sockets al puerto, `AcceptEx` + `SO_UPDATE_ACCEPT_CONTEXT`, `OVERLAPPED` en vuelo, drenado de `GetQueuedCompletionStatusEx`, temporizadores por *timeout*). El autor pasa a trabajar en **Windows real** con **Visual Studio 2026** (MSVC 19.51, CMake/Ninja *bundled*), lo que permite cerrar la deuda.

Decisión

Cerrar la deuda de runtime ejecutando `nexus-io` en Windows real con MSVC, mediante un arnés de verificación dedicado (en lugar de un job de CI: el CI sigue desactivado por cuota y el árbol completo no compila en Windows).

1. El preset `windows-msvc` con `-D NEXUS_BUILD_TESTS=OFF` compila **solo** `nexus-io` (+ `nexus-common`) con MSVC `/W4 /WX /permissive-`.
2. `tools/wincheck` es un ejecutable **Windows-only** (`CMakeLists` bajo `if(WIN32)`, **sin** `ctest` ni `ReactorPool` —que es POSIX—) enlazado a `nexus::io` que **ejercita** la capa: `File` bloqueante (`round-trip` `write_at` / `read_at`, `size` / `sync` / `truncate`) y `File` con E/S directa (`FILE_FLAG_NO_BUFFERING`, búfer alineado a 4 KiB); **eco IOCP por loopback** end-to-end (`Listener::bind` / `Socket::connect` + `AcceptEx` / `WSARecv` / `WSASend`) con cierre limpio (EOF), bombeando `wait_completions` / `run_completions` a mano con un **driver de corrutinas** propio (`sync_wait` no sirve: la *task* se suspende en E/S asíncrona); y `submit_timer` (deadline corto que vence y reanuda).
3. **Resultado: los 4 casos PASAN** con MSVC 19.51 (VS 2026).

Consecuencias

- (+) `nexus-io` deja de tener deuda de runtime: la portabilidad del puerto `Proactor` a otro proactor (IOCP) queda demostrada **ejecutándose**, no solo compilando.

- (+) MSVC `/W4 /WX` validó lo que MinGW no veía y reveló **una sola** divergencia real, de portabilidad de detección de *CPU features* en `nexus-common ( crc32c.cpp` :
`__builtin_cpu_supports / [[gnu::target("sse4.2")]]` de GCC → `__cpuid` + intrínsecos SSE4.2 incondicionales en MSVC, tras `#if defined(_MSC_VER)`); el camino GCC/Clang queda intacto.
- (+) El **diseño de ADR-0022 se confirma sin cambios**: ningún ajuste en el código IOCP/ `File` / `Socket` fue necesario para que funcionara en runtime (las rutas Win32/Winsock estaban correctas).
- (–) La verificación es **manual** (ejecutar `tools/wincheck`), no automática: al reactivar el CI, un job `windows-latest` debería ejecutarlo para evitar regresiones (tarea de cierre).
- (–) Sigue siendo **solo nexus-io** : el resto del servidor (reactor *pinning* con `pthread_setaffinity_np` , `nexusd` con señales POSIX/eventfd, backend `io_uring`) es Linux-nativo; un `nexusd` Windows completo queda fuera de alcance.

Alternativas consideradas

- **Mantener ADR-0022 (runtime como deuda)**: ya no se sostiene —hay máquina Windows con MSVC disponible—; dejar la capa sin ejecutar nunca era el único hueco de F10. Descartado.
- **Job de CI en windows-latest en vez de arnés local**: cerraría la regresión de forma automática, pero el CI está desactivado por cuota y el árbol completo no compila en Windows; el arnés local es **ejecutable hoy**. No es excluyente: ese job ejecutaría precisamente `tools/wincheck` . Aplazado.
- **Convertir wincheck en test de ctest (GoogleTest)**: mezclaría la verificación Windows con la suite Linux (que no compila en Windows) y arrastraría el *toolchain* de tests; un **ejecutable autónomo** es más simple, aislado y no depende de `NEXUS_BUILD_TESTS` . Descartado.

ADR-0024: Compactación del log de Raft por snapshot (base de snapshot en `RaftLog`)

- **Estado:** aceptado
- **Fecha:** 2026-06-20

Contexto

Bajo Raft por partición (ADR-0003), el **log replicado es el WAL** (glosario): crece sin techo aunque sus entradas más antiguas ya estén *committed* y aplicadas. Sin compactación, (1) el log de cada partición crece indefinidamente y (2) un seguidor que se reincorpora muy rezagado obligaría al líder a re-replicar desde el índice 1. El paper de Raft resuelve ambos con **snapshots** (§7): se toma una imagen del estado hasta `last_included_index`, se descarta el prefijo del log cubierto por ella y un seguidor demasiado atrás se pone al día con `InstallSnapshot` en vez de `AppendEntries`. El RPC `InstallSnapshot` y el tipo `Snapshot` ya existían (ADR-0014/Fase 2), pero `RaftLog` era **denso desde el índice 1** (índice $i \leftrightarrow \text{entries}[i-1]$), sin forma de descartar un prefijo ni de recuperar `term_at(last_included_index)` tras hacerlo.

Decisión

Dotar a `RaftLog` de una **base de snapshot** (`last_included_index`, `last_included_term`, `last_included_offset`) y compactar contra ella en tres planos coherentes:

1. **Modelo lógico (exacto).** `RaftLog` recuerda `snapshot_index/snapshot_term`; el índice i vive en `entries[i - snapshot_index - 1]`, `last_index() = snapshot_index + entries.size()`, `term_at(snapshot_index) = snapshot_term` y `term_at(i < snapshot_index)` es `Compacted`. `compact_to(index)` descarta el prefijo aplicado **exactamente** en `index` (el llamante garantiza `index ≤ commit_index`).
2. **Persistencia.** La base de snapshot se guarda en un **sidecar dedicado** `raft-snapshot` (un único registro de tamaño fijo con **CRC32C**, mismo patrón que `RaftStateStore` de D1), separado del sidecar de metadatos por entrada (`raft-meta`). Al abrir, `RaftLog::open` lee la base y reconstruye el espacio de índices; la comprobación de coherencia con el `PartitionLog` se generaliza para admitir un `log_start_offset` ya recortado.
3. **Reclamación física (best-effort).** `PartitionLog::truncate_prefix_to(offset)` borra los segmentos **sellados enteros** cuyo rango queda por debajo de `offset` (nunca el activo, nunca a media trama), avanzando `log_start_offset`. La compactación lógica es exacta en el índice; la física libera disco por segmentos completos (puede quedar algo por encima de `log_start_offset` hasta que el segmento rote). Es la pieza simétrica de `enforce_retention`, pero recortando a un **offset preciso**.

La **puesta al día de un seguidor** muy rezagado (cuyo `next_index ≤ snapshot_index` del líder) se hace con `InstallSnapshot`: el seguidor adopta la base de snapshot del líder y reanuda la replicación normal desde ahí. Coherente con ADR-0015 (FSM sin E/S): instalar un snapshot es una transición síncrona que reposiciona la base del log; el portador hace la E/S.

Alcance / FSM del broker. En NexusMQ la "máquina de estados" aplicada **es el propio log de particiones** (los `RecordBatch`); el `state` del `Snapshot` no es una materialización aparte, sino la **base** (`index`, `term`,

`offset`) que mantiene consistente el espacio de offsets entre réplicas. La visibilidad de los **datos** antiguos para consumidores la gobierna la **retención** (ADR de storage), ortogonal a la compactación del WAL de Raft.

Consecuencias

- (+) El log de Raft deja de crecer sin techo: una réplica acota su tamaño compactando el prefijo aplicado, y la base sobrevive a reinicios.
- (+) Reaprovecha el patrón de durabilidad de D1 (registro fijo + CRC32C + `fsync`) y la maquinaria de borrado de segmentos del `PartitionLog`.
- (+) El RPC `InstallSnapshot` ya existente encuentra por fin un modelo donde encajar.
- (–) La reclamación física es por segmentos enteros (no exacta al byte): aceptable y estándar.
- (–) La puesta al día por `InstallSnapshot` en el seguidor exige reposicionar el `PartitionLog` a una base vacía: se implementa de forma incremental (D2b) y la compactación **no se dispara automáticamente** hasta cablearla con seguridad en el servidor vivo (D3), de modo que el hueco queda latente, no activo.

Alternativas consideradas

- **No compactar (retención del WAL como único freno):** la retención borra datos antiguos, pero no resuelve el espacio de índices de Raft ni la puesta al día de un seguidor rezagado por debajo del punto de borrado. Insuficiente. Descartada.
- **Snapshot como materialización separada del estado (fichero de imagen):** clásico del paper, pero en un broker el estado aplicado es el propio log; duplicarlo en una imagen aparte sería redundante y costoso. Se adopta la base `(index, term, offset)` + datos en el `PartitionLog`. Descartada.
- **Recorte físico exacto al byte (partir segmentos):** complicaría el `PartitionLog` (segmentos inmutables una vez sellados) por una ganancia marginal. Se recorta por segmentos enteros. Descartada.

ADR-0025: Activación en producción del stack Raft + multi-reactor con transporte inter-nodo real

- **Estado:** aceptado
- **Fecha:** 2026-06-21

Contexto

Las fases previas dejaron listas, pero **sin enchufar al servidor vivo**, varias piezas: el log y la FSM de Raft (ADR-0014/0015), la `ReplicatedPartition` (ADR-0016), el `routing cross-core` (`PartitionRouter / call_on`), el `ReactorPool thread-per-core` (ADR-0005) y la persistencia (D1) y compactación (D2) del estado de Raft.

El binario `nexusd` corre hoy con **un único Reactor** y `Partition` simples (*ack* local); los RPC de Raft solo circulan por la **red virtual** de los tests (simulación determinista); nadie persiste el estado de Raft ni dispara la compactación en producción. D3 cierra esa deuda diferida por *fasing*: **activar** el stack en `nexusd` con **transporte real** entre nodos. No reescribe nada; es integración más inyección de un transporte de red.

Decisión

Cuatro piezas coherentes, implementadas de forma incremental (D3.1..D3.7), siempre verde:

1. **Plano inter-nodo separado del plano de cliente.** Los RPC de Raft viajan por su **propio plano** (su listener, sus conexiones persistentes entre nodos), distinto del plano de datos del cliente (ADR-0004/0013). Un **sobre de wire de Raft** rutea cada `RaftMessage` y el sobre identifica la **réplica de partición destino** (`topic, partition`) para entregar el RPC al `RaftNode` correcto del nodo receptor.
2. **Portador por partición, afinado al reactor dueño.** Cada réplica la conduce un **portador** (`RaftCarrier`) que vive en el reactor dueño de la partición (`PartitionRouter: core = partition % cores`): un **tick** periódico **local** avanza la FSM, drena `take_messages()` y entrega cada mensaje al transporte; los RPC entrantes se enrutan al reactor dueño (`call_on`) y se aplican con `on_*`. El camino del **tick** es local al reactor de la partición (sin cross-core), respetando shared-nothing: no hay estado de Raft compartido entre núcleos.
3. **Persistencia y compactación en el lazo del portador.** Al abrir la réplica se carga `RaftStateStore::load()` → `restore_persistent_state` (D1); **antes** de transportar `take_messages()`, si `persistent_state_dirty()`, se hace `save()` con `fsync` (regla §5 de Raft: persistir término/voto antes de responder al RPC). La compactación (`compact_to`, D2) se dispara por **política** (umbral de entradas aplicadas) desde el portador, ya con seguridad.
4. **Multi-reactor en el Server.** El `Server` pasa de un `Reactor` único a un `ReactorPool` (uno por núcleo, *pinned*); el listener acepta en el reactor 0 y el `RequestRouter` enruta cada petición a la partición por su reactor dueño (`call_on`), volviéndose **asíncrono** (`task<expected<...>>`). `ReplicatedPartition` (ADR-0016) sustituye a `Partition` cuando `replication_factor > 1`; con factor 1 (mono-nodo, desarrollo) sigue `Partition`.

Sobre de wire de Raft

El formato del sobre es `topic | partition | from | to | type:u8 | payload`, con prefijo de longitud para *streaming* sobre TCP. El campo `type` es el discriminante del `variant` del RPC y el `payload` reutiliza el `encode / decode` por RPC ya existente (ADR-0014). De este modo el contrato de wire de Raft reaprovecha los codecs de los RPC sin duplicarlos.

Consecuencias

- (+) D1/D2 dejan de ser mecanismo latente: el consenso se replica de verdad por la red y sobrevive a reinicios; la compactación acota el log en el servidor vivo.
- (+) El plano inter-nodo separado evita mezclar el contrato de cliente con el de réplica: evolucionan por separado (ADR-0013) y tienen SLAs distintos.
- (+) El portador por reactor respeta shared-nothing (ADR-0005).
- (+) La red virtual determinista se **conserva** para probar la lógica de la FSM; el transporte real se prueba aparte (sockets de loopback más inyección de caos).
- (–) Aparece un segundo listener/puerto (inter-nodo) y direccionamiento de peers por configuración.
- (–) El `RequestRouter` cambia de firma a asíncrono y el camino de despacho se refactoriza; se hace incremental para no romper el árbol.
- (–) El transporte real introduce timeouts/reintentos/reordenamiento que la red virtual no tenía: se asumen como parte del plano de red (`fundamentos/redes/`).

Alternativas consideradas

- **Reutilizar el plano de cliente para los RPC de Raft (un puerto, `ApiKey` s nuevas):** acopla el contrato de cliente al de réplica, mezcla flujos con SLAs distintos y complica el versionado. Se separa el plano. Descartada.
- **Portador global único (un hilo conduce todas las particiones):** concentra el trabajo, rompe shared-nothing y serializa el consenso de particiones independientes. Se hace por partición/reactor. Descartada.
- **Persistir el estado de Raft en cada tick (no solo si *dirty*):** `fsync` innecesarios en el camino caliente. Se persiste solo ante cambio (`dirty`), antes de enviar. Descartada.
- **`co_await` cross-core para el *reply* del RPC (estilo `call_on`):** un RPC a un nodo remoto **no vuelve** al completarse; su respuesta entra después como **otro** RPC (notificación asíncrona). El transporte inter-nodo es *fire-and-forget* con *reply* diferido, no petición/respuesta acoplada (a diferencia del `call_on` cross-core, que sí es local y síncrono entre reactores). Descartada para el plano de red.

ADR-0026: Sharding por núcleo del plano de datos — partición→núcleo y coordinación de grupos por hash

- **Estado:** aceptado
- **Fecha:** 2026-06-21

Contexto

ADR-0025 (punto 4) decidió mover el `Server` a un `ReactorPool` y volver asíncrono el `RequestRouter`, pero dejó a **alto nivel** cómo se reparte el estado entre núcleos. Tras D3.4a (`dispatch` asíncrono) y D3.4b (`Server` sobre `ReactorPool` con el plano de datos **confinado al núcleo 0**, sin *data races*), toca decidir el **sharding** concreto.

El modelo es *shared-nothing thread-per-core* (ADR-0005): ningún estado mutable se comparte entre hilos; el único canal entre núcleos es el paso de mensajes (`PartitionRouter` / `call_on`, ya existentes y probados). Hay tres estados que ubicar:

- (a) el **log/estado de cada partición** (`Partition` / `ReplicatedPartition`, hoy todos en un `TopicManager` único),
- (b) los **metadatos de topics** (qué topics existen y con cuántas particiones),
- (c) la **coordinación de grupos de consumidores** y sus **offsets confirmados** (`GroupCoordinator` / `OffsetManager`, hoy una instancia REACTOR-LOCAL por router).

Decisión

Tres reglas de ubicación, coherentes con shared-nothing:

1. **Partición → núcleo dueño** = `partition % N` (ya lo fija `PartitionRouter`). El **estado de cada partición** (su log, su pila Raft) vive **solo** en el reactor dueño. El `TopicManager` se **fragmenta**: cada núcleo abre e instancia únicamente las particiones que le tocan; las demás no existen en su memoria. Las operaciones de partición (Produce/Fetch) se enrutan al núcleo dueño con `call_on` (cross-core local y síncrono entre reactores; ADR-0025).
2. **Metadatos de topics = inmutables tras crear, replicados por valor a cada núcleo**. El conjunto `{nombre topic → nº particiones}` es plano de control que cambia raras veces (Create/DeleteTopic). Cada núcleo guarda **su propia copia** (INMUTABLE entre cambios), de modo que `Metadata` y la validación ("¿existe la partición P?") se responden **localmente** sin cross-core. Un cambio de metadatos se propaga publicando la nueva copia a cada núcleo vía `submit_to` (control, no *hot path*). No hay un `TopicManager` compartido con lock: se elige réplica inmutable por núcleo frente a estado compartido sincronizado.
3. **Grupo de consumidores → núcleo coordinador** = `hash(group_id) % N` (estilo Kafka *group coordinator*). La membresía del grupo (`GroupCoordinator`) y sus **offsets confirmados** (`OffsetManager`) viven en **un solo** núcleo —el coordinador del grupo—, no replicados. Las operaciones de grupo (JoinGroup/SyncGroup/Heartbeat/OffsetCommit/OffsetFetch) se enrutan a ese núcleo con `call_on`. Así cada grupo tiene un **dueño único** (linealizable sin locks) y la carga de grupos se reparte entre núcleos. El listado de grupos del puerto admin agrega con `call_on` sobre todos los núcleos.

Función de hash de ubicación

`hash(group_id)` usa una función estable y documentada (FNV-1a sobre los bytes del id), parte del **contrato interno** de ubicación; no viaja por wire.

Consecuencias

- (+) Cero estado mutable compartido entre hilos: el modelo sigue siendo shared-nothing puro (ADR-0005); la corrección no depende de locks sino del confinamiento por reactor.
- (+) Produce/Fetch y las operaciones de grupo escalan con los núcleos; cada partición y cada grupo tienen un dueño único que serializa sus operaciones sin contención global.
- (+) `Metadata` /validación son locales (sin cross-core en el *hot path* de cada petición).
- (–) Una petición que toca una partición o un grupo de **otro** núcleo paga un salto cross-core (`call_on` : encolar en el buzón del dueño más reanudar); es el coste inherente del sharding y se mide en D3.4.
- (–) Los metadatos de topics se **duplican** por núcleo: aceptable por ser pequeños e inmutables entre cambios, pero la propagación de un Create/DeleteTopic debe alcanzar a todos los núcleos antes de servir el nuevo estado.
- (–) El `RequestRouter` pasa a tener **una instancia por núcleo** y a depender del `PartitionRouter` / `call_on` ; su modelo de test cambia (de `sync_wait` sin reactor a conducir un reactor real o un doble).

Alternativas consideradas

- `TopicManager` **único compartido con lock (RW-mutex)**: rompe shared-nothing, introduce contención en el *hot path* y *cache ping-pong* en el lock; contradice ADR-0005 y la normativa de concurrencia ("la mejor región crítica es la que no existe"). Descartada.
- **Coordinador de grupos global en el núcleo 0**: concentra toda la carga de grupos en un núcleo (punto caliente) y serializa grupos independientes. Se reparte por hash del `group_id` . Descartada.
- **Replicar también offsets/membresía de grupo a todos los núcleos**: exigiría sincronizar escrituras entre núcleos (consenso o locks) para mantener un único valor confirmado por grupo; rompe el dueño único. Se confina cada grupo a su coordinador. Descartada.
- **Sharding de particiones por *hash(topic,partition)* en vez de `partition % N`**: repartiría mejor topics con pocas particiones, pero rompe la igualdad con `PartitionRouter` (ya probado) y el mapeo directo partición→Raft→núcleo. Se mantiene `partition % N` . Descartada.

ADR-0027: Cableado del modo proxy en el plano de datos — *pool* de conexiones aguas arriba por reactor

- **Estado:** aceptado
- **Fecha:** 2026-06-25

Contexto

ADR-0006 definió el *ingress* en **dos modos**: nativo directo (primario, *smart-client* al líder) y **proxy** (secundario, *opt-in*: enruta clientes "tontos" por *consistent-hashing* y releva sus tramas a un nodo). I18 implementó la lógica enrutable y testeable del proxy (`Proxy::route` sobre el anillo del `LoadBalancer` y `Proxy::forward` , relevo petición/respuesta **a nivel de trama** entre dos `Socket` ya conectados), pero **difirió** al cableado de servidor (D4-3) el *dialado* del nodo aguas arriba y el *pool*/reúso de esas conexiones.

Faltan dos piezas para activar el modo en el plano de datos: (a) **establecer** la conexión al plano de datos del nodo elegido **sin bloquear** el reactor, y (b) **reutilizarla** (un *handshake* TCP por petición cuesta RTTs; la normativa de redes exige *connection pooling*). Además, el `PeerDirectory` (ADR-0025) resuelve solo el **plano inter-nodo (Raft)**, en un puerto **separado** del plano de datos: el proxy no puede reusarlo para dialar el puerto de cliente.

Decisión

1. **UpstreamPool por reactor, REACTOR-LOCAL.** Cada reactor mantiene su propio *pool* —sin locks, coherente con shared-nothing (ADR-0005)—. `acquire(proactor, node)` devuelve una conexión **viva y en préstamo exclusivo** al nodo: reúsa una ociosa de la *free-list* del nodo o **diala una nueva** de forma asíncrona (`Socket::async_connect`) si no hay. `release(node, socket)` la devuelve a la *free-list* para reúso. El préstamo es **exclusivo** mientras dura el relevo de una conexión de cliente (el relevo es petición/respuesta a nivel de trama, I18): así nunca se **intercalan** tramas de dos clientes en la misma conexión aguas arriba (que corrompería el flujo). La *free-list* por nodo está **acotada** (cierra el excedente) para no fugar descriptores ni crecer sin límite (colas acotadas, normativa de concurrencia/datos-distribuidos).
2. **Directorio de direcciones del plano de datos, distinto del de Raft.** El `UpstreamPool` resuelve `NodeId` → `host:puerto` del **plano de cliente** mediante un `PeerDirectory` poblado con direcciones del plano de datos (instancia **separada** de la del plano Raft de ADR-0025). Se **reutiliza el tipo** `PeerDirectory / PeerAddress` (estructura idéntica: `NodeId` → `host:puerto` , inmutable, thread-safe de solo lectura) en vez de duplicar un tipo casi igual (minimiza entidades, Kent Beck 4); la distinción Raft vs datos es por **instancia y composición**, no por tipo. El *composition root* construye y posee ambos directorios.
3. **Activación opt-in.** El modo proxy del plano de datos es **opt-in** (ADR-0006): sin configurarlo, el servidor atiende en modo nativo directo (cada conexión la sirve `serve_connection` localmente). Con el modo activo, la conexión de cliente se enruta (`Proxy::route`) a un nodo y se releva (`Proxy::forward`) sobre una conexión obtenida del `UpstreamPool` , devuelta al *pool* al cerrar limpiamente el cliente.

Consecuencias

- (+) El proxy reutiliza conexiones TCP aguas arriba (ahorra *handshakes*/RTTs), cumple la normativa de redes y mantiene shared-nothing (un *pool* por reactor, sin contención).
- (+) El dialado es **asíncrono** (no congela el reactor).
- (+) Préstamo exclusivo $\Rightarrow$ sin intercalado de tramas $\Rightarrow$ corrección del relevo.
- (–) Una conexión ociosa reusada puede haber sido cerrada por el par mientras esperaba; el primer uso fallará y el llamante la descarta (un *health-check*/reintento de un salto queda como **mejora futura**, no en este corte).
- (–) Otro estado por reactor, que vive y se destruye en orden con el *pool* de reactores.
- (–) El proxy añade un salto y rompe el *zero-copy* (coste asumido y documentado en ADR-0006).

Alternativas consideradas

- **Pool global compartido entre reactores (con lock):** rompe shared-nothing (ADR-0005), introduce contención y *cache ping-pong* en el *hot path*; contradice la normativa de concurrencia. Descartada.
- **Dialar una conexión nueva por cada conexión de cliente, sin pool:** simple, pero paga un *handshake* TCP por cliente y no reusa nada; contradice la normativa de redes (*connection pooling*). Se conserva como **caso degenerado** (free-list vacía), no como diseño. Descartada como único.
- **Reúso concurrente de una conexión aguas arriba entre varios clientes (multiplexado por `correlation_id`):** maximizaría el reúso, pero exige **remapear** `correlation_id` y casar respuestas fuera de orden; mucho más complejo y propenso a errores. El relevo de I18 es por conexión; se mantiene el préstamo exclusivo. Descartada (posible evolución futura).
- **Añadir el puerto de datos al `PeerDirectory` de Raft (un solo directorio con dos puertos):** acopla dos planos con ciclos de vida y semánticas distintas en un mismo tipo; se prefieren **dos instancias** del mismo tipo. Descartada.

ADR-0028: Port completo de `nexusd` a Windows — backend, afinidad y señales por plataforma

- **Estado:** aceptado
- **Fecha:** 2026-06-27

Contexto

ADR-0023 dejó `nexus-io` (File/Socket/Listener + `IocpBackend`) **verificado en runtime** en Windows, pero ese alcance se limitaba a `nexus-io`: el resto del árbol seguía Linux-nativo y **no compilaba** en Windows. Este ADR amplía aquel alcance "solo `nexus-io`" al daemon completo (W3). Los puntos que bloqueaban la compilación del árbol entero eran:

- la **factoría de proactor** del `Server` construía siempre `IoUringBackend` (declarado en todas las plataformas pero **definido solo en Linux** → fallo de enlace),
- el *pinning* del `ReactorPool` usaba `pthread_setaffinity_np` / `cpu_set_t`,
- `nexusd` registraba señales POSIX,
- quedaban fugas POSIX en hojas (cliente/CLI bloqueantes con sockets BSD, `gmtime_r`, `std::filesystem::path::c_str()` que es `wchar_t*` en Windows y choca con las APIs `const char*` de OpenSSL).

El valor de portabilidad —que el puerto `Proactor` admite otro proactor— ya estaba demostrado por `nexus-io`; faltaba **extenderlo al daemon entero** (W3).

Decisión

Portar todo el árbol a Windows confinando la divergencia tras la abstracción `nexus-io` (`Proactor`) y guardas `#if defined(_WIN32)`, dejando el camino POSIX byte-idéntico. Cuatro piezas:

1. **Factoría de proactor (compilación).** `Server` elige el backend por defecto en compilación: `IocpBackend` en Windows, `IoUringBackend` en Linux (`make_default_proactor`, antes `make_io_uring_proactor`). Ambos son **proactores sobre el mismo puerto `Proactor`** (ADR-0021/0023), así que el bucle del reactor, el `RequestRouter` y las corrutinas de servicio **no cambian**. La DIP sigue intacta: los tests inyectan su doble.
2. **Afinidad de hilo.** `pin_thread_to_core` usa `SetThreadAffinityMask(handle, mask)` en Win32 y `pthread_setaffinity_np` / `cpu_set_t` en POSIX, con el **mismo reparto** `core % cpus`. Mejor esfuerzo en ambos; en Windows la máscara cubre un grupo de procesadores (≤ 64 CPUs), suficiente para el objetivo.
3. **Señales / parada.** `nexusd` registra `SetConsoleCtrlHandler` en Windows (capta Ctrl-C, Ctrl-Break, cierre de consola, *logoff* y apagado, en un hilo aparte) y `std::signal(SIGINT/SIGTERM)` en POSIX. Ambos manejadores solo **despiertan** el servidor: `Server::stop()` marca un flag y llama `Reactor::stop()` → `Proactor::wake()`, que en IOCP es `PostQueuedCompletionStatus` (thread-safe). El "despertar por `eventfd`" era un detalle del backend `io_uring`; **la abstracción `wake()` ya era portable**, así que el plano de control no necesitó rediseño, solo el registro del manejador.
4. **Hojas POSIX.** Sockets bloqueantes del cliente nativo y del CLI → Winsock (`SOCKET` / `closesocket`, firma y signo de `send` / `recv`, sin `MSG_NOSIGNAL`, `WSAStartup` por proceso vía RAIL como en `nexus-io`);

`gmtime_r` → `gmtime_s` (argumentos invertidos); rutas a OpenSSL vía un `native_path` que en POSIX devuelve la propia `path` (coste cero) y en Windows materializa la string narrow. Y se alinea la **política de avisos** MSVC con la canónica de Linux desactivando dos avisos `/w4` benignos que el gate Linux no exige (`C4324` —padding por `alignas` *deliberado* en las colas SPSC/MPMC— y `C4456` —*shadowing* idiomático de variables de condición en cadenas `if/else-if`—).

Consecuencias

- (+) **Todo el árbol** (`nexusd`, `nexus-cli`, `nexus-loadgen`, librerías) **compila y enlaza en Windows** con MSVC `/w4` `/WX` y con clang-cl (W2), no solo `nexus-io`: la portabilidad del puerto `Proactor` queda demostrada para el daemon completo.
- (+) Un solo binario, dos plataformas; comportamiento **idéntico en Linux** (todo guardado o inerte).
- (+) El diseño `Proactor` de ADR-0021/0023 se confirma: bastó **elegir** el backend, sin tocar el reactor.
- (–) El **runtime** del daemon en Windows (smoke produce/fetch por IOCP) y los **tests** (`ctest`) se verifican en etapas aparte (mismo patrón que ADR-0023).
- (–) La afinidad en máquinas de **> 64 CPUs** es aproximada en Windows (un solo grupo de procesadores); aceptable para el objetivo de *locality*.
- (–) El **gate canónico** (Linux: GCC/libstdc++ + Clang/libc++ + ASan/TSan) **no se ejecuta en Windows**: el cambio se entrega en la rama `windows-port` y el autor lo revalida y fusiona desde una sesión Linux.

Alternativas consideradas

- **Selección de backend por polimorfismo en runtime (un flag/registro)**: innecesaria —los backends son **excluyentes por plataforma**, conocida en compilación—; un `#if` es coste cero y no añade estado. Descartada.
- **Capa de abstracción de sockets bloqueantes compartida**: solo dos ficheros la usan (cliente nativo y CLI); una guarda local por fichero es más simple que un tipo nuevo. Aplazada (si surge un tercer consumidor).
- **Quedarse con `std::signal(SIGINT)` también en Windows**: compila, pero **no capta** cierre de consola/logoff/apagado y `SIGTERM` no se levanta en Windows; `SetConsoleCtrlHandler` es idiomático y completo. Descartada.
- **Renombrar las variables que disparan `C4456` o reordenar las colas para `C4324`**: churn en código **canónico** por avisos que la política de Linux no exige; se prefiere **alinear la política MSVC** (espejo de los checks apagados en `.clang-tidy`), dejando el código compartido intacto. Descartada.

ADR-0029: Adaptador Kafka asíncrono cross-core sobre el broker vivo + codec por versión (interop `kcat`)

- **Estado:** aceptado
- **Fecha:** 2026-06-28

Contexto

F7a–F7e entregaron el subconjunto Kafka como **librería de protocolo** (`src/kafka/` : codec big-endian, cabeceras, `ApiVersions` / `Metadata` / `Produce` / `Fetch` , `dispatcher` `KafkaGateway` con el puerto `KafkaBroker`), pero **sin cablear al servidor**: `nexusd` no escuchaba Kafka por ningún socket y no existía un adaptador real del puerto `KafkaBroker` . Faltaba cerrar el objetivo declarado de F7 —"habla con `kcat` "— con **interop verificada en vivo**.

Dos fuerzas condicionan el diseño:

1. el plano de datos es **shared-nothing thread-per-core** con **sharding partición→núcleo** (ADR-0026), así que una conexión Kafka aceptada en un reactor cualquiera debe poder tocar particiones que **posee otro núcleo**;
2. `kcat` /`librdkafka` **no negocia las versiones flexibles** que F7d/F7e asumían: usa **Produce v7** y **Fetch v11**, que son **clásicas** (longitudes `INT16` / `INT32` , sin *tagged fields*), mientras que `Metadata` v9 / `ListOffsets` v7 / `ApiVersions` v3 sí son flexibles.

Decisión

Un adaptador `KafkaServerBroker` (en `nexus-server`) que implementa el puerto `KafkaBroker` como **corrutinas** `task<...>` y enruta cada partición a su núcleo dueño vía `PartitionRouter::route` (ADR-0026), con un **listener** Kafka en puerto propio (`--kafka-port`) y codecs **Produce/Fetch** gobernados por la **versión negociada**. Cinco piezas:

1. **Puerto asíncrono.** Los métodos de `KafkaBroker` (`metadata` / `produce` / `fetch` / `list_offsets`) pasan a devolver `task<...>`: el `KafkaGateway` hace `co_await broker_.X(req)` . Así el adaptador puede **saltar al reactor dueño** de la partición y volver, en vez de restringir el servicio al núcleo 0. Es la elección **correcta** frente a un adaptador síncrono-solo-núcleo-0: respeta el *sharding* sin serializar todo en un núcleo.
2. **Cableado.** `Server` abre un *listener* en `--kafka-port` (separado del 9092 nativo); cada conexión la sirve `serve_kafka_connection` con el framing **Size:INT32** (big-endian) que alimenta `KafkaGateway::handle_request` . El adaptador se construye en el *composition root* del servidor (núcleo 0 como ancla de metadatos; `bind_cluster` le inyecta el `PartitionRouter` y los `TopicManager` por núcleo).
3. **Codec por versión.** `decode/encode` de Produce y Fetch reciben `api_version` y ramifican **clásico vs flexible** (`is_flexible(api_key, version)`), con *gates* de campo por versión (p. ej. `transactional_id` v3+, `last_fetched_epoch` **solo v12+** —el bug que rompía Fetch v11—). `ApiVersions` anuncia rangos que cubren lo que negocia `librdkafka`.
4. **Almacenamiento opaco con rebase de offset.** El `RecordBatch` v2 de Kafka se guarda **opaco** dentro del envoltorio interno del log (solo su `record_count` gobierna los offsets); en `Fetch` se reconstruye el blob y

se **reescribe el** `baseOffset` autoritativo (el CRC de Kafka cubre desde `attributes` , así que parchear `baseOffset` **no** invalida el CRC).

5. **Records nunca** `null` . Un `Fetch` sin datos nuevos (consumidor al día con el *high-watermark*) devuelve un `MessageSet` **vacío** (longitud 0), **no** `null` (-1): librdkafka rechaza un `MessageSetSize` de -1 como trama corrupta.

Consecuencias

- (+) `kcat` **interopera en vivo**: `-L` (metadata), `-P` (produce) y `-C` (consume) funcionan, incluido **multi-partición cross-core** (mensajes servidos desde el núcleo dueño).
- (+) El puerto `KafkaBroker` queda **desacoplado** del broker (DIP): el protocolo no conoce `nexus-broker` y se testea con un `FakeBroker` ; el adaptador con un broker local *unbound*.
- (+) El diseño de ADR-0026 se confirma: bastó `co_await route(...)` por partición.
- (–) El adaptador asíncrono **propaga** `task<>` a todo el puerto (más verboso que síncrono), justificado por la corrección cross-core.
- (–) Cobertura **parcial** del protocolo: solo las 5 APIs y las versiones que negocia librdkafka; sin grupos de consumidores (`JoinGroup` / `Heartbeat`) ni transacciones —fuera del alcance *stretch*.

Alternativas consideradas

- **Adaptador síncrono que sirve solo desde el núcleo 0**: *diff* menor, pero **viola el sharding** (toda partición tendría que vivir o copiarse al núcleo 0) o serializa el tráfico Kafka en un núcleo. Descartada: la corrección y la coherencia con ADR-0026 pesan más que el tamaño del cambio.
- **Asumir versiones flexibles (v9/v12) e ignorar las clásicas**: es lo que hacía F7d/F7e y **rompe con** `kcat` (Produce v7 / Fetch v11). El codec **debe** ramificar por versión. Descartada.
- **Traducir el** `RecordBatch` **de Kafka a/desde el formato interno (no opaco)**: caro y frágil (reencode más recálculo de CRC en el *hot path*) sin beneficio: el log solo necesita contar records y asignar offsets. Descartada a favor del blob opaco más rebase de `baseOffset` .

ADR-0030: Partición mono-protocolo — guarda cross-protocol nativo/Kafka

- **Estado:** aceptado
- **Fecha:** 2026-07-09

Contexto

El plano de datos habla dos protocolos sobre el **mismo** almacenamiento: el **binario nativo** (ADR-0004) y el **subconjunto Kafka** (ADR-0029). Ambos anexas al mismo `PartitionLog`, pero **codifican los records de forma incompatible**:

- El camino **nativo** guarda un `RecordBatch` propio cuyo payload son records nativos.
- El adaptador **Kafka** envuelve el `RecordBatch` v2 de Kafka como **blob opaco** dentro de un `RecordBatch` interno: `produce` cuenta sus records para avanzar offsets y `fetch` lo devuelve tal cual, reescribiendo el `baseOffset` (ADR-0029).

Nada impedía **mezclar** los dos protocolos en una misma partición. Si un productor nativo y un consumidor Kafka (o viceversa) tocaban la misma partición, el consumidor recibía bytes que su decodificador no sabe leer: el lado Kafka intentaba interpretar records nativos como un `RecordBatch` v2 y, al fallar el `peek`, **devolvía cero records en silencio**; el lado nativo servía el blob de Kafka como si fueran records nativos. En ambos casos el fallo era **silencioso y corruptor** —el peor modo de fallo—: ni un error al productor ni al consumidor, solo datos ilegibles.

Un informe de pruebas (hallazgo P2) lo detectó: *native/Kafka cross-protocol incompatibility in the same topic*. Había que **cerrar la puerta** a la mezcla y hacer el fallo **explícito**.

Decisión

Una partición es **mono-protocolo**: el **primer** productor que escribe en ella **reclama** su protocolo, y todo acceso posterior del **otro** protocolo se **rechaza con un error de wire**.

1. **Marca por partición.** `PartitionBase` lleva un `WireProtocol protocol_` (`Unset` → `Native` | `Kafka`), `REACTOR-LOCAL` (sin sincronizar: cada partición se toca solo desde su núcleo dueño, ADR-0026). `claim_protocol(proto)` la reclama si está `Unset` o confirma que ya es la suya; si la posee el otro protocolo devuelve `InvalidArgument`.
2. **Reclamo en la escritura.** El `produce` de cada borde reclama **antes** de anexas: el `RequestRouter` con `Native`, el `KafkaServerBroker` con `Kafka`. Un cruce en `produce` se traduce a `InvalidRequest` en ambos wires (`from_error` en el nativo; `to_kafka_error` en Kafka), un error **permanente** (reintentar no ayuda).
3. **Rechazo en la lectura.** El `fetch` de cada borde consulta `protocol()`: si la partición la posee el **otro** protocolo, devuelve `InvalidRequest` en vez de servir bytes ilegibles. Esto **sustituye el retorno silencioso de cero records** por un error tipado y visible.

La marca es **por partición**, no por topic: cada partición es un log independiente y el cruce solo corrompe dentro de una misma partición (ADR-0026). No se inventa un código de wire nuevo: se reutiliza

`InvalidRequest` , que ya existe en ambos protocolos, con un mensaje de contexto que nombra el cruce.

Consecuencias

- (+) **Fin del fallo silencioso:** mezclar protocolos en una partición produce un error explícito (`InvalidRequest`) al productor o al consumidor infractor, en lugar de datos corruptos.
- (+) **Coste despreciable:** una comparación de enum en el borde de `produce / fetch` , sin E/S ni cross-core añadido; la marca vive con la partición en su núcleo dueño.
- (+) **Sin cambio de contrato de wire:** no hay código de error nuevo; los clientes existentes ya entienden `InvalidRequest` .
- (–) **Granularidad de proceso (en memoria):** `protocol_` no se persiste. Tras un reinicio arranca en `Unset` y la **primera** escritura vuelve a reclamar; el protocolo de los datos **ya presentes en disco** no se re-infiere al abrir el log. En la práctica una partición se dedica a un protocolo, así que la marca se re-establece con el mismo valor; persistir el protocolo (cabecera de log/metadatos) queda **diferido** a cuando exista un caso real de mezcla tras reinicio.
- (–) **No hay transcodificación:** no se convierte entre formatos; el objetivo es aislar, no interoperar dentro de una partición. Un topic pensado para ambos mundos usa particiones (o topics) separados por protocolo.

Alternativas consideradas

- **No hacer nada (statu quo):** deja el fallo silencioso y corruptor. Descartada: es justo el hallazgo P2.
- **Marca por topic en vez de por partición:** más simple de razonar, pero más gruesa de lo necesario —el cruce solo daña dentro de una partición— y desalinea con el sharding partición→núcleo (la marca tendría que replicarse/consensuarse entre núcleos). Descartada a favor de por-partición.
- **Persistir el protocolo en el log/metadatos:** resolvería el caso *mezcla tras reinicio*, pero exige tocar el formato en disco y la recuperación por una situación que hoy no se da. Diferida.
- **Código de wire dedicado (p. ej. `CrossProtocol`):** más expresivo, pero amplía el contrato de errores en ambos protocolos por un caso de borde; `InvalidRequest` + mensaje basta. Descartada.
- **Transcodificar entre formatos al vuelo:** enorme superficie (semántica de records, timestamps, headers, compresión) y con pérdidas; contradice el diseño de blob opaco de ADR-0029. Descartada.

ADR-0031: Cifrado en reposo del log con AES-256-GCM y framing AEAD por bloque

- **Estado:** aceptado
- **Fecha:** 2026-07-12

Feature nueva, opcional y con degradación limpia (patrón TLS de [ADR-0019](#) y compresión): sin clave configurada, el broker escribe el log **en claro** y se comporta byte a byte como hasta ahora. Cierra el punto «cifrado en reposo» del [capítulo 30](#) (trabajo futuro).

Contexto

El log de partición persiste en disco los `RecordBatch` en claro (segmentos `.log` append-only; cap. 9). En reposo, cualquiera con acceso al volumen —copia de seguridad, disco robado, snapshot de VM, operador sin necesidad de conocer el contenido— lee los mensajes. Falta una capa de **confidencialidad en reposo** que sea opcional (no todos los despliegues la necesitan ni tienen OpenSSL), transparente (el resto del motor no cambia), y compatible con las garantías del log: **lectura por offset con acceso aleatorio**, recuperación de cola *torn*, truncado (resolución de conflictos Raft) y re-append.

El reto criptográfico central de un log append-only cifrado es el **nonce**: AES-GCM es catastróficamente inseguro si se reutiliza un par (clave, nonce). Un contador de nonces es frágil bajo el ciclo truncar→re-append del log (un seguidor Raft descarta su cola divergente y vuelve a escribir en los mismos offsets), porque re-emitaría nonces ya usados con la misma clave.

Decisión

Cifrado **AEAD AES-256-GCM** sobre el log, con **OpenSSL** como dependencia opcional

(`find_package(OpenSSL)` → `NEXUS_HAVE_OPENSSL`; sin ella, `EncryptionKey` / `SegmentCipher` devuelven `Unsupported` y los tests hacen `GTEST_SKIP`). Cinco decisiones coordinadas:

1. **Granularidad por bloque de escritura, jamás por record.** Cada `append` de un `RecordBatch` se cifra como **un bloque** independiente. Nunca se cifra record a record (coste por operación inasumible y fuga de tamaños individuales).
2. **DEK por segmento derivada de la KEK.** La **KEK** (clave maestra de 256 bits) llega por entorno/config (`NEXUS_ENCRYPTION_KEY` o `--encryption-key HEX`) y **jamás** se persiste ni entra en el repo. No cifra datos: solo deriva, vía **HKDF-SHA256(KEK, salt aleatoria de 16 bytes por segmento)**, una **DEK** distinta por segmento. Esto acota el uso de cada clave a un único segmento (aísla el radio de daño) y mantiene el número de cifrados por clave muy por debajo del límite de colisión de nonces aleatorios.
3. **Nonce aleatorio de 96 bits por bloque.** Cada bloque toma un nonce fresco del CSPRNG (`RAND_bytes`). Es **robusto ante truncado/re-append**: no hay contador que rebobinar, cada escritura es un nonce nuevo con probabilidad de colisión despreciable dado el techo de bloques por DEK. **Invariante nº 1: nunca se reutiliza un nonce con la misma clave.**

4. **Framing autodescriptivo con metadatos de traversal autenticados en claro.** El `.log` empieza por una **cabecera de segmento** de 32 bytes (`magic "NXSEG1"` | `ids` de KDF/cipher | `flags` | `salt`) → autodetección cifrado/claro al abrir y logs mixtos. Cada bloque es `version` | `flags` | `base_offset` | `record_count` | `ct_len` | `nonce(12)` | `tag(16)` | `ciphertext`. `base_offset / record_count / ct_len` viajan **en claro pero autenticados** (AAD = cabecera del bloque salvo el tag): permiten **recorrer el log y localizar por offset sin descifrar** (los offsets y tamaños no son secretos; las claves/valores de los records sí, van en el ciphertext). Manipular cualquier metadato en claro se detecta al abrir el bloque.
5. **Integridad on-disk = tag GCM; el CRC32C se conserva dentro del plaintext.** El tag GCM autentica cada bloque (supera al CRC para ciphertext). El CRC32C del batch permanece **dentro** del plaintext cifrado como defensa en profundidad y para que el camino en claro sea idéntico al de hoy.

La rotación de claves queda como **trabajo futuro documentado** (la salt por segmento y los ids en la cabecera dejan el formato preparado).

Consecuencias

- (+) Confidencialidad en reposo real (AES-NI vía OpenSSL) sin tocar el resto del motor: el cifrado vive confinado en `segment_crypto.{hpp,cpp}` y en el framing de `Segment`.
- (+) **Degradación limpia:** sin clave, o sin OpenSSL, el broker escribe en claro y los 789 tests previos siguen verdes (camino en claro byte-idéntico). Cumple coste-cero (ADR-0008).
- (+) Lectura por offset, recuperación de cola *torn*, truncado y re-append siguen funcionando **cifrados**, gracias al framing por bloque con metadatos autenticados en claro.
- (+) La DEK por segmento + nonce aleatorio hace el esquema **seguro ante el ciclo truncar→re-append** del log, sin contadores de nonce frágiles.
- (–) El `.log` cifrado no es byte-idéntico al plano (cabecera de segmento + 46 bytes de cabecera por bloque); el `scan` arranca en `data_start_`. Sobrecoste de espacio ≈ 78 bytes/segmento + 46 bytes/batch.
- (–) La KEK es responsabilidad del operador (gestión de secretos externa). Perderla = perder los datos; filtrarla = perder la confidencialidad. Sin rotación en v1.0.
- (–) Compilación condicional (`#ifdef NEXUS_HAVE_OPENSSL`) en la primitiva cripto y `GTEST_SKIP` en sus tests.

Alternativas consideradas

- **Cifrado a nivel de sistema de ficheros (LUKS/dm-crypt) o de bloque del SO:** cero código, pero fuera del control del broker, no viaja con el segmento al *tiered storage* (Hito B ofrece el ciphertext tal cual), y no protege backups/snapshots lógicos. Complementario, no sustituto.
- **Nonce por contador (determinista) con DEK global:** el patrón AES-GCM más común, pero **frágil bajo truncar→re-append** del log Raft (reusaría nonces) y concentra todo el tráfico bajo una sola clave. Descartado por la invariante nº 1.
- **AES-GCM-SIV (resistente a reutilización de nonce):** elimina el riesgo de nonce, pero exige dos pasadas sobre el plaintext y no está en toda versión de OpenSSL; el par DEK-por-segmento + nonce aleatorio da el mismo margen de seguridad con AES-GCM estándar y una sola pasada.
- **Cifrar por record:** máxima granularidad, pero coste por operación y sobrecoste de tag por record inasumibles, y filtra el tamaño de cada mensaje. Descartado a favor del bloque = batch.
- **ChaCha20-Poly1305:** excelente sin AES-NI, pero el target tiene AES-NI y OpenSSL ya estaba fijado para TLS (ADR-0019); AES-256-GCM reutiliza la misma dependencia.

ADR-0032: Almacenamiento por niveles (tiered storage)

— puerto `StorageTier` y tier local

- **Estado:** aceptado
- **Fecha:** 2026-07-12

Feature nueva, opcional y con degradación limpia (patrón TLS de [ADR-0019](#) y cifrado de [ADR-0031](#)): sin `--tier-dir`, el broker se comporta byte a byte como hasta ahora. Cierra el punto «tiered storage» del [capítulo 30](#) (trabajo futuro).

Contexto

El log de partición retiene los segmentos sellados en disco local hasta que la retención los borra (cap. 9). Para retención larga a bajo coste —el patrón de Pulsar/Kafka *tiered storage*— conviene descargar los segmentos **fríos** (sellados, ya no en el *hot set*) a un almacén de objetos barato (S3 y similares), reclamando el disco local, y **rehidratarlos de forma transparente** cuando un consumidor rezagado los lee. El reto: hacerlo sin acoplar el motor de log a una nube concreta, sin romper las garantías del log (lectura por offset, recuperación, truncado de Raft) y de forma que interopere con el cifrado en reposo (ADR-0031).

Decisión

Un **puerto** `StorageTier` (inversión de dependencias) más un adaptador local por defecto, integrados en el `PartitionLog` con **opt-in y degradación limpia**. Cinco decisiones:

- 1. Puerto orientado a fichero.** `StorageTier` expone `put_file` / `fetch_file` / `contains` / `object_size` / `remove` / `list_segment_bases` sobre una **clave de objeto** `TierObjectKey` (`<topic>/<partition>/<base:020>.<ext>`, determinista y jerárquica). Es orientado a **fichero** porque un segmento **es** un fichero: descargar y rehidratar son copias, sin cargar segmentos enteros en memoria. El `PartitionLog` depende de la interfaz, no de una nube. El adaptador por defecto (`LocalStorageTier`) copia a un **directorio objeto** local (coste cero, ADR-0008); un adaptador S3 (futuro) implementaría el mismo contrato tras `find_package`.
- 2. Descargar solo segmentos sellados; reclamar solo tras confirmar.** `offload_sealed_to_tier` sube al tier los segmentos **sellados** (nunca el activo), del más antiguo al más nuevo, y **solo tras confirmar la subida** (`put_file` es atómico e idempotente) borra los ficheros locales y marca el segmento como frío. Un fallo del tier deja el segmento local y se reintenta (idempotente). Nunca se pierde un dato por una reclamación prematura.
- 3. El tier es la autoridad; sin manifiesto local.** Al reabrir, el `PartitionLog` reconstruye su **prefijo frío** listando el tier (`list_segment_bases`), sin un fichero manifiesto que pudiera desincronizarse. Las bases que también existen localmente (offload confirmado pero sin reclamar por un *crash*) se descartan del prefijo: el segmento local es autoritativo. La **contigüidad** del log (sin huecos) permite reconstruir el rango de cada segmento frío solo con las bases ordenadas.

4. **Lectura transparente por rehidratación.** `read` sirve el *suffix* caliente localmente y, para un offset del prefijo frío, **rehidrata** el segmento (baja `.log` + `.index` a un temporal, lo abre —descifrándolo si procede, ADR-0031— y sirve el fragmento), limpiando el temporal (RAII). El rango del log (`log_start / log_end`) **no cambia** al descargar. Interopera con el cifrado: el tier guarda el **ciphertext tal cual** (sube y baja bytes opacos; la clave nunca sale del broker).

5. **Política de descarga en la rotación; operaciones destructivas tier-conscientes.** Con un tier configurado, cada **rotación** de segmento dispara la descarga de los sellados (best-effort: un fallo no aborta la rotación). Las operaciones de Raft se hacen conscientes del prefijo frío: `truncate_prefix_to / reset_to` (compactación/snapshot) borran del tier los segmentos que descartan; `truncate_to` rechaza truncar dentro del prefijo frío (historia comprometida, que Raft nunca reescribe); `enforce_retention` no toca el *hot set* local mientras haya prefijo frío (los datos más antiguos ya están en el tier).

La KEK, `--tier-dir / NEXUS_TIER_DIR`, `topic / partition` forman la identidad; el tier lo posee el *composition root* (`Server`), compartido por el nodo, y se propaga (`TopicCatalog` → `TopicManager` → `LogConfig`) como puntero **no-propietario** a cada `PartitionLog`.

Consecuencias

- (+) Retención larga a bajo coste sin tocar el resto del motor: el tiering vive en `storage_tier / local_storage_tier` y en el framing del `PartitionLog`; índice, retención y Raft no cambian.
- (+) **Degradación limpia:** sin `--tier-dir`, el prefijo frío está siempre vacío y todos los caminos nuevos son *no-ops*; el comportamiento es byte-idéntico al de hoy (858 tests verdes).
- (+) La lectura por offset, la recuperación, el truncado y el snapshot de Raft siguen funcionando con datos fríos, gracias a la rehidratación transparente y a las operaciones *tier-conscientes*.
- (+) Interopera con el cifrado en reposo (sube/baja ciphertext opaco) y prepara un adaptador S3 como evolución del mismo puerto.
- (–) La rehidratación baja el **segmento entero** por cada lectura fría (sin caché local persistente): correcto pero no óptimo. Una caché de rehidratación es trabajo futuro.
- (–) La descarga en la rotación es **síncrona** (copia de fichero en el hilo del reactor con el tier local); el offload asíncrono queda como trabajo futuro. Para el tier local (copia local) el coste es asumible.
- (–) La recuperación tras **pérdida del disco local** (árbol local vacío con objetos en el tier) queda fuera de alcance: se prioriza el caso normal de reinicio, que conserva al menos el segmento activo local.

Alternativas consideradas

- **Puerto orientado a bytes (put / get de blobs):** más portable a object stores, pero obliga a cargar segmentos enteros en memoria. Un segmento **es** un fichero; la interfaz de fichero evita la copia en RAM y el adaptador local es una copia trivial. Un adaptador S3 igualmente sube/baja vía fichero temporal (patrón estándar).
- **Manifiesto local de segmentos descargados:** rápido de consultar, pero es estado duplicado que puede desincronizarse del tier ante un *crash* entre la subida y la escritura del manifiesto. Listar el tier (autoridad única) es más simple y robusto.
- **Cifrado a nivel de tier (re-cifrar al subir):** innecesario y peligroso (la clave tendría que viajar al tier). Subir el ciphertext del ADR-0031 tal cual da confidencialidad en el tier sin exponer la KEK.

- **Descarga asíncrona en un hilo de mantenimiento:** mejor para no bloquear el reactor, pero añade un subsistema de tareas de fondo que el motor (Fase 1, E/S bloqueante en storage) aún no tiene; la descarga síncrona en la rotación es coherente con el modelo actual y se deja la versión asíncrona como evolución.
- **Borrar el segmento local sin descargar (solo retención):** es lo que ya hace `enforce_retention`; el tiering **añade** la opción de conservar los datos fríos accesibles a bajo coste en vez de perderlos.

ADR-0033: Exactly-once multi-partición nativo

(transacciones, coordinador y `read_committed`)

- **Estado:** aceptado
- **Fecha:** 2026-07-12

Feature nueva, opcional y con degradación limpia (patrón de [ADR-0031](#) y [ADR-0032](#)): sin usar la API transaccional, el broker se comporta byte a byte como hasta ahora. Cierra el punto «exactly-once transaccional entre particiones» del [capítulo 30](#) (trabajo futuro). El 2PC **recuperable** que lo sostiene se detalla en [ADR-0034](#).

Contexto

El **productor idempotente** (`ProducerSession`, §5.9) ya da *effectively-once* **por partición**: `producer_id` + época de *fencing* + dedup por secuencia descartan reintentos. Falta la pieza que hace visible **atómicamente** un conjunto de escrituras que abarca **varias particiones**: o se ven todas (commit) o ninguna (abort), sin estados intermedios observables. Es el modelo de transacciones de Kafka. El reto: darlo **solo en la superficie nativa** (no en el subset Kafka, [ADR-0030](#)), reutilizando la idempotencia existente, sin acoplarlo al resto del motor y con **terminología honesta**: es *effectively-once* end-to-end (deduplicación + visibilidad atómica), **no** una entrega *exactly-once* literal (imposible en el caso general con fallos de red).

Decisión

Un modelo transaccional **opt-in** con cuatro piezas coordinadas, todas deterministas y probadas por una simulación:

1. **Control records (marcadores COMMIT/ABORT).** Dos *flags* en `attrs` del `RecordBatch` —**transaccional** y **control**— disjuntos de los bits de códec. Un batch de **control** no lleva datos de usuario sino un único **marcador** `EndTxnMarker` (`type` COMMIT/ABORT, `coordinator_epoch`, `version`), con codec de clave/valor versionado y decodificador defensivo (`common/control_record`). El marcador delimita el fin de la transacción en el log de cada partición participante.
2. **Coordinador de transacciones como FSM sin E/S, con su propio Raft.** `TransactionCoordinator` (`broker/transaction_coordinator`) es una máquina de estados síncrona **sin E/S** (patrón `RaftNode` / `GroupCoordinator`, [ADR-0015](#)): consume `init_producer_id` / `begin` / `add_partitions` / `commit` / `abort` / `on_marker_written` / `tick` con el `now` inyectado y produce **órdenes de marcador** en una cola que el portador transporta. Su estado (metadatos de cada transacción: estado, participantes, época) es **replicable por su propio grupo Raft**. `init_producer_id` (`InitProducerId` / `initTransactions`) asigna la **identidad** del productor (`producer_id` + época) y rota la época al reiniciar.
3. **LSO por partición + nivel de aislamiento.** `PartitionTxnIndex` mantiene, por partición, el **Last Stable Offset** = `min(high_watermark, primer_offset de la transacción abierta más antigua)` y el registro de las transacciones **abortadas**. Un consumidor `read_committed` no ve más allá del LSO (los datos posteriores podrían pertenecer a una transacción sin decidir) y **filtra** los records de transacciones

abortadas y los marcadores de control (`filter_committed`); `read_uncommitted` ve todo hasta el *high-watermark*, como hasta ahora.

4. **Fencing por época en las dos direcciones.** El **productor** arrastra su época; una encarnación anterior (zombi) queda expulsada (`Fenced`) por `init_producer_id` , que además **aborta** su transacción en curso para no bloquear el LSO. El **coordinador** sella cada marcador con su `coordinator_epoch` ; una partición **descarta** los marcadores de un coordinador obsoleto (fencing en el failover). Reutiliza la misma semántica de época que `ProducerSession` (§5.9).

La API nativa — `initTransactions` / `beginTransaction` / `addPartitionsToTxn` / `commit` / `abort` — se asienta sobre estas piezas. El camino **no transaccional** (sin los *flags* en `attrs`) es byte-idéntico al de hoy.

Consecuencias

- (+) **Visibilidad atómica multi-partición:** un commit hace visibles todos los records de la transacción a los consumidores `read_committed` ; un abort, ninguno. Verificado por una **simulación determinista** (300 transacciones con commit/abort aleatorios, entregas parciales y failover del coordinador: al final se ve exactamente el conjunto confirmado).
- (+) **Degradación limpia:** sin API transaccional, el prefijo transaccional está vacío, el LSO == *high-watermark* y todos los caminos nuevos son *no-ops*.
- (+) Reutiliza la idempotencia (`ProducerSession`) y el patrón FSM-sin-E/S; el índice, la retención y Raft de partición no cambian. Interopera con el cifrado (ADR-0031) y el tiering (ADR-0032); los marcadores son records normales del log.
- (–) **Solo superficie nativa:** el subset Kafka no expone transacciones (coherente con ADR-0030). Documentado como límite.
- (–) Es *effectively-once* **honesto**, no *exactly-once* literal: la deduplicación y la visibilidad atómica evitan duplicados y estados parciales, pero la entrega end-to-end exacta no es alcanzable ante fallos arbitrarios; la terminología lo refleja.
- (–) El LSO puede **retenerse** mientras una transacción siga abierta: un productor que abre y no cierra frena a los `read_committed` de esa partición hasta el `tick` de timeout (abort del servidor).

Alternativas consideradas

- **Exactly-once literal de entrega:** imposible en el caso general (el problema de los dos generales); se elige *effectively-once* honesto (dedup + atomicidad de visibilidad), que es lo que ofrecen los sistemas reales.
- **Marcador por record en vez de por batch/transacción:** multiplicaría el overhead y rompería la unidad de escritura (el batch, §9.3). El marcador por transacción, en un batch de control propio, es el modelo de Kafka y encaja con el log existente.
- **Filtrado solo en el cliente (sin LSO en el servidor):** dejaría ver datos no confirmados hasta que el cliente los descartara; el LSO en el servidor es la frontera correcta de visibilidad y evita exponer estados intermedios.
- **Transacciones también en el subset Kafka:** fuera de alcance (ADR-0030, partición mono-protocolo); la superficie nativa es suficiente para demostrar el modelo.
- **Coordinador con estado en memoria no replicado:** un fallo perdería transacciones en vuelo; el coordinador con **Raft propio** y 2PC **logueado** (ADR-0034) lo hace recuperable.

ADR-0034: 2PC logueado y recuperable (reconciliación con la prohibición del 2PC bloqueante)

- **Estado:** aceptado
- **Fecha:** 2026-07-12

Complementa a [ADR-0033](#): detalla **cómo** se ejecuta el *two-phase commit* de una transacción multi-partición sin caer en el **2PC en memoria bloqueante** que la normativa de la biblioteca (`fundamentos/datos-distribuidos`) desaconseja.

Contexto

El *two-phase commit* clásico tiene un defecto conocido: si el **coordinador cae** entre la fase de preparación y la de commit, los participantes quedan **bloqueados** esperando la decisión, indefinidamente. Por eso la normativa del proyecto prohíbe el «2PC en memoria bloqueante». Pero el commit atómico multi-partición de [ADR-0033](#) es un 2PC (preparar la decisión → escribir marcadores en cada participante). Hay que reconciliar ambas cosas: dar atomicidad multi-partición **sin** que un fallo del coordinador bloquee a los participantes.

Decisión

Un 2PC **logueado y recuperable**, no bloqueante, con cuatro reglas:

1. **La decisión se registra antes de actuar.** El coordinador pasa la transacción a `PrepareCommit` / `PrepareAbort` —y **persiste** esa transición en su **propio log de Raft**— **antes** de escribir ningún marcador en las particiones. La decisión es durable y está replicada por quórum en cuanto se toma.
2. **La recuperación re-conduce, no espera.** Un coordinador que arranca (o un nuevo líder tras un failover) **reconstruye** su estado desde el log de Raft. Si encuentra una transacción en `Prepare*`, **re-emite** los marcadores que falten (`resume_pending`): el 2PC se **reanuda**, no se queda esperando. Los participantes nunca dependen de que un coordinador concreto siga vivo; dependen de que el **grupo Raft** del coordinador tenga quórum (postura CP, [ADR-0007](#)).
3. **Fencing del coordinador por época.** Cada marcador se sella con la `coordinator_epoch` (la época de liderazgo del coordinador que lo emite; sube en cada failover). Una partición **descarta** un marcador cuya época sea inferior a la última vista para ese productor: dos coordinadores solapados (viejo líder rezagado + nuevo líder) no pueden escribir decisiones contradictorias.
4. **Los marcadores son idempotentes; el timeout desbloquea al productor colgado.** Re-emitar un marcador ya aplicado es un *no-op* (la transacción ya está cerrada en esa partición). Una transacción que queda `ongoing` demasiado tiempo (productor que abre y no cierra) se **aborta** por `tick` de timeout, liberando el LSO de sus participantes.

Consecuencias

- (+) **No bloqueante:** la caída del coordinador no cuelga a los participantes; el nuevo líder re-conduce la decisión ya registrada. El límite es la disponibilidad del **quórum** del grupo Raft del coordinador, no la de un proceso.
- (+) **Atómico y recuperable:** la decisión (commit/abort) es durable antes de tener efectos visibles; el sistema converge al mismo resultado tras cualquier fallo a mitad, como valida la simulación determinista (failover a mitad del commit → se resuelve).
- (+) Reutiliza la infraestructura de Raft del proyecto (el coordinador es «otro grupo Raft»), sin un gestor de transacciones externo.
- (–) La escritura de marcadores es **at-least-once** (se re-emite ante la duda); la idempotencia en la partición lo absorbe.
- (–) Añade una dependencia de disponibilidad: sin quórum en el grupo del coordinador, no se pueden **cerrar** transacciones nuevas (coherente con la postura CP; las escrituras no transaccionales no se ven afectadas).

Alternativas consideradas

- **2PC en memoria bloqueante:** el modelo prohibido; un fallo del coordinador bloquea a los participantes. Descartado por la normativa y por corrección.
- **3PC (three-phase commit):** elimina el bloqueo añadiendo una fase, pero a costa de más *round-trips* y de suposiciones de temporización; el 2PC **logueado sobre Raft** logra el mismo no-bloqueo apoyándose en el consenso que el proyecto ya tiene.
- **Gestor de transacciones externo (XA/servicio aparte):** un subsistema nuevo y una dependencia operativa; el coordinador como grupo Raft propio es coherente con la arquitectura *shared-nothing* existente.
- **Decidir primero y loguear después:** invertiría el orden y abriría una ventana en la que un fallo dejaría marcadores escritos sin decisión registrada (irrecuperable). Loguear **antes** de actuar es lo que da la recuperabilidad.